# Projeto Final Ciência de Dados

March 12, 2021

## 1 Ciência de Dados - Trabalho final

### 1.1 Objetivo:

- Criação de um modelo de classificação para identificicação de malwares das categorias *Adware*, *Ransomware*, *Scareware* e *SMS Malware* em aplicações Android.

### 1.2 *Dataset* utilizado:

- *Dataset* obtido da UNB (*University of New Brunswick*) chamado CIC-AndMal2017, contendo dados de fluxo de tráfego rede de 10.854 aplicações Android sendo 4.354 malware e 6.500 de aplicações benignas.
- Nos arquivos relacioanados ao *dataset* há além dos CSVs com dados de fluxo de tráfego as APKs das aplicações.
- Mais detalhes sobre o *dataset* pode ser visto na seção "Exploração de dados" do projeto no github.

### 1.3 Bibliotecas implementadas

- Alguns códigos foram implementados para auxiliar o processamento dos dados e experimentos e são listados a seguir com seus respectivos links.
  - manifest_script.py
  - funcoes_uteis.py

## 2 Pré-processamento dos dados

- Os dados de fluxo de tráfego estão armazenados em arquivos CSVs separados em pastas por categoria e família.
- Todos os arquivos possuem a mesma estrutura com 87 colunas.
- Para fazer o treinamento dos modelos considerando o objetivo deste trabalho, faz-se necessário a junção desses arquivos em apenas um. Este processo é apresentado na sequência desse *notebook*.

[1]:
```
# Importação de bibliotecas
import pandas as pd
import numpy as np

from sklearn.neighbors import KNeighborsClassifier
from sklearn.ensemble import RandomForestClassifier
```

```
from sklearn.neural_network import MLPClassifier

from sklearn.preprocessing import MinMaxScaler
from sklearn.model_selection import train_test_split

from sklearn.metrics import accuracy_score
from sklearn.metrics import classification_report

# Códigos implementados pelo autor
from lib import funcoes_uteis
```

[4]:
```
path = '/home/efbaro/Documentos/dados/CSVs/'
# Obtém recursivamente o caminho para todos os arquivos CSVs
# a partir do ponto inicial passado como parâmetro
files = funcoes_uteis.get_csv_files(path)

df = None

for file in files:
    # Separa o nome da aplicação que está presente
    # no nome dos arquivos.
    tokens = file.split('-')
    tokens = tokens[-1].split('.pcap')
    if isinstance(df, pd.core.frame.DataFrame):
        # Lê o arquivo csv e armazena em um DataFrame
        new_df = pd.read_csv(file, delimiter=',')
        # Inclui o nome da aplicação na coluna NOME_APP
        new_df['NOME_APP'] = tokens[0]
        df = pd.concat([df, new_df])
    else:
        df = pd.read_csv(file, delimiter=',')
        df['NOME_APP'] = tokens[0]

df
```

[5]:
```
print('Número de exemplos:', len(df))
print('Número de colunas:',len(df.columns))
print('Nomes das colunas:', [coluna for coluna in df.columns])
```

```
Número de exemplos: 2616579
Número de colunas: 86
Nomes das colunas: ['Flow ID', ' Source IP', ' Source Port', ' Destination IP',
' Destination Port', ' Protocol', ' Timestamp', ' Flow Duration', ' Total Fwd
Packets', ' Total Backward Packets', 'Total Length of Fwd Packets', ' Total
Length of Bwd Packets', ' Fwd Packet Length Max', ' Fwd Packet Length Min', '
Fwd Packet Length Mean', ' Fwd Packet Length Std', 'Bwd Packet Length Max', '
Bwd Packet Length Min', ' Bwd Packet Length Mean', ' Bwd Packet Length Std',
```

```
'Flow Bytes/s', ' Flow Packets/s', ' Flow IAT Mean', ' Flow IAT Std', ' Flow IAT
Max', ' Flow IAT Min', 'Fwd IAT Total', ' Fwd IAT Mean', ' Fwd IAT Std', ' Fwd
IAT Max', ' Fwd IAT Min', 'Bwd IAT Total', ' Bwd IAT Mean', ' Bwd IAT Std', '
Bwd IAT Max', ' Bwd IAT Min', 'Fwd PSH Flags', ' Bwd PSH Flags', ' Fwd URG
Flags', ' Bwd URG Flags', ' Fwd Header Length', ' Bwd Header Length', 'Fwd
Packets/s', ' Bwd Packets/s', ' Min Packet Length', ' Max Packet Length', '
Packet Length Mean', ' Packet Length Std', ' Packet Length Variance', 'FIN Flag
Count', ' SYN Flag Count', ' RST Flag Count', ' PSH Flag Count', ' ACK Flag
Count', ' URG Flag Count', ' CWE Flag Count', ' ECE Flag Count', ' Down/Up
Ratio', ' Average Packet Size', ' Avg Fwd Segment Size', ' Avg Bwd Segment
Size', ' Fwd Header Length.1', 'Fwd Avg Bytes/Bulk', ' Fwd Avg Packets/Bulk', '
Fwd Avg Bulk Rate', ' Bwd Avg Bytes/Bulk', ' Bwd Avg Packets/Bulk', 'Bwd Avg
Bulk Rate', 'Subflow Fwd Packets', ' Subflow Fwd Bytes', ' Subflow Bwd Packets',
' Subflow Bwd Bytes', 'Init_Win_bytes_forward', ' Init_Win_bytes_backward', '
act_data_pkt_fwd', ' min_seg_size_forward', 'Active Mean', ' Active Std', '
Active Max', ' Active Min', 'Idle Mean', ' Idle Std', ' Idle Max', ' Idle Min',
' Label', 'NOME_APP']
```

### 2.1 Amostragem dos dados

- Devido a grande quantidade de exemplos, mais de 2,5 milhões, a velocidade dos treinamentos pode ser damasiadamente lenta, portanto, neste trabalho será utilizado 3% do total de exemplos, resultando em um pouco mais de 78 mil exemplos.

[6]:
```
# Descomentar
df = df.sample(frac=0.03, random_state=0)
print('Número de exemplos:', len(df))
```

```
Número de exemplos: 78497
```

[7]:
```
# Distribuição das classes
df.groupby([' Label']).size()
```

[7]:
```
 Label
ADWARE_DOWGIN                1152
ADWARE_EWIND                 1315
ADWARE_FEIWO                 1623
ADWARE_GOOLIGAN              2865
ADWARE_KEMOGE                1182
ADWARE_KOODOUS                959
ADWARE_MOBIDASH               951
ADWARE_SELFMITE               418
ADWARE_SHUANET               1221
ADWARE_YOUMI                 1028
BENIGN                      36344
MALWARE                        84
RANSOMWARE_CHARGER           1206
RANSOMWARE_JISUT              789
```

```
RANSOMWARE_KOLER              1284
RANSOMWARE_LOCKERPIN           755
RANSOMWARE_PLETOR              132
RANSOMWARE_PORNDROID          1354
RANSOMWARE_RANSOMBO           1164
RANSOMWARE_SIMPLOCKER         1035
RANSOMWARE_SVPENG             1661
RANSOMWARE_WANNALOCKER        1023
SCAREWARE                      229
SCAREWARE_ANDROIDDEFENDER     1700
SCAREWARE_ANDROIDSPY           768
SCAREWARE_AVFORANDROID        1219
SCAREWARE_AVPASS              1207
SCAREWARE_FAKEAPP             1036
SCAREWARE_FAKEAPPAL           1361
SCAREWARE_FAKEAV              1181
SCAREWARE_FAKEJOBOFFER         963
SCAREWARE_FAKETAOBAO          1047
SCAREWARE_PENETHO              688
SCAREWARE_VIRUSSHIELD          717
SMSMALWARE_BEANBOT             354
SMSMALWARE_BIIGE               970
SMSMALWARE_FAKEINST            459
SMSMALWARE_FAKEMART            173
SMSMALWARE_FAKENOTIFY          634
SMSMALWARE_JIFAKE              174
SMSMALWARE_MAZARBOT            178
SMSMALWARE_NANDROBOX          1361
SMSMALWARE_PLANKTON           1161
SMSMALWARE_SMSSNIFFER         1053
SMSMALWARE_ZSONE               317
dtype: int64
```

### 2.2 Ajuste na coluna *Label*

- Como o objetivo é prever *Malwares* para as categorias *Adware*, *Ransomware*, *Scareware* e *SMS Malware*, as famílias serão retiradas da coluna *Label*, mantendo apenas as categorias.

[8]:
```
# Divide Label em Label e Family
df[['Label', 'Family']] = df[' Label'].str.split('_', 1, expand=True)
# Remove a antiga coluna ' Label'
df = df.drop(columns=[' Label'])
```

### 2.3 Remoção de colunas

- Serão removidas as colunas:
  - *Timestamp* - representa apenas a data e a hora em que os dados foram coletados, não

tendo relavânciaa para o objetivo estabelecido.
  - *Flow ID* - representa apenas um identificador do exemplo, não representado dado relevante para o treinamento.
  - *Family* - Como o objetivo é apenas prever as categorias dos *Malwares* a Família será descartatda.
  - *Source IP* e *Destination IP* - Como os dados são de fluxo de tráfego rede, e a captura se dá pelas duas vias, o IP do aparelho se repete muitas vezes em uma das duas colunas em todos os exemplos, e é provável que exemplos novos não possuam o mesmo IP do aparelho utilizado na captura, por este motivo essas duas colunas serão removidas.
- A coluna NOME_APP será mantida pois será utilizada mais para frente.

[9]:
```
# Remove colunas desnecessárias
columns = list(df.columns)
columns.remove('Flow ID')
columns.remove(' Source IP')
columns.remove(' Destination IP')
columns.remove('Family')
columns.remove(' Timestamp')
df = df[columns]
print('Número de colunas:',len(df.columns))
```

```
Número de colunas: 82
```

### 2.4 Remoção de exemplos

- Existe um subconjunto de exemplos rotulados apenas como *Malware*, como eles não possuem uma categoria serão eliminados.
- Também serão eliminados os registros que possuem exemplos nulos.

[10]:
```
print('Número de exemplos:', len(df))
```

```
Número de exemplos: 78497
```

[11]:
```
# Remove exemplos que têm o rótulo somente MALWARE
df = df[df['Label'] != 'MALWARE']
# Remove exemplos com valores nulos.
df = df.dropna(how='any', axis=0)
```

[12]:
```
print('Número de exemplos:', len(df))
```

```
Número de exemplos: 78411
```

[13]:
```
# Exibe DataFrame resultante
df
```

[13]:

| | Source Port | Destination Port | Protocol | Flow Duration | \ |
|---|---|---|---|---|---|
| 311999 | 49738.0 | 443.0 | 6.0 | 314154.0 | |
| 2315643 | 33281.0 | 443.0 | 6.0 | 183700.0 | |

| | | | | |
|---|---|---|---|---|
| 1348860 | 54449.0 | 5222.0 | 6.0 | 119979513.0 |
| 289365 | 55276.0 | 80.0 | 6.0 | 9791581.0 |
| 2106238 | 33483.0 | 443.0 | 6.0 | 117446695.0 |
| … | … | … | … | … |
| 644643 | 45990.0 | 80.0 | 6.0 | 31756458.0 |
| 1265866 | 58928.0 | 80.0 | 6.0 | 115910.0 |
| 2370110 | 39152.0 | 53.0 | 17.0 | 1414090.0 |
| 955043 | 37919.0 | 80.0 | 6.0 | 10552731.0 |
| 1045533 | 40188.0 | 80.0 | 6.0 | 785321.0 |

| | Total Fwd Packets | Total Backward Packets | \ |
|---|---|---|---|
| 311999 | 15.0 | 18.0 | |
| 2315643 | 2.0 | 0.0 | |
| 1348860 | 49.0 | 43.0 | |
| 289365 | 2.0 | 0.0 | |
| 2106238 | 23.0 | 16.0 | |
| … | … | … | |
| 644643 | 2.0 | 0.0 | |
| 1265866 | 66.0 | 65.0 | |
| 2370110 | 1.0 | 1.0 | |
| 955043 | 2.0 | 2.0 | |
| 1045533 | 12.0 | 11.0 | |

| | Total Length of Fwd Packets | Total Length of Bwd Packets | \ |
|---|---|---|---|
| 311999 | 1637.0 | 19098.0 | |
| 2315643 | 0.0 | 0.0 | |
| 1348860 | 1111.0 | 1397.0 | |
| 289365 | 0.0 | 0.0 | |
| 2106238 | 4910.0 | 9771.0 | |
| … | … | … | |
| 644643 | 0.0 | 0.0 | |
| 1265866 | 372.0 | 89571.0 | |
| 2370110 | 32.0 | 207.0 | |
| 955043 | 0.0 | 0.0 | |
| 1045533 | 372.0 | 11524.0 | |

| | Fwd Packet Length Max | Fwd Packet Length Min | … | Active Mean | \ |
|---|---|---|---|---|---|
| 311999 | 737.0 | 0.0 | … | 0.000000e+00 | |
| 2315643 | 0.0 | 0.0 | … | 0.000000e+00 | |
| 1348860 | 273.0 | 0.0 | … | 1.985529e+06 | |
| 289365 | 0.0 | 0.0 | … | 0.000000e+00 | |
| 2106238 | 541.0 | 0.0 | … | 2.683545e+06 | |
| … | … | … | … | … | |
| 644643 | 0.0 | 0.0 | … | 0.000000e+00 | |
| 1265866 | 372.0 | 0.0 | … | 0.000000e+00 | |
| 2370110 | 32.0 | 32.0 | … | 0.000000e+00 | |
| 955043 | 0.0 | 0.0 | … | 0.000000e+00 | |

```
1045533                  372.0                    0.0  …  0.000000e+00

          Active Std   Active Max   Active Min     Idle Mean      Idle Std  \
311999   0.000000e+00          0.0          0.0  0.000000e+00  0.000000e+00
2315643  0.000000e+00          0.0          0.0  0.000000e+00  0.000000e+00
1348860  2.351435e+06    6009953.0     194744.0  1.513963e+07  3.611158e+06
289365   0.000000e+00          0.0          0.0  0.000000e+00  0.000000e+00
2106238  3.619360e+06    5242819.0     124271.0  5.602101e+07  6.875939e+07
…                 …            …            …             …             …
644643   0.000000e+00          0.0          0.0  0.000000e+00  0.000000e+00
1265866  0.000000e+00          0.0          0.0  0.000000e+00  0.000000e+00
2370110  0.000000e+00          0.0          0.0  0.000000e+00  0.000000e+00
955043   0.000000e+00          0.0          0.0  0.000000e+00  0.000000e+00
1045533  0.000000e+00          0.0          0.0  0.000000e+00  0.000000e+00

            Idle Max    Idle Min                              NOME_APP  \
311999           0.0         0.0    2c7b372254730bfa366e4759db34812c
2315643          0.0         0.0  com.asdhillon.admin.gymapplication
1348860   20168014.0  10341591.0    68c9b7be13a2baef87370d291a5190ac
289365           0.0         0.0    244c982e91b55edd55fab1c96c392211
2106238  104641248.0   7400781.0    13bca905ccc119771040fd5fd30afff1
…                …           …                                   …
644643           0.0         0.0                 zok.android.numbers
1265866          0.0         0.0    b3a694ab3b58de4a944a3d4a03f67c6d
2370110          0.0         0.0                   com.bf.app7418de
955043           0.0         0.0         com.jetappfactory.jetaudio
1045533          0.0         0.0             br.com.tapps.deardiary

              Label
311999   RANSOMWARE
2315643      BENIGN
1348860      ADWARE
289365   RANSOMWARE
2106238   SCAREWARE
…               …
644643       BENIGN
1265866      ADWARE
2370110      BENIGN
955043       BENIGN
1045533      BENIGN

[78411 rows x 82 columns]
```

### 2.5 Distribuição das amostras por classe

[14]:
```
# Distribuição das classes
funcoes_uteis.plot_distribuicao_classes(df, 'Label')
```

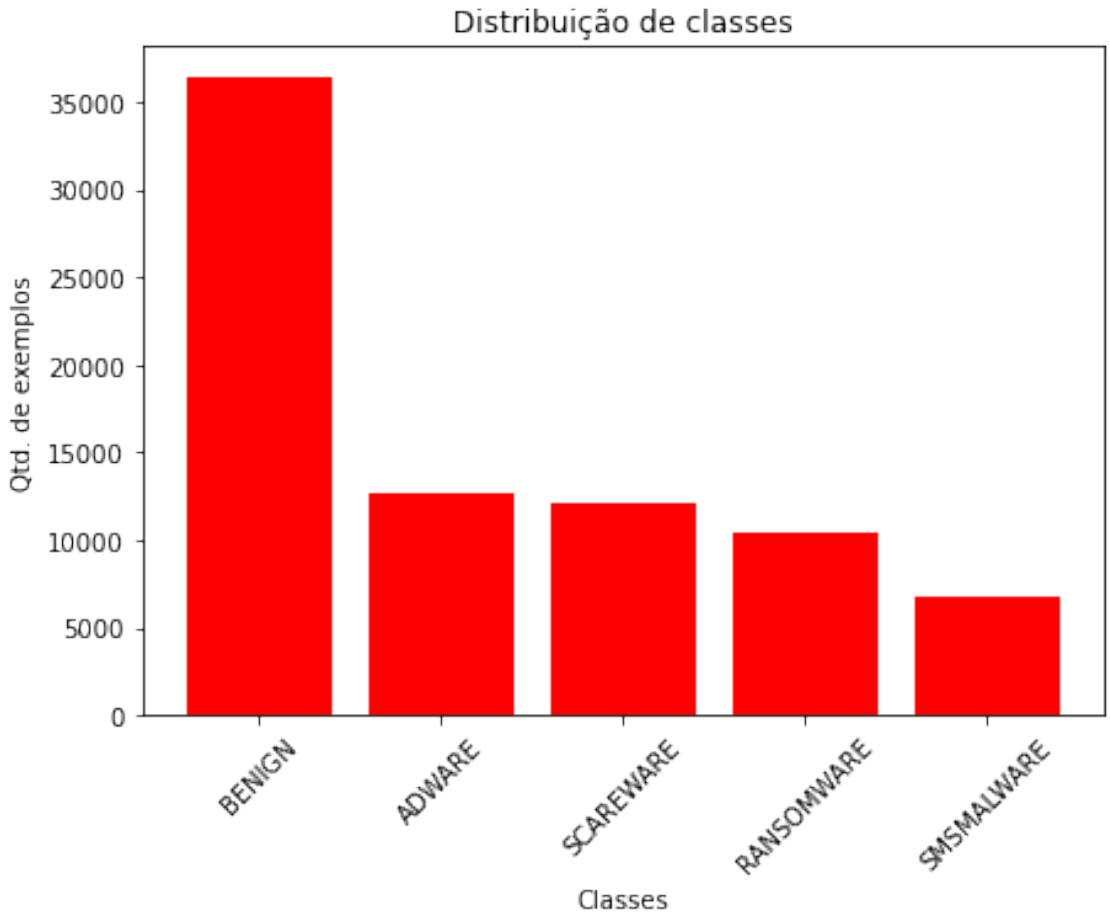


### 2.6 Salvar *dataset* preparado

- Salvar dados preparados para uso futuro.

[15]:
```
# Salva DataFrame em arquivo CSV
df.to_csv(path + 'dados_fluxo_trafego.csv', index=False)
# Reseta os índices
df.reset_index(drop=True, inplace=True)
```

[16]:
```
# Abre arquivo
#path = '/home/efbaro/Documentos/dados/CSVs/'
#df = pd.read_csv(path + 'dados_fluxo_trafego.csv', delimiter=',')
```

## 2.7 Lendo e tranformandos dados de permissões dos Android_manifests

- Para enriquecer o *dataset* foi extraído das APKs relacionados aos dados os arquivos AndroidManifests e deles extraiu-se as permissões das aplicações, que foram tranformadas em arquivos CSVs. Essa extração foi realizada com a ajuda do script manifest_script.py. Os arquivos CSVs foram organizados em pastas da mesma forma que os CSVs dos dados de tráfego de rede.
- Esses dados foram concatenados aos dados de trafego por meio do nome da aplicação.

[127]:
```
# Lê as permissões em todos os arquvios e os coloca em um único dataset
path = '/home/efbaro/Documentos/dados/CSVs_permissions/'
files = funcoes_uteis.get_csv_files(path)

df_permissions = None

for i in range(len(files)):

    # Obtém rótulo a partir do diretório da aplicação
    label = files[i].replace(path, '')
    label = label.split('/')
    label = label[0].split('_')
    label = label[0]
    label

    if i == 0:
        df_permissions = pd.read_csv(files[i], delimiter=',')
        df_permissions['Label'] = label
    else:
        new_df =  pd.read_csv(files[i], delimiter=',')
        new_df['Label'] = label
        df_permissions = pd.concat([df_permissions, new_df])

df_permissions
```

[127]:

| | NOME_APP | \ |
|---|---|---|
| 0 | 0639a74f508591f99a7d2309f5825fea | |
| 1 | 0bccdcc7d63f0754e9e66c806e8e9203 | |
| 2 | 0df8e91d4ee84180099a26d97cf5baf4 | |
| 3 | 00357b0e208c20df3182d54cb2ba15bf | |
| 4 | 02548535ff1cc285fddf699f2d77bcba | |
| .. | … | |
| 4 | c57194d05a30d53c764983c70e471791 | |
| 5 | 8be7ac1e01b3a5db14103187232d4f75 | |
| 6 | eda9098498a6201383e311f9b3757b4f | |
| 7 | 5d7af62c7f33522a8fe50085204d90c8 | |
| 8 | 1c0c1837e99107f137c47e87570be00f | |

| PERMISSOES | Label |
|---|---|

```
0    ACCESS_NETWORK_STATE|ACCESS_WIFI_STATE|CHANGE_…  Ransomware
1    ACCESS_NETWORK_STATE|ACCESS_WIFI_STATE|CHANGE_…  Ransomware
2    ACCESS_NETWORK_STATE|ACCESS_WIFI_STATE|CHANGE_…  Ransomware
3    ACCESS_NETWORK_STATE|ACCESS_WIFI_STATE|CHANGE_…  Ransomware
4    ACCESS_NETWORK_STATE|ACCESS_WIFI_STATE|CALL_PH…  Ransomware
..                                                 …          …
4    ACCESS_NETWORK_STATE|INTERNET|READ_PHONE_STATE…   Scareware
5    ACCESS_COARSE_LOCATION|ACCESS_FINE_LOCATION|AC…   Scareware
6    GET_TASKS|RECEIVE_BOOT_COMPLETED|RECEIVE_SMS|R…   Scareware
7    ACCESS_NETWORK_STATE|ACCESS_WIFI_STATE|BROADCA…   Scareware
8    ACCESS_NETWORK_STATE|ACCESS_WIFI_STATE|BROADCA…   Scareware

[2115 rows x 3 columns]
```

[128]:
```
# Remove exemplos que não tem permissoes
df_permissions = df_permissions[~df_permissions['PERMISSOES'].isnull()]
```

### 2.7.1 Conversão da colula de permissões em várias colunas com as respectivas permissões

[129]:
```
# Cria uma lista com as permissões
permlist = df_permissions.values.tolist()

big_list = []
for l in permlist:
    big_list += [[l[0]] + l[1].split('|') + [l[2]]]
len(big_list)
```

[129]: 2067

[130]:
```
# Obtenção do espaço amostral das permissões únicas
uniqueperms = {x for l in big_list for x in l[1:-1]}
print(len(uniqueperms))
```

```
469
```

[131]:
```
# Definindo o novo cabeçalho
df_header = ['NOME_APP'] + list(uniqueperms) + ['Label']
len(df_header)
```

[131]: 471

[132]:
```
# Preenchimento do dataframe de treino
df_train_content = []
nperm = len(df_header)
for sample in big_list:
    has_permission = [0] * nperm
```

```
    has_permission[0] = sample[0]
    has_permission[-1] = sample[-1]
    for perm in sample[1:-1]:
        has_permission[df_header.index(perm)] = 1
    df_train_content.append(has_permission)
df_permissoes_train = pd.DataFrame(df_train_content, columns=df_header)
pd.set_option('display.max_rows', 150)
df_permissoes_train
```

[132]:

| | NOME_APP | SENSOR_ENABLE | GALLERY_PROVIDER | \ |
|---|---|---|---|---|
| 0 | 0639a74f508591f99a7d2309f5825fea | 0 | 0 | |
| 1 | 0bccdcc7d63f0754e9e66c806e8e9203 | 0 | 0 | |
| 2 | 0df8e91d4ee84180099a26d97cf5baf4 | 0 | 0 | |
| 3 | 00357b0e208c20df3182d54cb2ba15bf | 0 | 0 | |
| 4 | 02548535ff1cc285fddf699f2d77bcba | 0 | 0 | |
| … | … | … | … | |
| 2062 | c57194d05a30d53c764983c70e471791 | 0 | 0 | |
| 2063 | 8be7ac1e01b3a5db14103187232d4f75 | 0 | 0 | |
| 2064 | eda9098498a6201383e311f9b3757b4f | 0 | 0 | |
| 2065 | 5d7af62c7f33522a8fe50085204d90c8 | 0 | 0 | |
| 2066 | 1c0c1837e99107f137c47e87570be00f | 0 | 0 | |

| | CEMOJI | WRITE_HISTORY_BOOKMARKS | lh2 | NFC_SE | AUTHENTICATE_ACCOUNTS | \ |
|---|---|---|---|---|---|---|
| 0 | 0 | 0 | 0 | 0 | 0 | |
| 1 | 0 | 0 | 0 | 0 | 0 | |
| 2 | 0 | 0 | 0 | 0 | 0 | |
| 3 | 0 | 0 | 0 | 0 | 0 | |
| 4 | 0 | 0 | 0 | 0 | 0 | |
| … | … | … | … | … | … | |
| 2062 | 0 | 0 | 0 | 0 | 0 | |
| 2063 | 0 | 0 | 0 | 0 | 0 | |
| 2064 | 0 | 0 | 0 | 0 | 0 | |
| 2065 | 0 | 0 | 0 | 0 | 0 | |
| 2066 | 0 | 0 | 0 | 0 | 0 | |

| | DELETE_CACHE_FILES | MDM_CONTENT_PROVIDER | … | DISABLE_KEYGUARD | wise | \ |
|---|---|---|---|---|---|---|
| 0 | 0 | 0 | … | 0 | 0 | |
| 1 | 0 | 0 | … | 0 | 0 | |
| 2 | 0 | 0 | … | 0 | 0 | |
| 3 | 0 | 0 | … | 0 | 0 | |
| 4 | 0 | 0 | … | 0 | 0 | |
| … | … | … | … | … | … | |
| 2062 | 0 | 0 | … | 0 | 0 | |
| 2063 | 0 | 0 | … | 0 | 0 | |
| 2064 | 0 | 0 | … | 0 | 0 | |
| 2065 | 0 | 0 | … | 1 | 0 | |
| 2066 | 0 | 0 | … | 1 | 0 | |

```
      RECORD_VIDEO  MODIFY_PHONE_STATE  ACTION_BOOT_COMPLETED  \
0                0                   0                      0
1                0                   0                      0
2                0                   0                      0
3                0                   0                      0
4                0                   0                      0
…              …                   …                      …
2062             0                   0                      0
2063             1                   0                      0
2064             0                   0                      0
2065             0                   0                      0
2066             0                   0                      0

      AVIATE_INTER_APP  jotspot  SMARTCARD  sierraqa       Label
0                    0        0          0         0  Ransomware
1                    0        0          0         0  Ransomware
2                    0        0          0         0  Ransomware
3                    0        0          0         0  Ransomware
4                    0        0          0         0  Ransomware
…                  …      …        …        …         …
2062                 0        0          0         0   Scareware
2063                 0        0          0         0   Scareware
2064                 0        0          0         0   Scareware
2065                 0        0          0         0   Scareware
2066                 0        0          0         0   Scareware

[2067 rows x 471 columns]
```

[133]:
```
# Salva dados de permissões transformados
df_permissoes_train.to_csv(path+ 'permissoes_train.csv', index=False)
# Reseta os índices
df_permissoes_train.reset_index(drop=True, inplace=True)
```

[134]:
```
# Abre arquivo
#path = '/home/efbaro/Documentos/dados/CSVs_permissions/'
#df_permissoes_train = pd.read_csv(path + 'permissoes_train.csv', delimiter=',')
```

[135]:
```
# Remove label das permissoes
columns = list(df_permissoes_train.columns)
columns.remove('Label')
df_permissoes_train = df_permissoes_train[columns]
```

### 2.7.2 Junção dos *datasets*

[136]:
```
# Faz a junção das permissões com os dados de fluxo de trafego
df = pd.merge(df, df_permissoes_train, how="left", on='NOME_APP')
```

[137]:
```
# Muda posição da coluna Label para última posição do DataFrame
colunas = list(df.columns)
colunas.remove('Label')
colunas.append('Label')
df = df[colunas]
df
```

[137]:

| | Source Port | Destination Port | Protocol | Flow Duration | \ |
|---|---|---|---|---|---|
| 0 | 49738.0 | 443.0 | 6.0 | 314154.0 | |
| 1 | 33281.0 | 443.0 | 6.0 | 183700.0 | |
| 2 | 54449.0 | 5222.0 | 6.0 | 119979513.0 | |
| 3 | 55276.0 | 80.0 | 6.0 | 9791581.0 | |
| 4 | 33483.0 | 443.0 | 6.0 | 117446695.0 | |
| … | … | … | … | … | |
| 80694 | 45990.0 | 80.0 | 6.0 | 31756458.0 | |
| 80695 | 58928.0 | 80.0 | 6.0 | 115910.0 | |
| 80696 | 39152.0 | 53.0 | 17.0 | 1414090.0 | |
| 80697 | 37919.0 | 80.0 | 6.0 | 10552731.0 | |
| 80698 | 40188.0 | 80.0 | 6.0 | 785321.0 | |

| | Total Fwd Packets | Total Backward Packets | \ |
|---|---|---|---|
| 0 | 15.0 | 18.0 | |
| 1 | 2.0 | 0.0 | |
| 2 | 49.0 | 43.0 | |
| 3 | 2.0 | 0.0 | |
| 4 | 23.0 | 16.0 | |
| … | … | … | |
| 80694 | 2.0 | 0.0 | |
| 80695 | 66.0 | 65.0 | |
| 80696 | 1.0 | 1.0 | |
| 80697 | 2.0 | 2.0 | |
| 80698 | 12.0 | 11.0 | |

| | Total Length of Fwd Packets | Total Length of Bwd Packets | \ |
|---|---|---|---|
| 0 | 1637.0 | 19098.0 | |
| 1 | 0.0 | 0.0 | |
| 2 | 1111.0 | 1397.0 | |
| 3 | 0.0 | 0.0 | |
| 4 | 4910.0 | 9771.0 | |
| … | … | … | |
| 80694 | 0.0 | 0.0 | |
| 80695 | 372.0 | 89571.0 | |

```
80696                         32.0                          207.0
80697                          0.0                            0.0
80698                        372.0                        11524.0

       Fwd Packet Length Max   Fwd Packet Length Min  …  DISABLE_KEYGUARD  \
0                      737.0                     0.0  …               0.0
1                        0.0                     0.0  …               0.0
2                      273.0                     0.0  …               0.0
3                        0.0                     0.0  …               0.0
4                      541.0                     0.0  …               0.0
…                          …                       …  …               …
80694                    0.0                     0.0  …               0.0
80695                  372.0                     0.0  …               0.0
80696                   32.0                    32.0  …               0.0
80697                    0.0                     0.0  …               1.0
80698                  372.0                     0.0  …               0.0

       wise  RECORD_VIDEO  MODIFY_PHONE_STATE  ACTION_BOOT_COMPLETED  \
0       0.0           0.0                 0.0                    0.0
1       0.0           0.0                 0.0                    0.0
2       0.0           0.0                 0.0                    0.0
3       0.0           0.0                 0.0                    0.0
4       0.0           0.0                 0.0                    0.0
…     …           …                   …                      …
80694   0.0           0.0                 0.0                    0.0
80695   0.0           0.0                 0.0                    0.0
80696   0.0           1.0                 0.0                    0.0
80697   0.0           0.0                 0.0                    0.0
80698   0.0           0.0                 0.0                    0.0

       AVIATE_INTER_APP  jotspot  SMARTCARD  sierraqa       Label
0                   0.0      0.0        0.0       0.0  RANSOMWARE
1                   0.0      0.0        0.0       0.0      BENIGN
2                   0.0      0.0        0.0       0.0      ADWARE
3                   0.0      0.0        0.0       0.0  RANSOMWARE
4                   0.0      0.0        0.0       0.0   SCAREWARE
…                 …      …        …       …         …
80694               0.0      0.0        0.0       0.0      BENIGN
80695               0.0      0.0        0.0       0.0      ADWARE
80696               0.0      0.0        0.0       0.0      BENIGN
80697               0.0      0.0        0.0       0.0      BENIGN
80698               0.0      0.0        0.0       0.0      BENIGN

[80699 rows x 551 columns]
```

[138]:
```
print('Número de exemplos:', len(df))
```

```
Número de exemplos: 80699
```

[139]:
```
# Remove exemplos com valores nulos.
df = df.dropna(how='any', axis=0)
```

[140]:
```
print('Número de exemplos:', len(df))
print('Número de colunas:',len(df.columns))
```

```
Número de exemplos: 77542
Número de colunas: 551
```

[141]:
```
# Exibe novamente a distribuição dos dados
funcoes_uteis.plot_distribuicao_classes(df, 'Label')
```

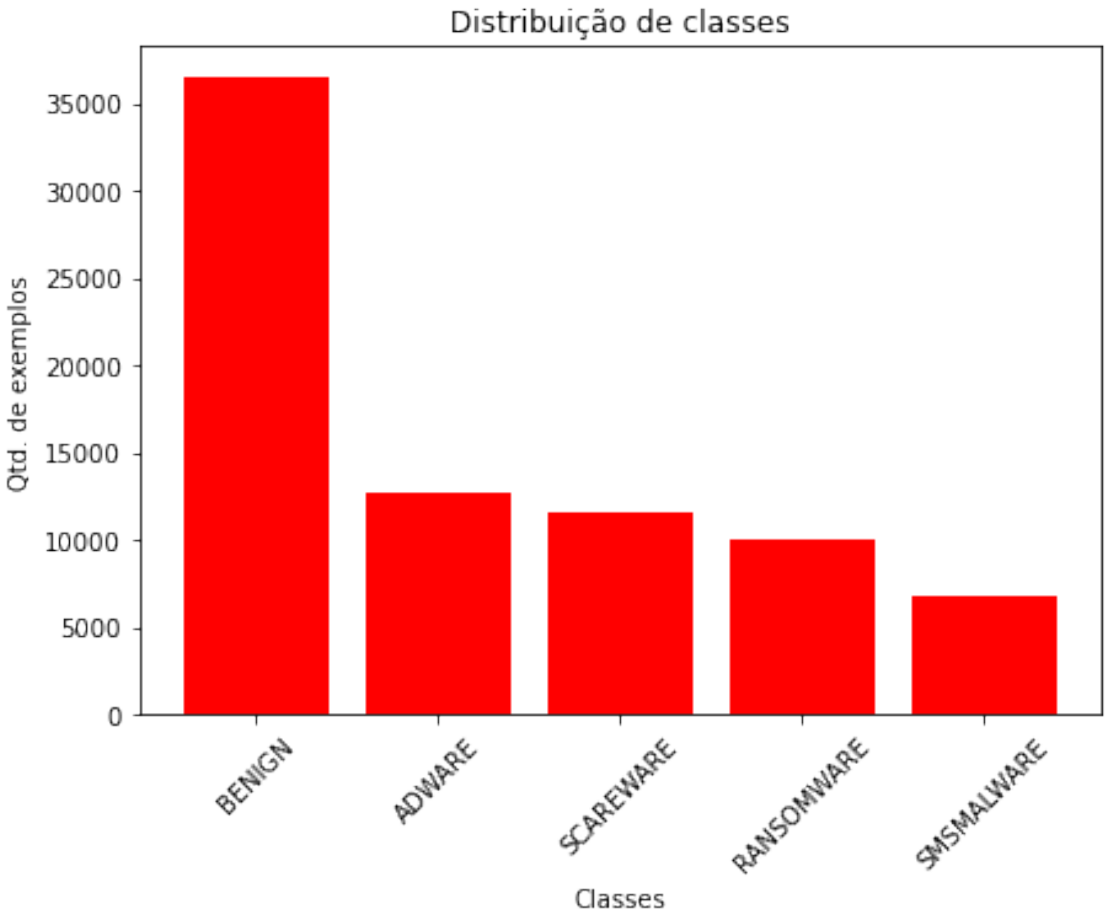


## 3 Treinamento

- O treinamento será feito com os algoritmos KNN,Random Forest e MLP.

[142]:
```
# Lista com os melhores classificados que serão utilizados na validação
dic_melhores_modelos = {'split_perc_knn':[],
                        'split_perc_rf':[],
                        'split_perc_mlp':[],
                        'melhor_val_cruz_knn':[],
                        'melhor_val_cruz_rf':[],
                        'melhor_val_cruz_mlp':[]}
```

## 3.1 Divisão do *dataset*

- O *dataset* será dividido em duas porções uma de validação com 20% do total de dados, e outra para etapa de treinamento com os outros 80%.
- Na sequência os 80% para treinamento serão divididos em mais duas partes dos quais serão 80% para treinamento dos modelos e 20% para teste.
- A separação é feita misturando os dados (shuffle=True) e estratificada pela classe *(stratify=df['Label'])* buscando com isso manter a distribuição dos dados.

[143]:
```
# Separação inicial 80/20
df_treinamento, df_validacao = train_test_split(df, test_size=0.2,␣
↪shuffle=True, stratify=df['Label'])
```

### 3.1.1 Distribuição das amostras de treinamento

[13]:
```
funcoes_uteis.plot_distribuicao_classes(df_treinamento, 'Label')
```

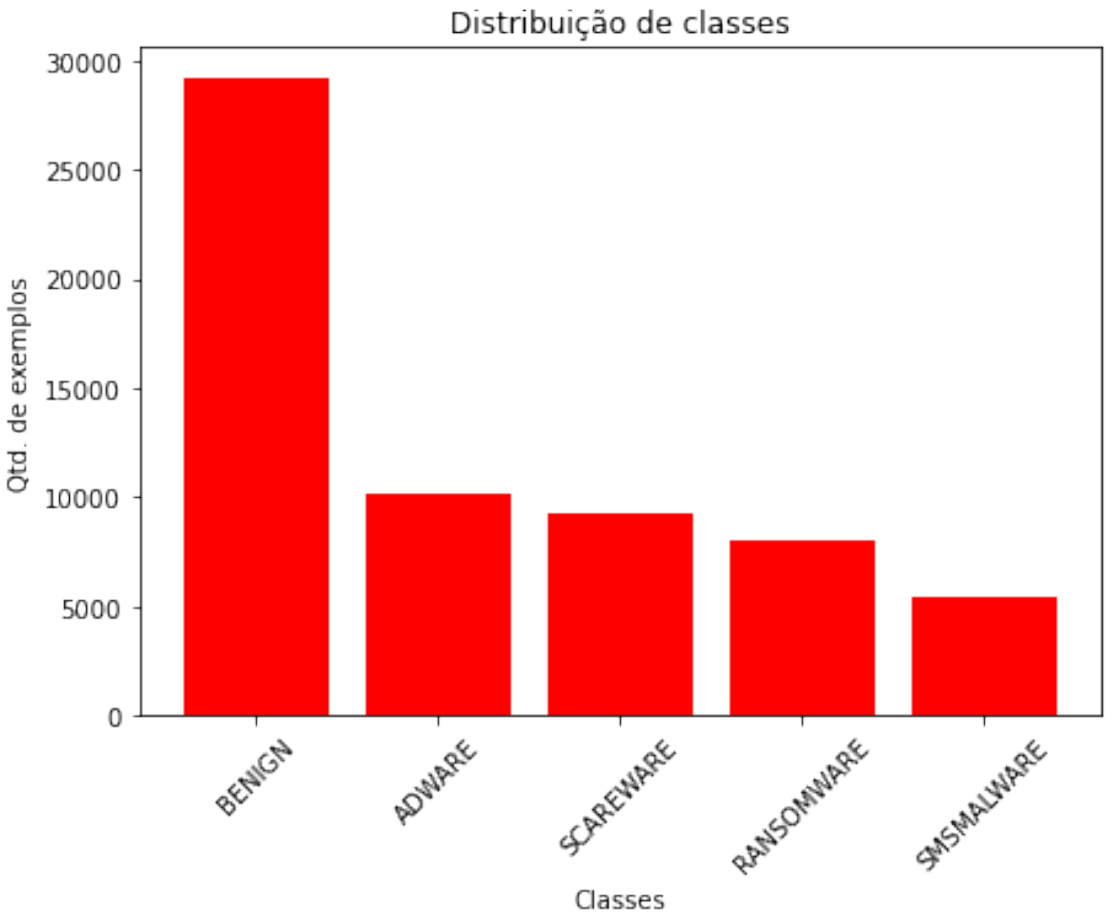


### 3.1.2 Distribuição das amostras de validação

[14]:
```
funcoes_uteis.plot_distribuicao_classes(df_validacao, 'Label')
```

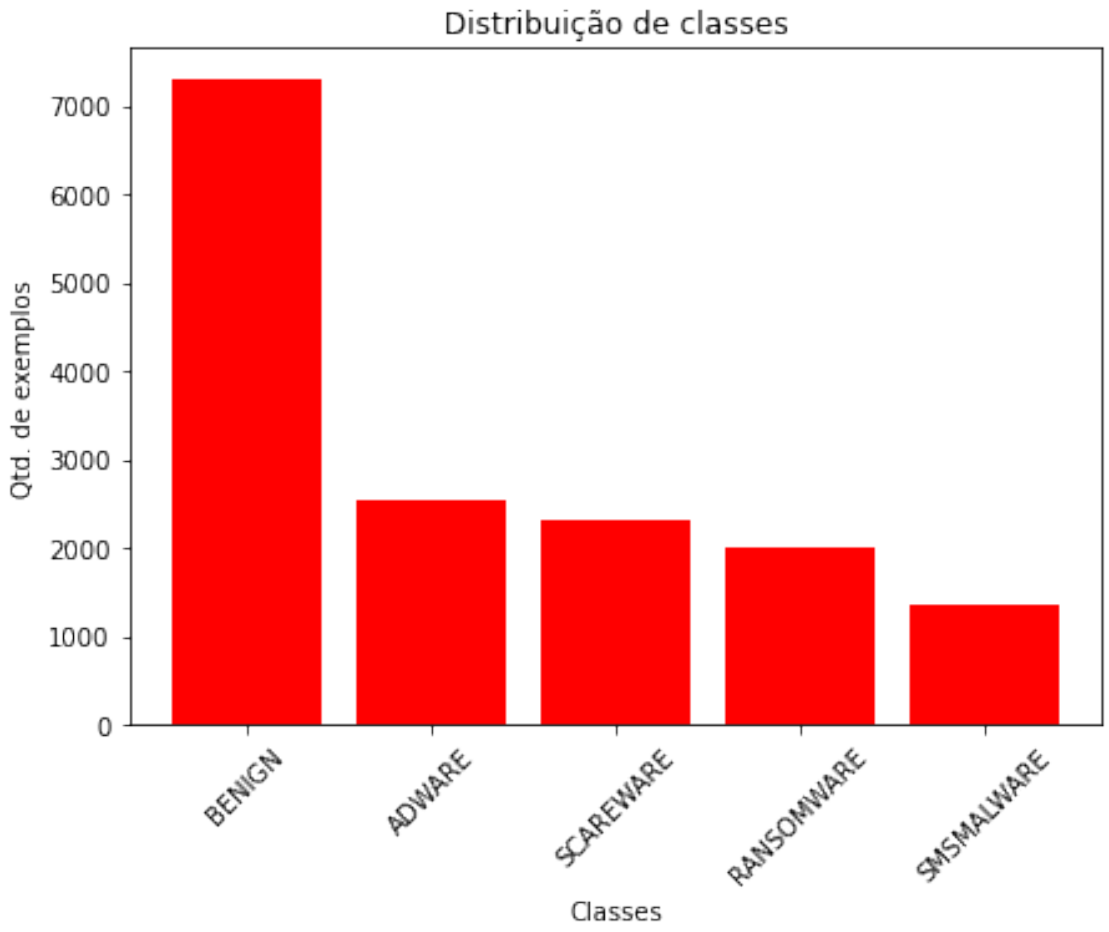


[144]:
```
# Separação para treinamento 80/20 sobre o df_treinamento
df_train, df_teste = train_test_split(df_treinamento, test_size=0.2,␣
 ↪shuffle=True, stratify=df_treinamento['Label'])
```

[16]:
```
funcoes_uteis.plot_distribuicao_classes(df_teste, 'Label')
```

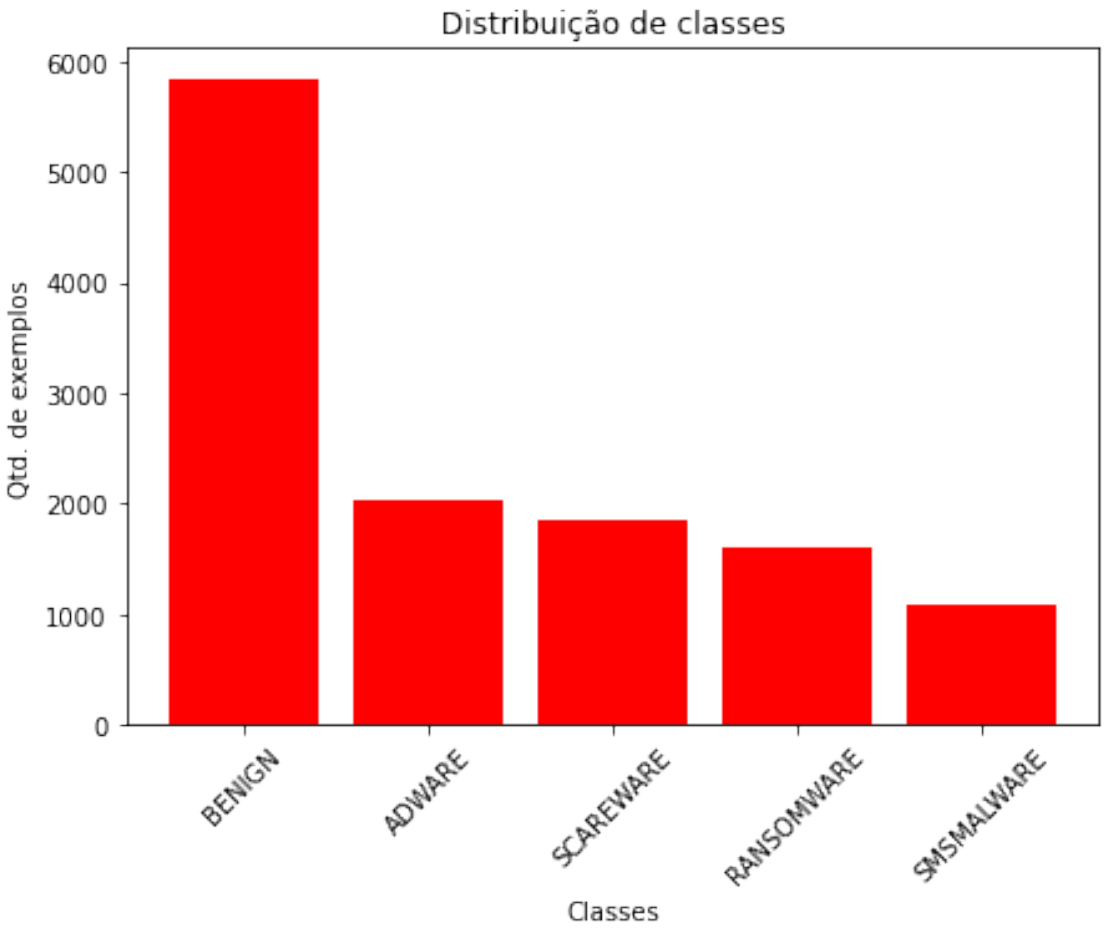


### 3.2 Normalização

- Muitos atributos do *dataset* selecionado possuem diferença de escala muito grande, como os atributos *'Flow Duration'* e *'Total Fwd Packets'*. Essa diferença de escala, dependendo do classificador utilizado, pode dar uma significância muito maior para o primeiro "Flow Duration", já que ele varia muito mais em escala.
- Para resolver este problema será realizada a normalização dos atributos que não representam valores categórigos. No *dataset* utilizado apenas os atributos *' Source Port'*, *' Destination Port'*, *' Protocol'*, *' Label'* e *'NOME_APP'* representam atributos categóricos, os demais atributos serão portanto normalizados.
- Para normalização será utilizado o min-max scaler do scikit learn. O *Min-max Scaling* reescala todas as características em um intervalo entre zero e um, utilizando a equação:

$$z_i = \frac{x_i - min(x)}{max(x) - min(x)}$$

em que: - $x_i$ é o valor da característica $x$ de um examplar $i$; - $min(x)$ é o menor valor da característica

$x$ no conjunto de treino; - $max(x)$ é o maior valor da característica $x$ no conjunto de treino.

[145]:
```
# Obtém colunas
colunas = list(df_train.columns)
# Colunas que devem ser removidas
colunas_remov = [' Source Port', ' Destination Port', ' Protocol', 'NOME_APP',␣
 ↪'Label']
# Remove colunas que NÃO serão normalizadas
for coluna in colunas_remov:
    colunas.remove(coluna)

# Inicializa o MinMax
scaler = MinMaxScaler(feature_range=(0,1))
# Treina MinMax somente as colunas selecionadas
scaler.fit(df_train[colunas])
# Transform as características
train_caract_norm = scaler.transform(df_train[colunas])
teste_caract_norm = scaler.transform(df_teste[colunas])
valid_caract_norm = scaler.transform(df_validacao[colunas])
treinamento_caract_norm = scaler.transform(df_treinamento[colunas])

# Cria os DataFrames normalizados
df_train_norm = pd.DataFrame(train_caract_norm, columns=colunas,index=df_train.
 ↪index)
df_teste_norm = pd.DataFrame(teste_caract_norm, columns=colunas,index=df_teste.
 ↪index)
df_validacao_norm = pd.DataFrame(valid_caract_norm,␣
 ↪columns=colunas,index=df_validacao.index)
df_treinamento_norm = pd.DataFrame(treinamento_caract_norm,␣
 ↪columns=colunas,index=df_treinamento.index)

# Concatena as colunas não normalizadas aos novos DataFrame e reorganiza as␣
 ↪colunas
df_train_norm =  pd.concat([df_train_norm, df_train[colunas_remov]], axis=1)
df_train_norm = df_train_norm[df_train.columns]

df_teste_norm =  pd.concat([df_teste_norm, df_teste[colunas_remov]], axis=1)
df_teste_norm = df_teste_norm[df_teste.columns]

df_validacao_norm =  pd.concat([df_validacao_norm,␣
 ↪df_validacao[colunas_remov]], axis=1)
df_validacao_norm = df_validacao_norm[df_validacao.columns]

df_treinamento_norm = pd.concat([df_treinamento_norm,␣
 ↪df_treinamento[colunas_remov]], axis=1)
df_treinamento_norm = df_treinamento_norm[df_treinamento.columns]
```

## 3.3 Treinamento *percentage split*

- Nesta etapa serão realizados treinamentos com a divisão dos dados em duas partes uma de 80% para treinamento e outra de 20%, essa divisão foi realizada sobre os 80% dos dados, como já visto nas etapas anteriores
- Inicialmente serão realizados os treinamentos variando alguns hiperparâmetros dos algoritmos para identificar os que proporcionam os melhores resultados, analisando para isso a acurácia de cada modelo gerado. Na sequência os melhores hiperparâmetros serão utilizados para um novo treinamento em que serão exibidos a matriz de confusão, Curva ROC, acurácia e erro do modelo.

### 3.3.1 Preparação dos dados para treinamento, normalizados e não normalizados

[146]:
```
# Remove a coluna NOME_APP
df_train_norm = df_train_norm.drop('NOME_APP', axis=1)
df_train = df_train.drop('NOME_APP', axis=1)

df_teste_norm = df_teste_norm.drop('NOME_APP', axis=1)
df_teste = df_teste.drop('NOME_APP', axis=1)
```

[147]:
```
# Dados de treinamento
X_train_norm = df_train_norm.iloc[:,0:-1].values
y_train_norm = df_train_norm.iloc[:,-1].values

X_train = df_train.iloc[:,0:-1].values
y_train = df_train.iloc[:,-1].values
```

[148]:
```
# Dados de teste
X_teste_norm = df_teste_norm.iloc[:,0:-1].values
y_teste_norm = df_teste_norm.iloc[:,-1].values

X_teste = df_teste.iloc[:,0:-1].values
y_teste = df_teste.iloc[:,-1].values
```

### 3.3.2 KNN (*K-nearest neighbors algorithm*)

- Neste algoritmo serão variados o parâmetro número de vizinhos (*n_neighbors*) de 3 até 100 para detectar o melhor parâmetro. As métricas de distância testadas serão a *euclidean* e *manhattan*

[111]:
```
numero_de_vizinhos = [3,5,7,9,11,13,15,25,45,70,100]
metricas_de_distancia = ['euclidean', 'manhattan']
```

[112]:
```
# Dados normalizados
acc = []
ks = []
metricas = []
for metrica in metricas_de_distancia:
```

```
    for k in numero_de_vizinhos:
        # Cria modelo
        clf_KNN = KNeighborsClassifier(n_neighbors=k, metric=metrica)
        # Treina modelo
        clf_KNN.fit(X_train_norm, y_train_norm)
        # Faz predição sobre os dados de teste
        y_pred = clf_KNN.predict(X_teste_norm)
        # Calcula a acurácia
        acuracia = accuracy_score(y_teste_norm, y_pred)
        acc.append(acuracia)
        ks.append(k)
        metricas.append(metrica)

# Exibe os resultados
funcoes_uteis.plot_resultados(ks, 'k',
                              acc, 'acc', metricas,
                              'Definição de parâmetros do KNN\nDados␣
↪normalizados')
```

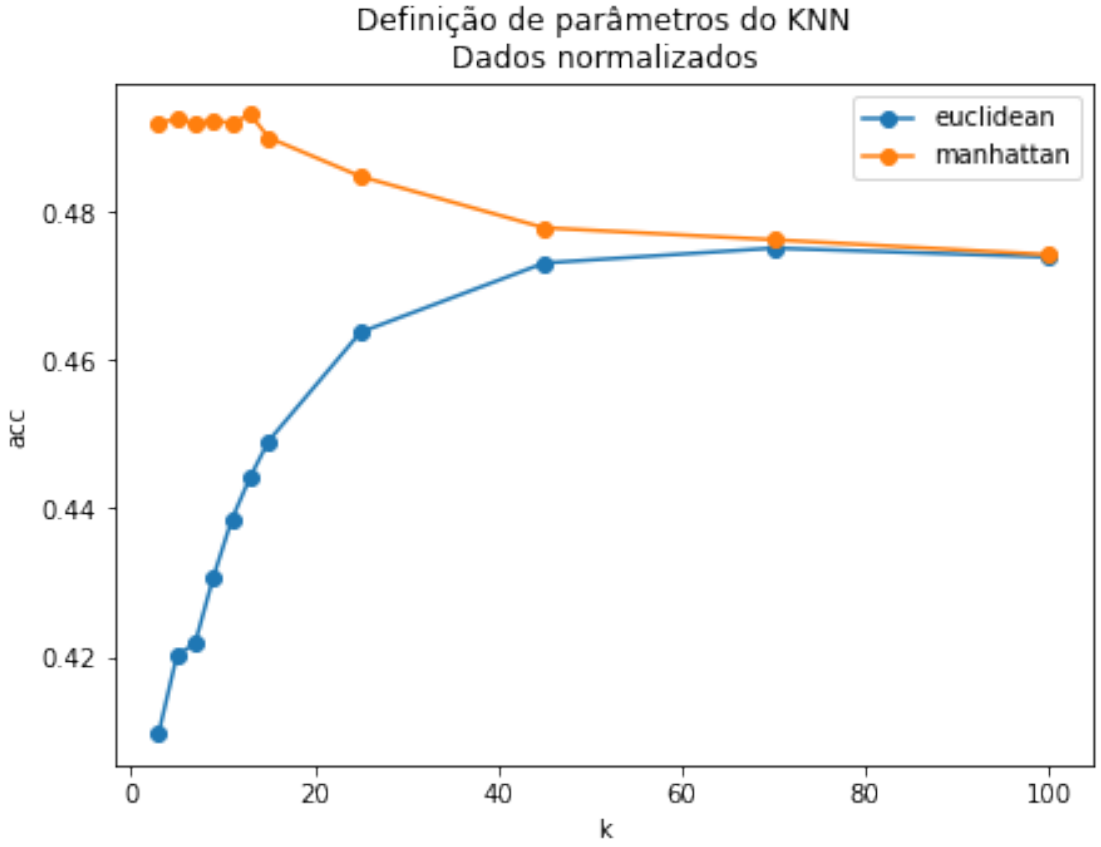

[113]:
```
# Dados não normalizados
acc = []
ks = []
metricas = []
for metrica in metricas_de_distancia:
    for k in numero_de_vizinhos:
        # Cria modelo
        clf_KNN = KNeighborsClassifier(n_neighbors=k, metric=metrica)
        # Treina modelo
        clf_KNN.fit(X_train, y_train)
        # Faz predição sobre os dados de teste
        y_pred = clf_KNN.predict(X_teste)
        # Calcula a acurácia
        acuracia = accuracy_score(y_teste, y_pred)
        acc.append(acuracia)
        ks.append(k)
        metricas.append(metrica)

# Exibe os resultados
funcoes_uteis.plot_resultados(ks, 'k',
                    acc, 'acc', metricas,
                    'Definição de parâmetros do KNN\nDados não normalizados')
```

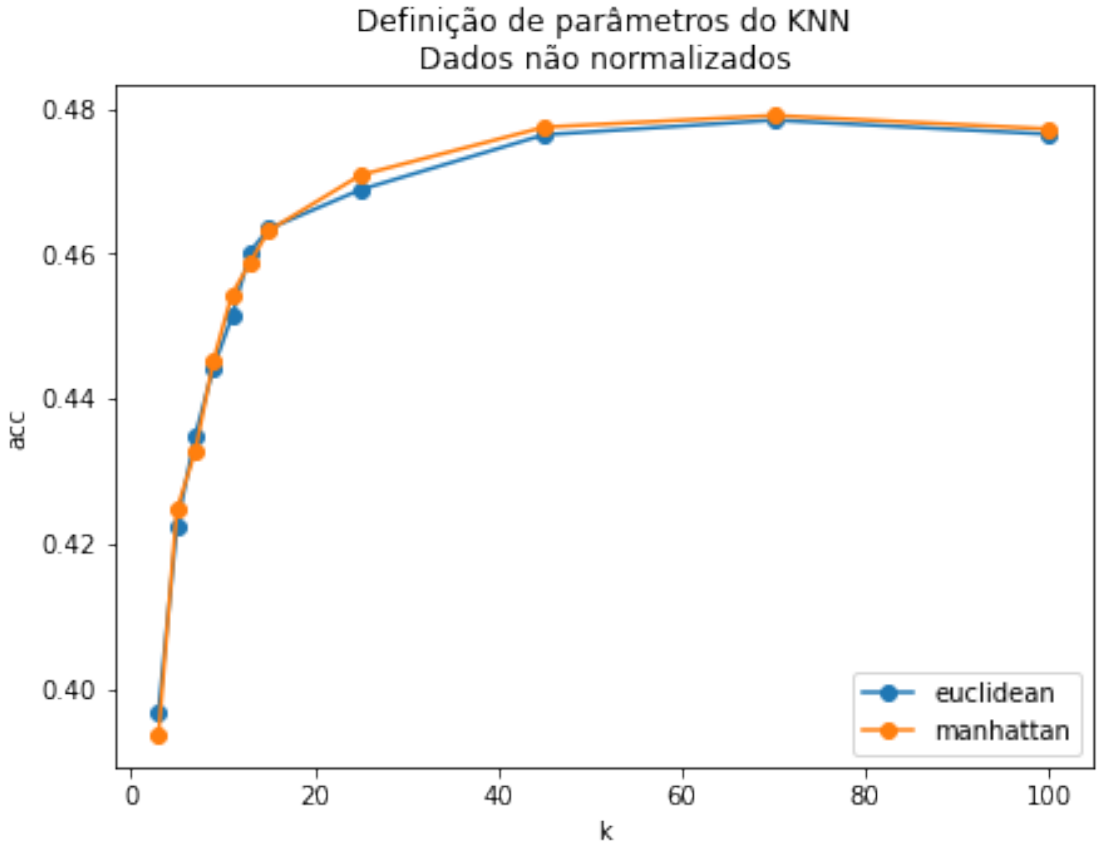

**Discussão**

- No KNN a utilização dos **dados normalizados** chegaram a resultados sensivelmente melhores, pelos experimentos o melhor valor de k foi 13 e a melhor métrica de distância foi a *manhattan*. Portanto o experimento para o KNN será executado com os seguintes hiperparâmetros e dados:
  - Dados: Normalizados
  - Número de vizinhos (k): 13
  - Métrica de distância: *manhattan*

[87]:
```
clf_KNN = KNeighborsClassifier(n_neighbors=13, metric='manhattan')
# Treina modelo
clf_KNN.fit(X_train_norm, y_train_norm)
# Faz predição sobre os dados de teste
y_pred = clf_KNN.predict(X_teste_norm)
# Imprime resultados
print(classification_report(y_pred, y_teste_norm, zero_division=True))
```

```
              precision    recall  f1-score   support

      ADWARE       0.19      0.46      0.27       857
      BENIGN       0.94      0.50      0.66     10821
  RANSOMWARE       0.07      0.35      0.12       339
   SCAREWARE       0.04      0.25      0.08       322
  SMSMALWARE       0.02      0.37      0.04        68

    accuracy                           0.49     12407
   macro avg       0.25      0.39      0.23     12407
weighted avg       0.83      0.49      0.60     12407
```

[88]:
```
# Calcula erro (1-accuracy)
accuracy = accuracy_score(y_teste, y_pred)
erro = 1 - accuracy
print('Acurácia: {:.3f}'.format(accuracy))
print('Erro: {:.3f}'.format(erro))
```

```
Acurácia: 0.490
Erro: 0.510
```

[89]:
```
# Guarda o modelo gerado
dic_melhores_modelos['split_perc_knn'] = []
dic_melhores_modelos['split_perc_knn'] = []

dic_melhores_modelos['split_perc_knn'].append(clf_KNN)
```

```
dic_melhores_modelos['split_perc_knn'].append(accuracy)
```

[90]:
```
# Exibe a matriz de confusão
funcoes_uteis.plot_confusion_matrix(y_teste, y_pred,
                                    set(y_teste),
                                    'Matriz de Confusão KNN')
```

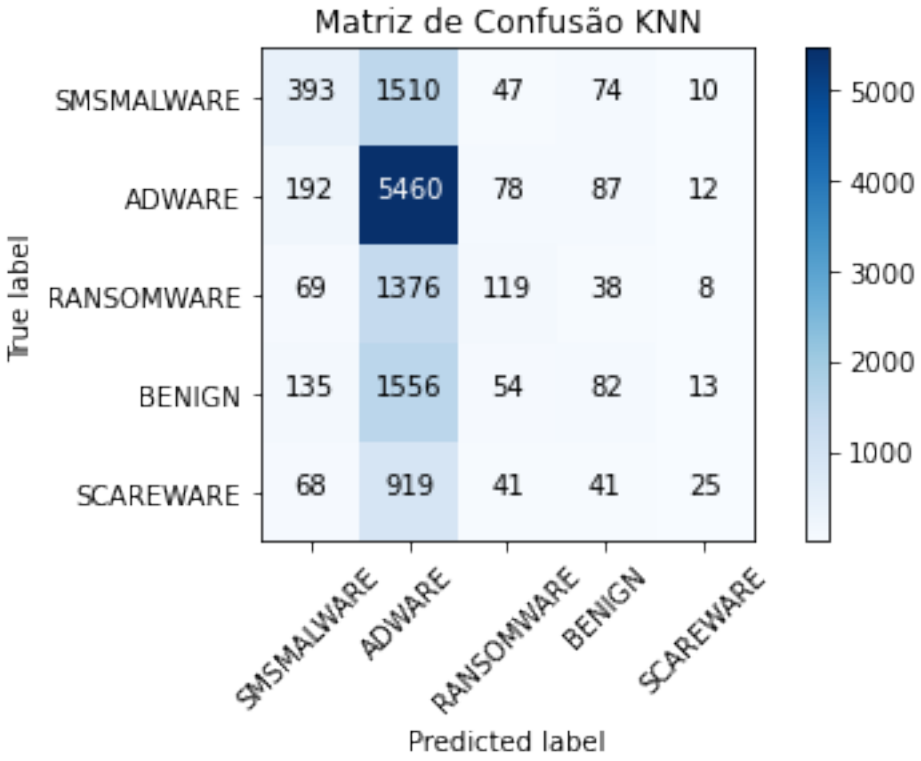


[119]:
```
# Exibe curva ROC
funcoes_uteis.plot_roc_curve(clf_KNN, X_train, y_train, X_teste, y_teste)
```

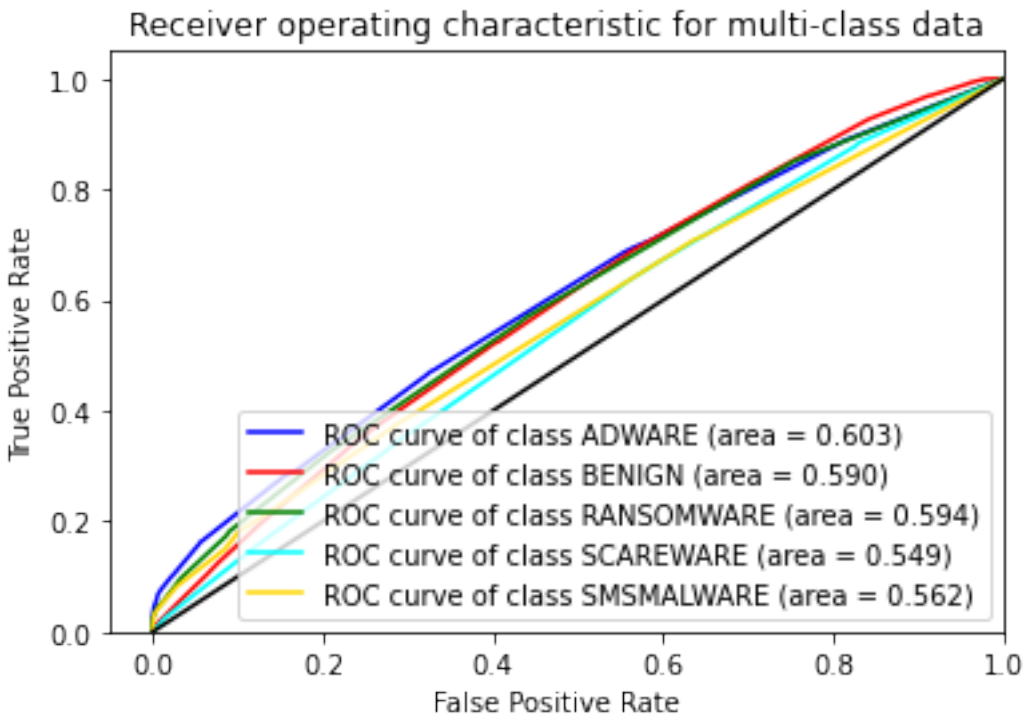


### 3.3.3 *Random Forest*

- Neste algoritmo foi feita a variação do hiperparâmetro número estimadores (*n_estimators*) de 5 até 100 para detectar o melhor.

[121]:
```
numero_de_estimadores = [5,10,20,30,40,50,75,100]
```

[122]:
```
# Dados normalizados
acc = []
num_estimadores = []
divisao = []
for n_estimators in numero_de_estimadores:
    # Cria modelo
    clf_rf = RandomForestClassifier(n_estimators=n_estimators, random_state=0)
    # Treina modelo
    clf_rf.fit(X_train_norm, y_train_norm)
    # Faz predição sobre os dados de teste
    y_pred = clf_rf.predict(X_teste_norm)
    # Calcula a acurácia
    acuracia = accuracy_score(y_teste_norm, y_pred)
    acc.append(acuracia)
    num_estimadores.append(n_estimators)
    divisao.append('RandomForest')
```

```
# Exibe os resultados
funcoes_uteis.plot_resultados(num_estimadores, 'Núm. de Estimadores',
                              acc, 'acc', divisao,
                              'Definição de parâmetros do Random Forest\nDados␣
 ↪normalizados')
```

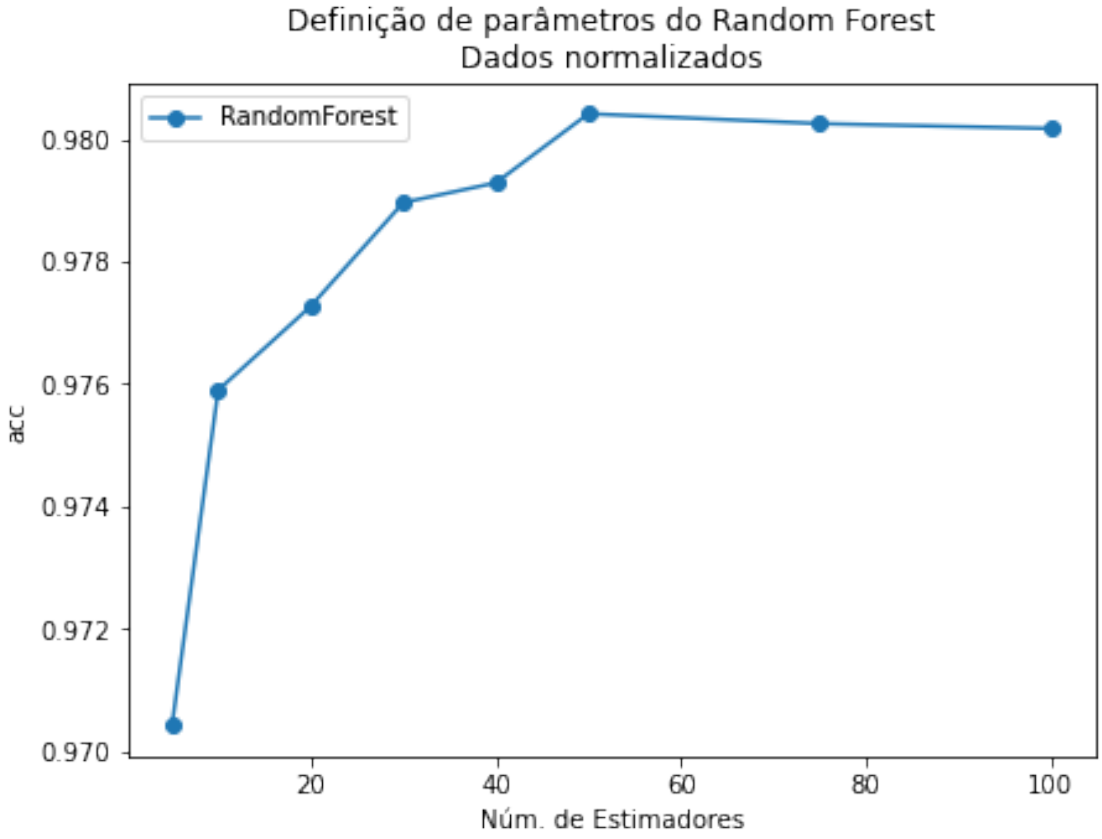


[123]:
```
# Dados não normalizados
acc = []
num_estimadores = []
divisao = []
for n_estimators in numero_de_estimadores:
    # Cria modelo
    clf_rf = RandomForestClassifier(n_estimators=n_estimators, random_state=0)
    # Treina modelo
    clf_rf.fit(X_train, y_train)
    # Faz predição sobre os dados de teste
    y_pred = clf_rf.predict(X_teste)
    # Calcula a acurácia
    acuracia = accuracy_score(y_teste, y_pred)
    acc.append(acuracia)
```

```
    num_estimadores.append(n_estimators)
    divisao.append('RandomForest')

# Exibe os resultados
funcoes_uteis.plot_resultados(num_estimadores, 'Núm. de Estimadores',
                              acc, 'acc', divisao,
                              'Definição de parâmetros do Random Forest\nDados␣
 ↪normalizados')
```

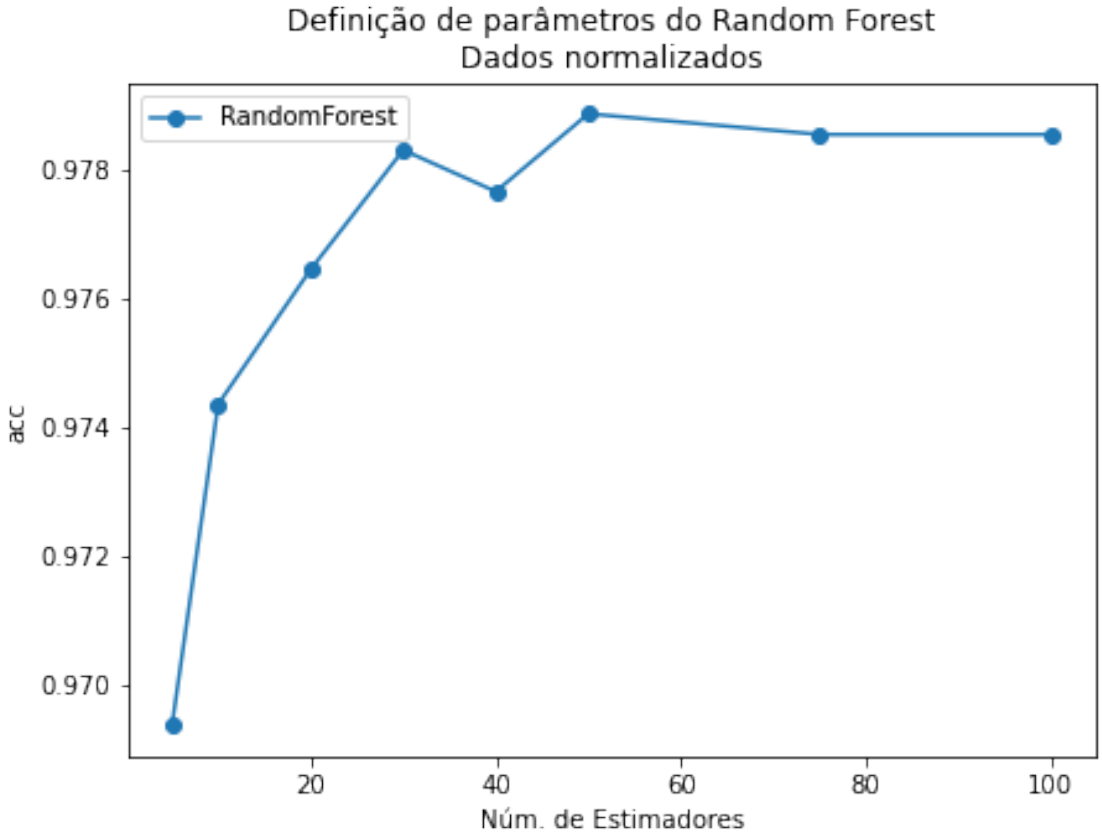


**Discussão**

- Para o *RandomForest* a utilização dos **dados normalizados** chegaram a resultados sensivelmente melhores, pelos experimentos a melhor quantidade de estimadores foi 50. Portanto o experimento para o *RandomForest* será executado com os seguintes hiperparâmetros e dados:
  - Dados: Normalizados
  - Número de estimadores: 50

[91]:
```
# Cria modelo
clf_rf = RandomForestClassifier(n_estimators = 50, random_state=0)
# Treina modelo
```

```
clf_rf.fit(X_train_norm, y_train_norm)
# Faz predição sobre os dados de teste
y_pred = clf_rf.predict(X_teste_norm)
# Imprime resultados
print(classification_report(y_pred, y_teste_norm, zero_division=True))
```

```
              precision    recall  f1-score   support

      ADWARE       0.97      0.99      0.98      2000
      BENIGN       1.00      0.97      0.98      5970
  RANSOMWARE       0.98      1.00      0.99      1581
   SCAREWARE       0.96      0.99      0.97      1775
  SMSMALWARE       0.96      0.97      0.96      1081

    accuracy                           0.98     12407
   macro avg       0.97      0.98      0.98     12407
weighted avg       0.98      0.98      0.98     12407
```

[92]:
```
# Calcula erro (1-accuracy)
accuracy = accuracy_score(y_teste_norm, y_pred)
erro = 1 - accuracy
print('Acurácia: {:.3f}'.format(accuracy))
print('Erro: {:.3f}'.format(erro))
```

```
Acurácia: 0.981
Erro: 0.019
```

[93]:
```
# Guarda o modelo gerado
dic_melhores_modelos['split_perc_rf'] = []
dic_melhores_modelos['split_perc_rf'] = []

dic_melhores_modelos['split_perc_rf'].append(clf_rf)
dic_melhores_modelos['split_perc_rf'].append(accuracy)
```

[94]:
```
# Exibe a matriz de confusão
funcoes_uteis.plot_confusion_matrix(y_teste_norm, y_pred,
                                    set(y_teste_norm),
                                    'Matriz de Confusão RF')
```

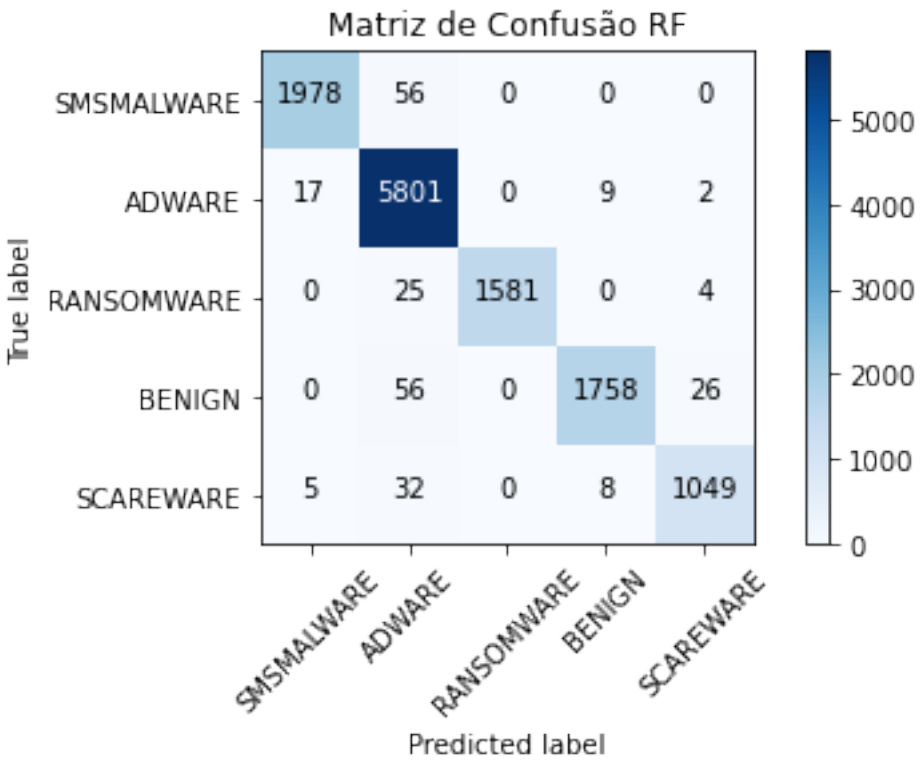


[127]:
```
# Exibe curva ROC
funcoes_uteis.plot_roc_curve(clf_rf, X_train_norm, y_train_norm,
                             X_teste_norm, y_teste_norm)
```

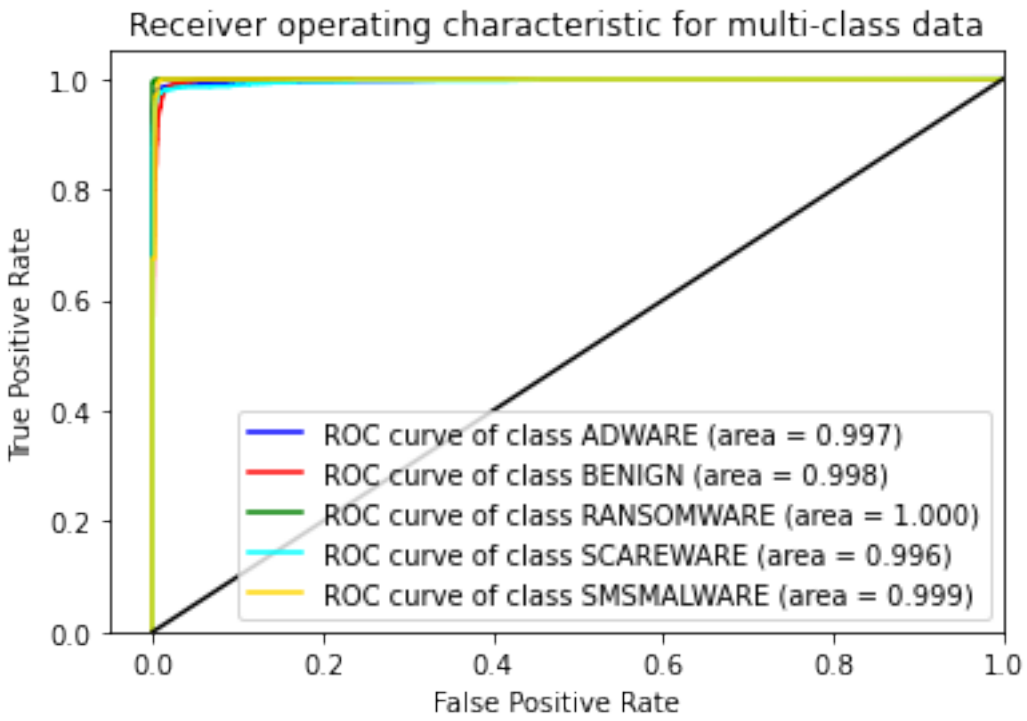


### 3.3.4 MLP (*Multi-layer Perceptron*)

- Neste algoritmo serão variados o hiperparametro de número de camadas ocultas x número de neurônios, (*hidden_layer_sizes*) variando as camadas 1 até 2 e número de neurônios de 50 até 100 para detectar o melhor parâmetro.

[129]:
```
tamanhos_camada_oculta = [(50,),(100,),(150,),(50,50),(100,100),
                          (150,150)]
```

[144]:
```
# Dados normalizados
acc = []
num_camadas = []
divisao = []
for camadas_ocultas in tamanhos_camada_oculta:
    # Cria modelo
    clf_mlp =  MLPClassifier(hidden_layer_sizes=camadas_ocultas, random_state=1)
    # Treina modelo
    clf_mlp.fit(X_train_norm, y_train_norm)
    # Faz predição sobre os dados de teste
    y_pred = clf_mlp.predict(X_teste_norm)
    # Calcula a acurácia
    acuracia = accuracy_score(y_teste_norm, y_pred)
    acc.append(acuracia)
    num_camadas.append(str(camadas_ocultas))
```

```
    divisao.append('MLP')

# Exibe os resultados
funcoes_uteis.plot_resultados(num_camadas, 'Camadas ocultas',
                              acc, 'acc', divisao,
                              'Definição de hiperparâmetros do MLP\nDados␣
 ↪normalizados', figsize=(7,5))
```

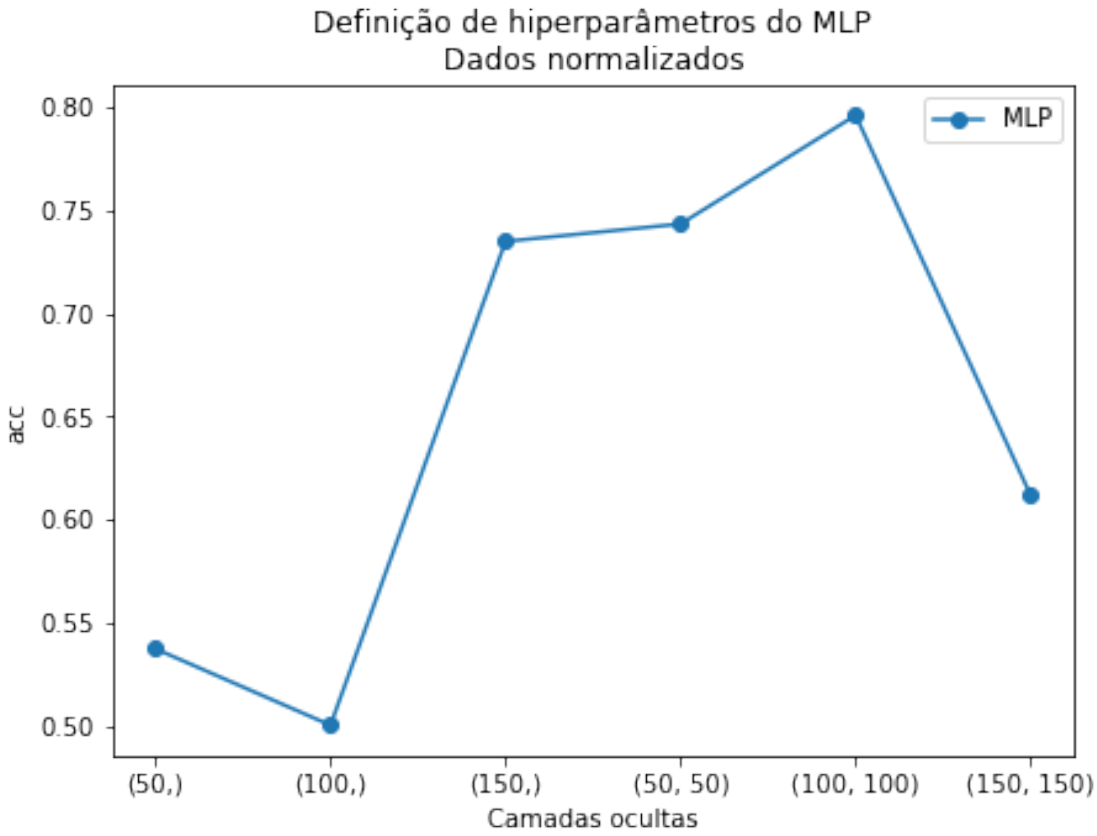


[133]:
```
# Dados não normalizados
acc = []
num_camadas = []
divisao = []
for camadas_ocultas in tamanhos_camada_oculta:
    # Cria modelo
    clf_mlp =  MLPClassifier(hidden_layer_sizes=camadas_ocultas, random_state=1)
    # Treina modelo
    clf_mlp.fit(X_train, y_train)
    # Faz predição sobre os dados de teste
    y_pred = clf_mlp.predict(X_teste)
    # Calcula a acurácia
```

```
    acuracia = accuracy_score(y_teste, y_pred)
    acc.append(acuracia)
    num_camadas.append(str(camadas_ocultas))
    divisao.append('MLP')

# Exibe os resultados
funcoes_uteis.plot_resultados(num_camadas, 'Camadas ocultas',
                              acc, 'acc', divisao,
                              'Definição de hiperparâmetros do MLP\nDados não␣
 ↪normalizados', figsize=(7,5))
```

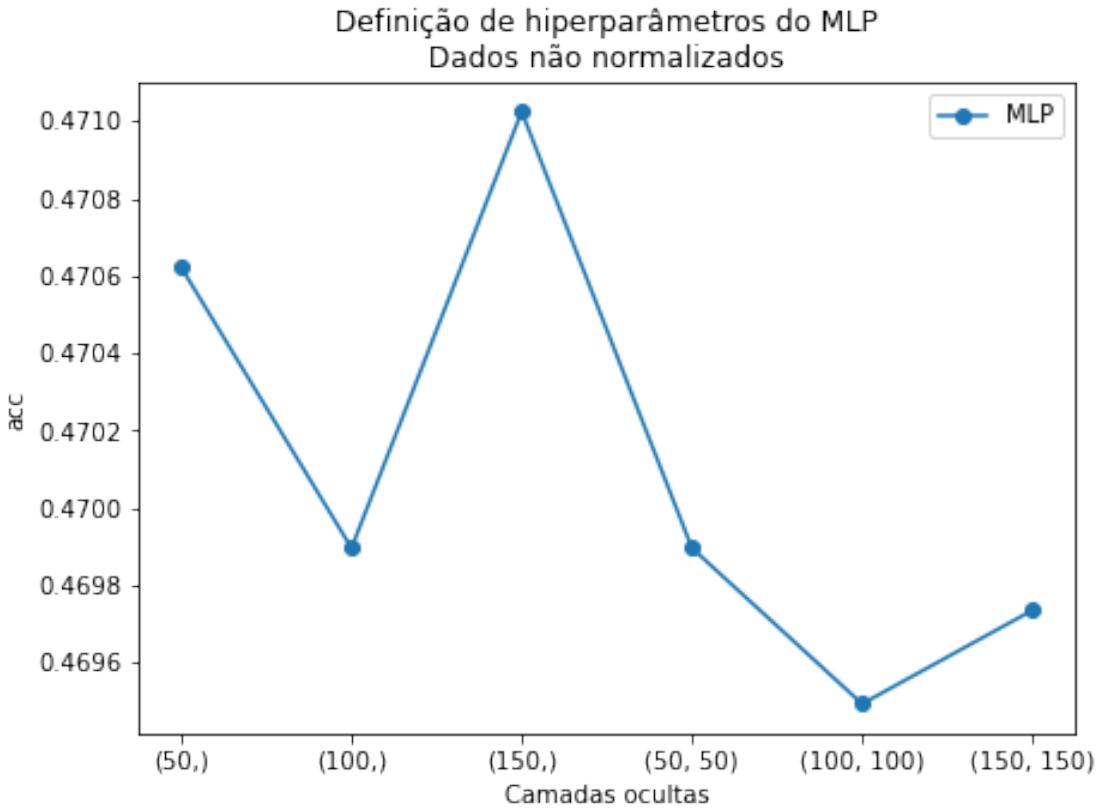


**Discussão**

- Para o MLP a utilização dos **dados normalizados** chegaram a resultados melhores, pelos experimentos o melhor configuração das camadas ocultas é (100,100). Portanto o experimento para o *MLP* será executado com os seguintes hiperparâmetros e dados:
  - Dados: Normalizados
  - Configuração de camadas ocultas: (100,100)

[149]:
```
# Cria modelo
clf_mlp = MLPClassifier(hidden_layer_sizes=(100,100), random_state=1)
```

```
# Treina modelo
clf_mlp.fit(X_train_norm, y_train_norm)
# Faz predição sobre os dados de teste
y_pred = clf_mlp.predict(X_teste_norm)
# Imprime resultados
print(classification_report(y_pred, y_teste, zero_division=True))
```

```
              precision    recall  f1-score   support

      ADWARE       0.83      0.78      0.81      2144
      BENIGN       0.90      0.80      0.85      6509
  RANSOMWARE       0.83      0.92      0.87      1455
   SCAREWARE       0.72      0.84      0.78      1586
  SMSMALWARE       0.62      0.94      0.74       713

    accuracy                           0.83     12407
   macro avg       0.78      0.86      0.81     12407
weighted avg       0.84      0.83      0.83     12407
```

[150]:
```
# Calcula erro (1-accuracy)
accuracy = accuracy_score(y_teste_norm, y_pred)
erro = 1 - accuracy
print('Acurácia: {:.3f}'.format(accuracy))
print('Erro: {:.3f}'.format(erro))
```

```
Acurácia: 0.827
Erro: 0.173
```

[151]:
```
# Guarda o modelo gerado
dic_melhores_modelos['split_perc_mlp'] = []
dic_melhores_modelos['split_perc_mlp'] = []

dic_melhores_modelos['split_perc_mlp'].append(clf_mlp)
dic_melhores_modelos['split_perc_mlp'].append(accuracy)
```

[152]:
```
# Exibe a matriz de confusão
funcoes_uteis.plot_confusion_matrix(y_teste_norm, y_pred,
                                    set(y_teste_norm),
                                    'Matriz de Confusão RF')
```

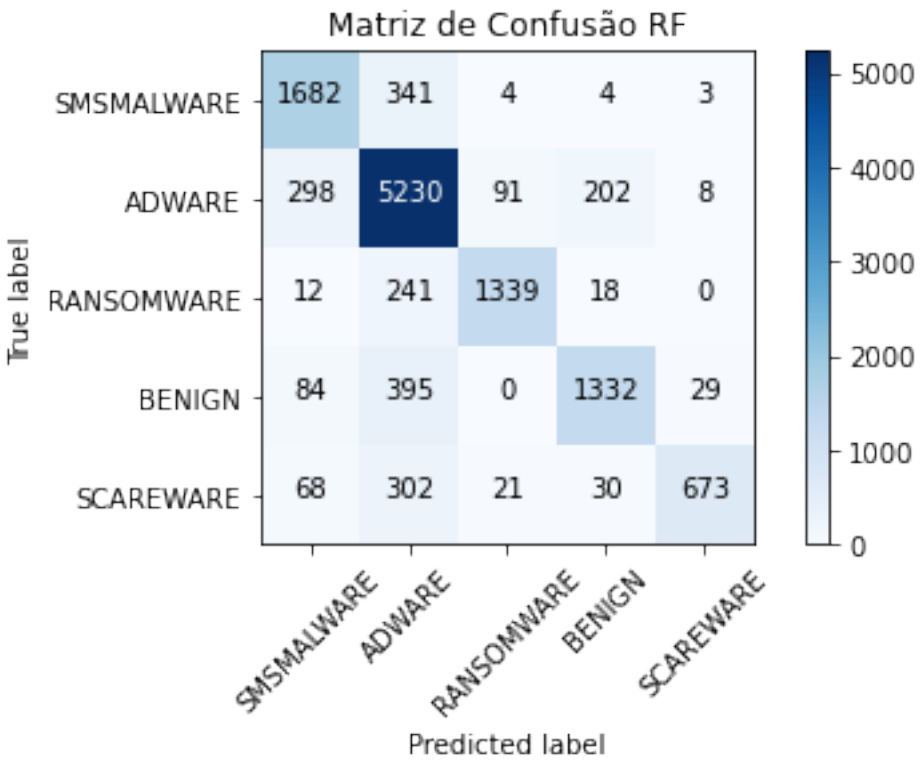


[153]:
```
# Exibe curva ROC
funcoes_uteis.plot_roc_curve(clf_mlp, X_train_norm, y_train_norm,
                             X_teste_norm, y_teste_norm)
```

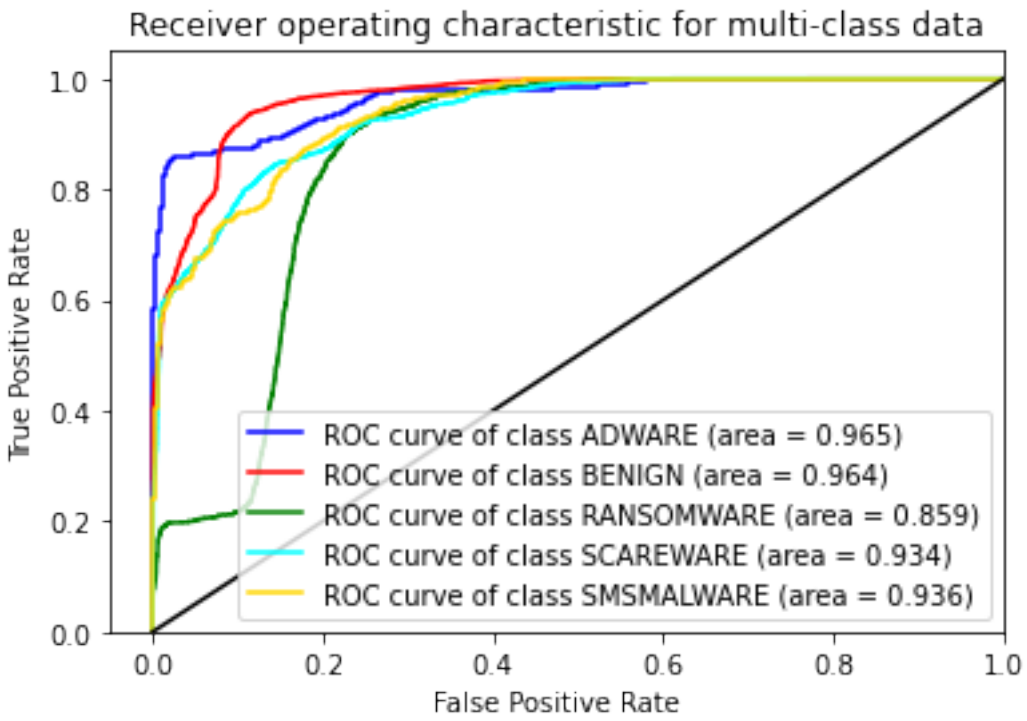


### 3.3.5 Comparação de Resultados e discussão

- É possível observar pelos experimentos anteriores e pelo gráfico abaixo que o KNN não consegue separar bem as classes. Isto pode ser observando tanto na matriz de confusão quanto pela curva ROC, uma vez que as linhas se aproximam muito do meio do gráfico. O *Random Forest* obteve os melhores resultados para predição de todas as classes, com índice muito baixo de falsos positivos, conforme pode ser visto pela curva ROC do algoritmo. O MLP consegue prever razoavelmente bem algumas classes, entretanto tem dificuldades para prever SMSMALWARE e SCAREWARE.
- Entre todos os modelos testados até este ponto, o *Random Forest* é o melhor modelo.

[162]:
```
classsificador_split_test = ['KNN', 'RF', 'MLP','KNN', 'RF', 'MLP',]
acuracias_split_test = [0.490,0.981,0.827,1-0.490,1-0.981,1-0.827]
divisao_split_test = ['acc','acc','acc','erro','erro','erro']

# Exibe os resultados
funcoes_uteis.plot_resultados(classsificador_split_test, 'Classificador',
                              acuracias_split_test, 'acc', divisao_split_test,
                              'Resultados dos classificadores', figsize=(7,5))
```

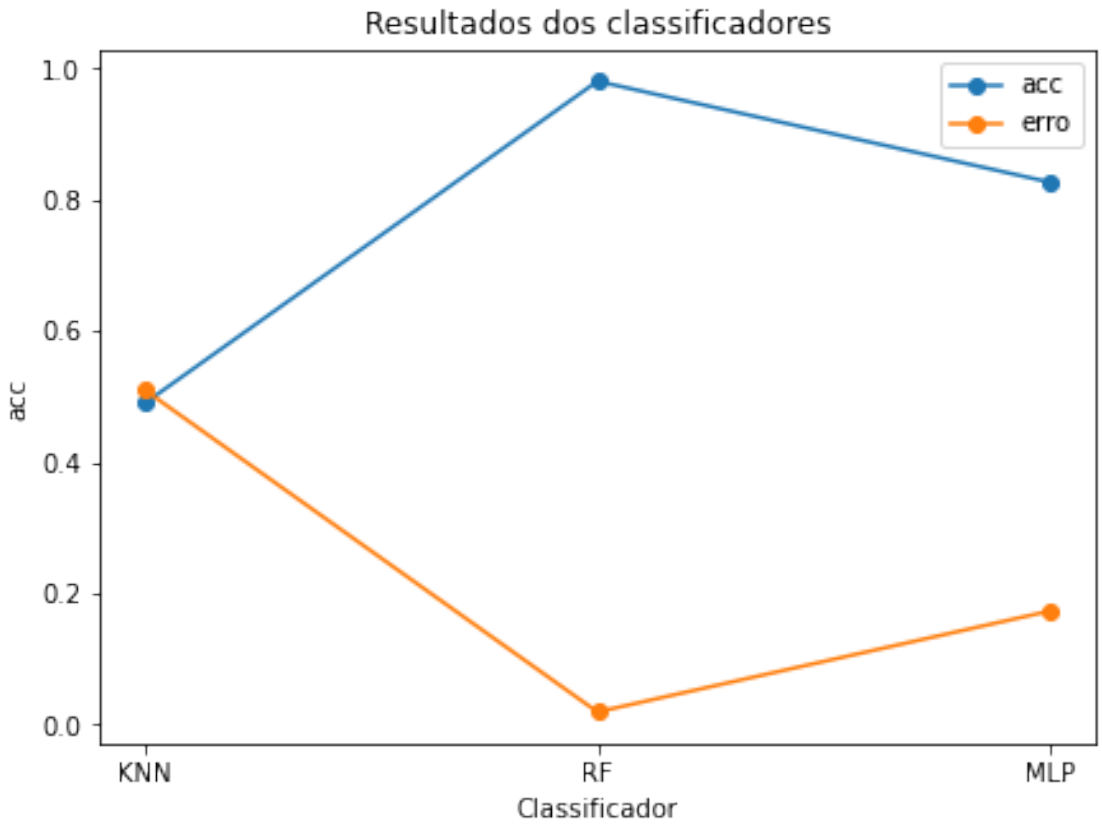


### 3.4 Treinamento e teste com validação cruzada

- Nesta etapa serão realizados treinamentos e teste com validação cruzada em 5 partes (*folds*). Para o treinamento e teste serão utilizados os 80% dos dados separados anteriormente.
- Os treinamentos serão realizados considerando os melhores hiperparâmentros encontrados anteriormente para os algoritmos. Para cada etapa do treinamento será exibido a matriz de confusão, Curva ROC, acurácia e erro do modelo.

#### 3.4.1 Preparação dos dados para treinamento, normalizados e não normalizados

[19]:
```
# Remove a coluna NOME_APP
df_treinamento_norm = df_treinamento_norm.drop('NOME_APP', axis=1)
df_treinamento = df_treinamento.drop('NOME_APP', axis=1)
```

[20]:
```
# Dados totais de treinamento
X_treinamento_norm = df_treinamento_norm.iloc[:,0:-1].values
y_treinamento_norm = df_treinamento_norm.iloc[:,-1].values

X_treinamento = df_treinamento.iloc[:,0:-1].values
y_treinamento = df_treinamento.iloc[:,-1].values
```

### 3.4.2 KNN (*K-nearest neighbors algorithm*)

- Neste algoritmo utilizados serão os mesmos hiperparametros da etapa *percentage split*. Portanto o experimento para o KNN será executado com os seguintes hiperparâmetros e dados:
  - Dados: Normalizados
  - Número de vizinhos (k): 13
  - Métrica de distância: *manhattan*

[21]:
```
clf_kNN = KNeighborsClassifier(n_neighbors=13, metric='manhattan')

scores, models, folds = funcoes_uteis.k_fold_train(clf_kNN,␣
↪df_treinamento_norm, clf_name='KNN')
```

```
Acurácia: 0.494
Erro: 0.506
```

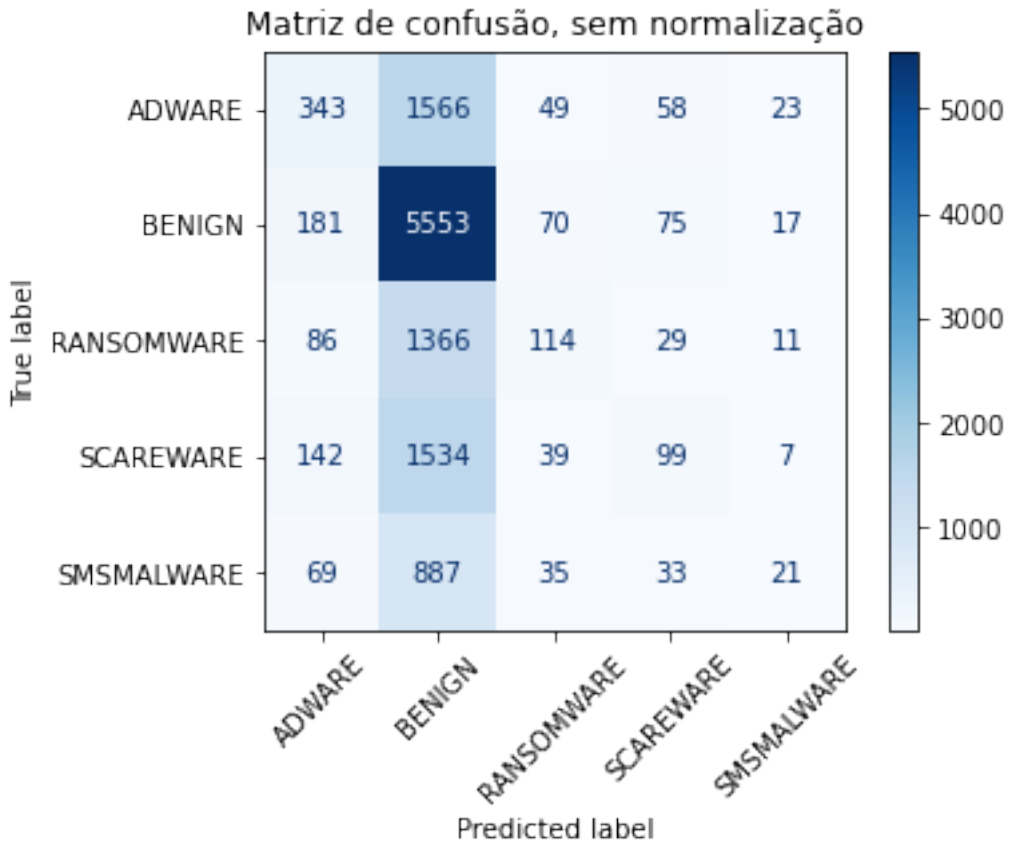

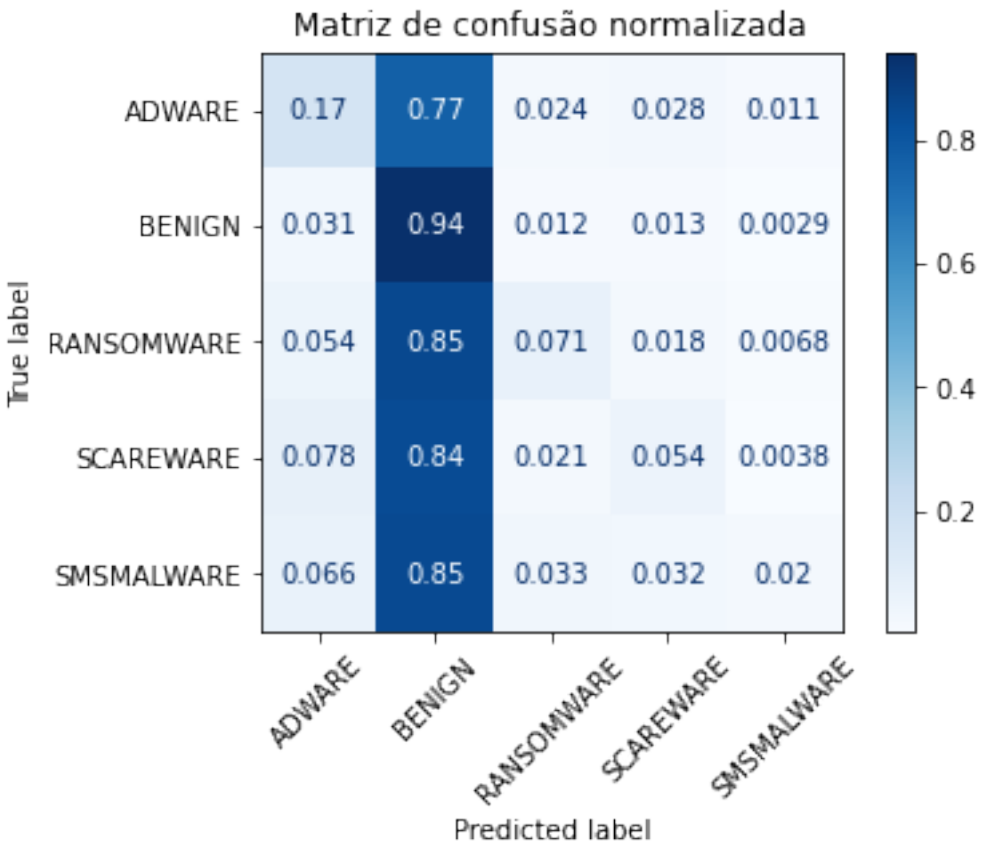
Matriz de confusão normalizada
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
True label
0.17 0.77 0.024 0.028 0.011
0.031 0.94 0.012 0.013 0.0029
0.054 0.85 0.071 0.018 0.0068
0.078 0.84 0.021 0.054 0.0038
0.066 0.85 0.033 0.032 0.02
0.8
0.6
0.4
0.2
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
Predicted label

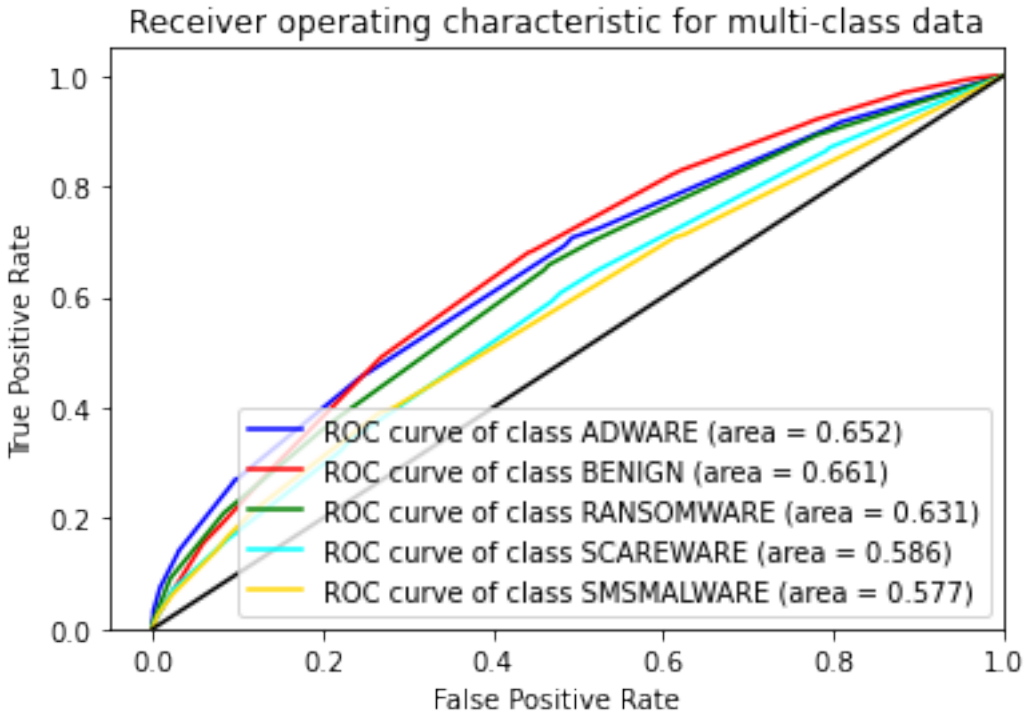
Receiver operating characteristic for multi-class data
True Positive Rate
False Positive Rate
0.0
0.2
0.4
0.6
0.8
1.0
ROC curve of class ADWARE (area = 0.652)
ROC curve of class BENIGN (area = 0.661)
ROC curve of class RANSOMWARE (area = 0.631)
ROC curve of class SCAREWARE (area = 0.586)
ROC curve of class SMSMALWARE (area = 0.577)

```
Acurácia: 0.491
Erro: 0.509
```

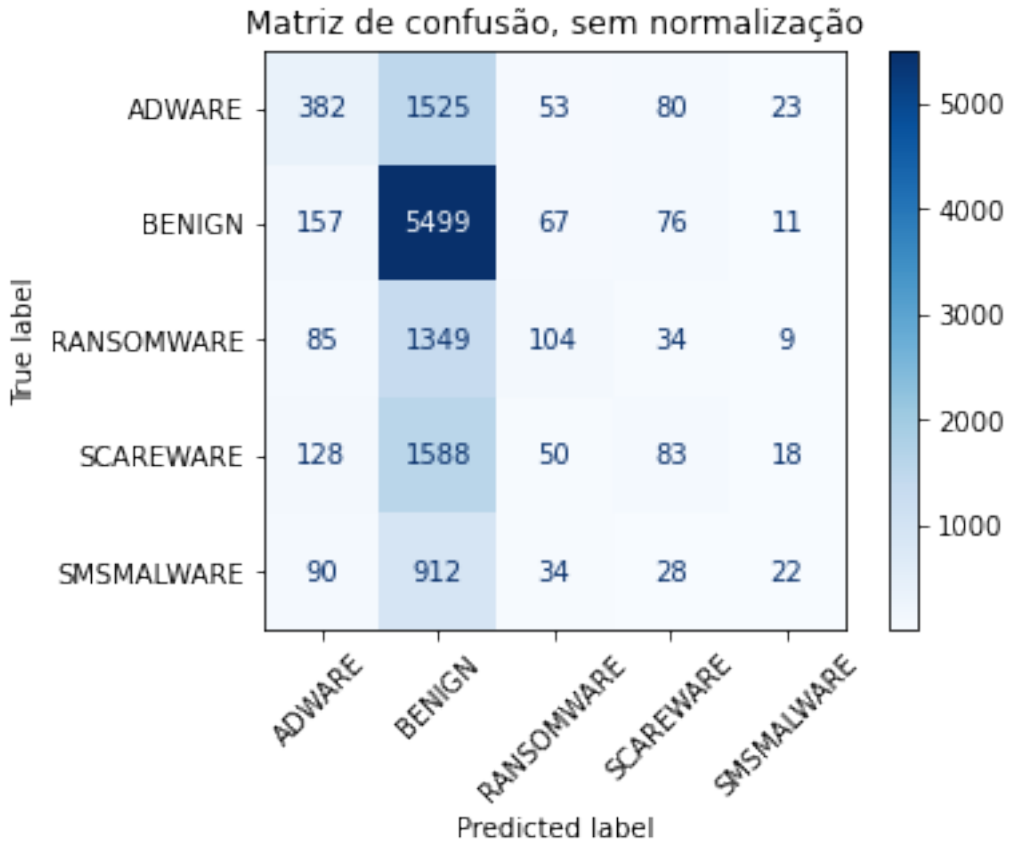

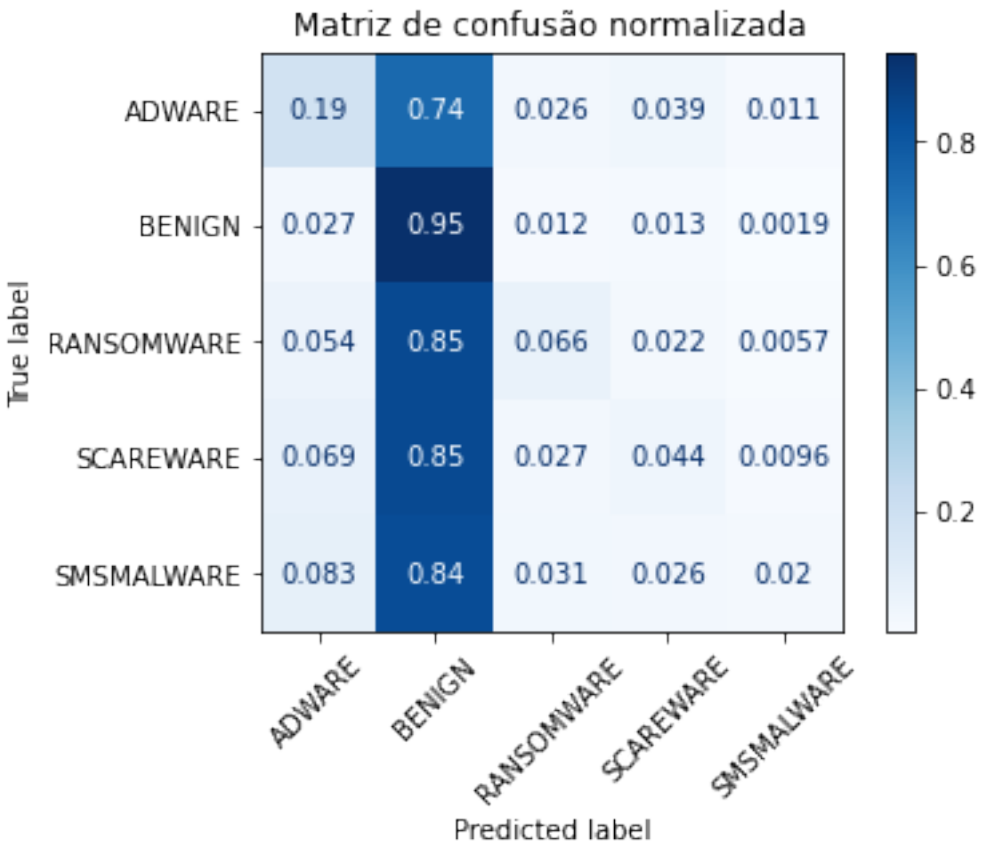
Matriz de confusão normalizada
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
0.19 0.74 0.026 0.039 0.011
0.027 0.95 0.012 0.013 0.0019
0.054 0.85 0.066 0.022 0.0057
0.069 0.85 0.027 0.044 0.0096
0.083 0.84 0.031 0.026 0.02
True label
Predicted label
0.8
0.6
0.4
0.2

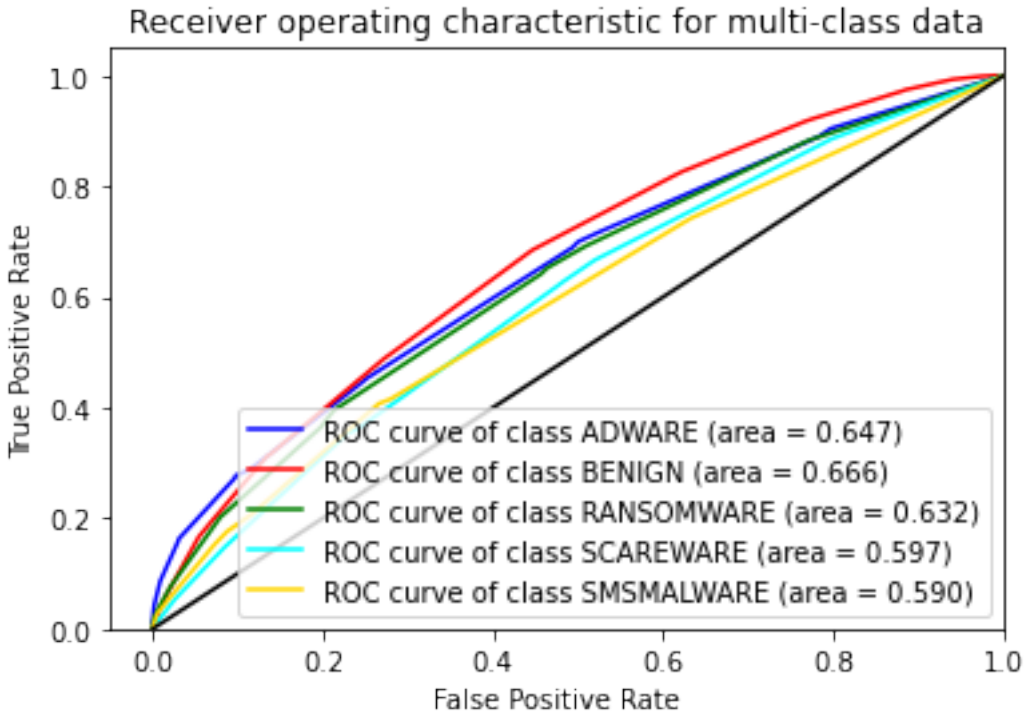
Receiver operating characteristic for multi-class data
True Positive Rate
False Positive Rate
0.0
0.2
0.4
0.6
0.8
1.0
ROC curve of class ADWARE (area = 0.647)
ROC curve of class BENIGN (area = 0.666)
ROC curve of class RANSOMWARE (area = 0.632)
ROC curve of class SCAREWARE (area = 0.597)
ROC curve of class SMSMALWARE (area = 0.590)

Acurácia: 0.489
Erro: 0.511

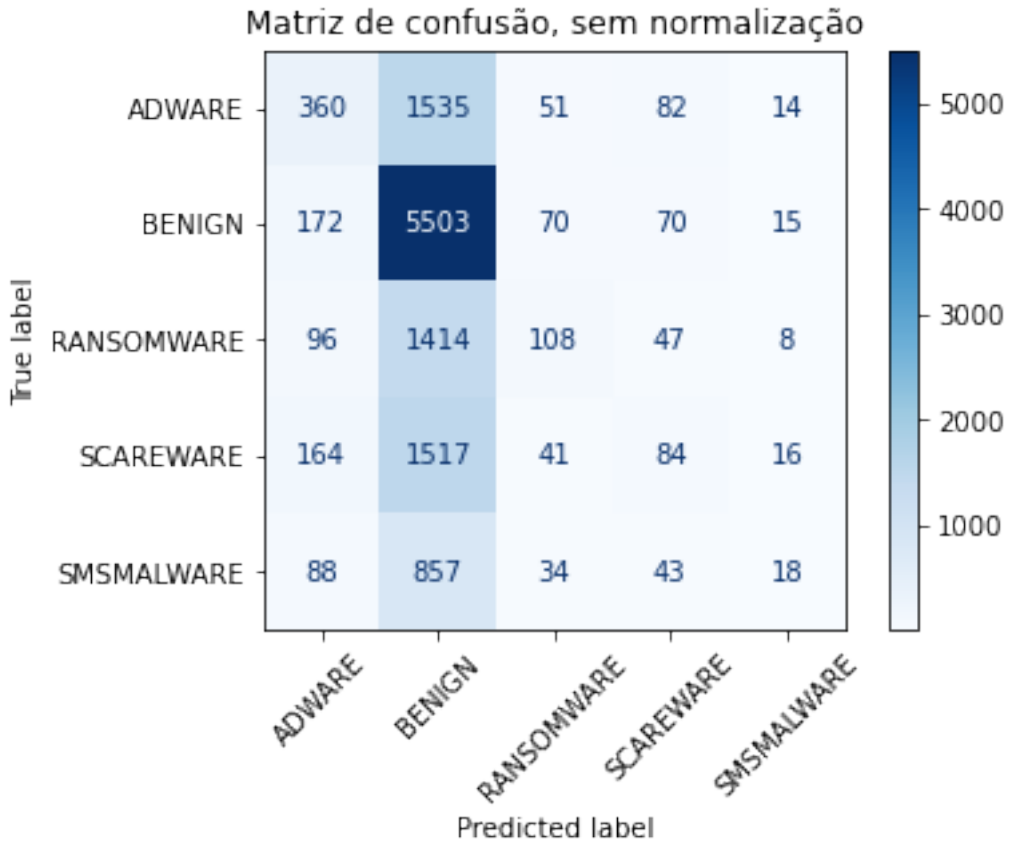

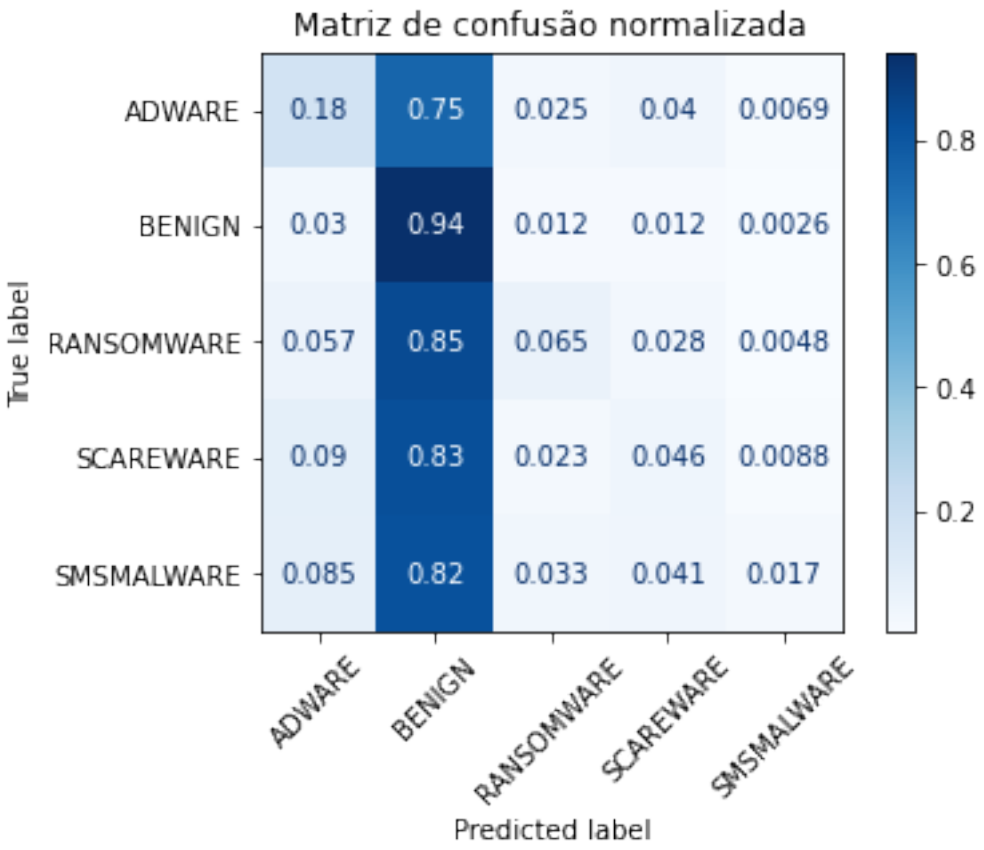
Matriz de confusão normalizada
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
0.18 0.75 0.025 0.04 0.0069
0.03 0.94 0.012 0.012 0.0026
0.057 0.85 0.065 0.028 0.0048
0.09 0.83 0.023 0.046 0.0088
0.085 0.82 0.033 0.041 0.017
True label
Predicted label
0.8
0.6
0.4
0.2

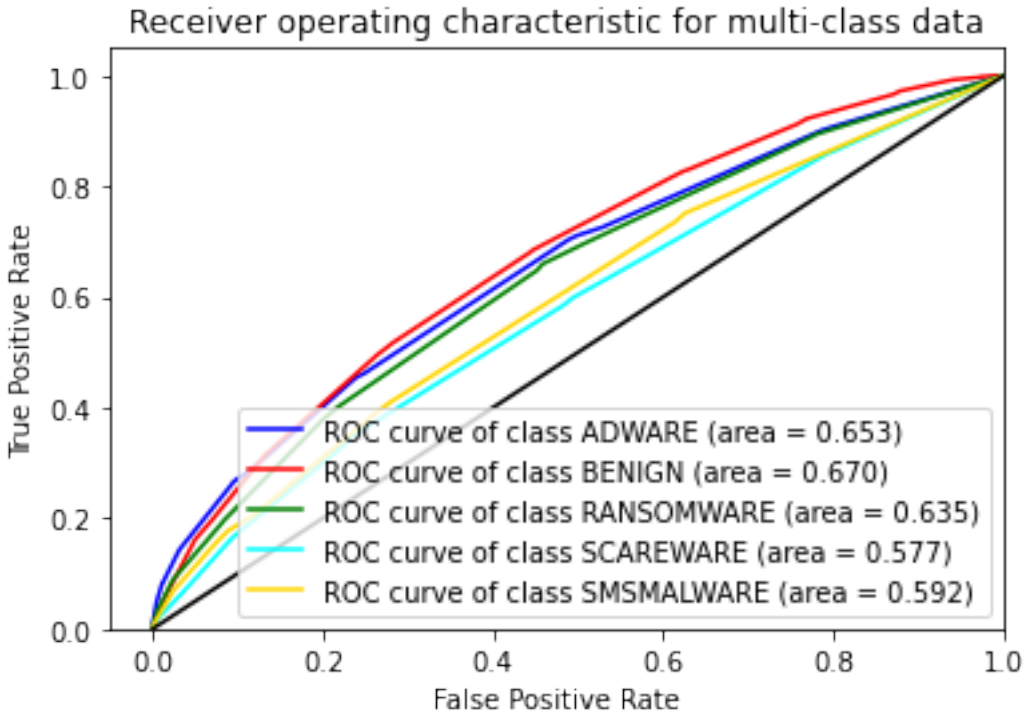
Receiver operating characteristic for multi-class data
True Positive Rate
False Positive Rate
0.0
0.2
0.4
0.6
0.8
1.0
ROC curve of class ADWARE (area = 0.653)
ROC curve of class BENIGN (area = 0.670)
ROC curve of class RANSOMWARE (area = 0.635)
ROC curve of class SCAREWARE (area = 0.577)
ROC curve of class SMSMALWARE (area = 0.592)

```
Acurácia: 0.487
Erro: 0.513
```

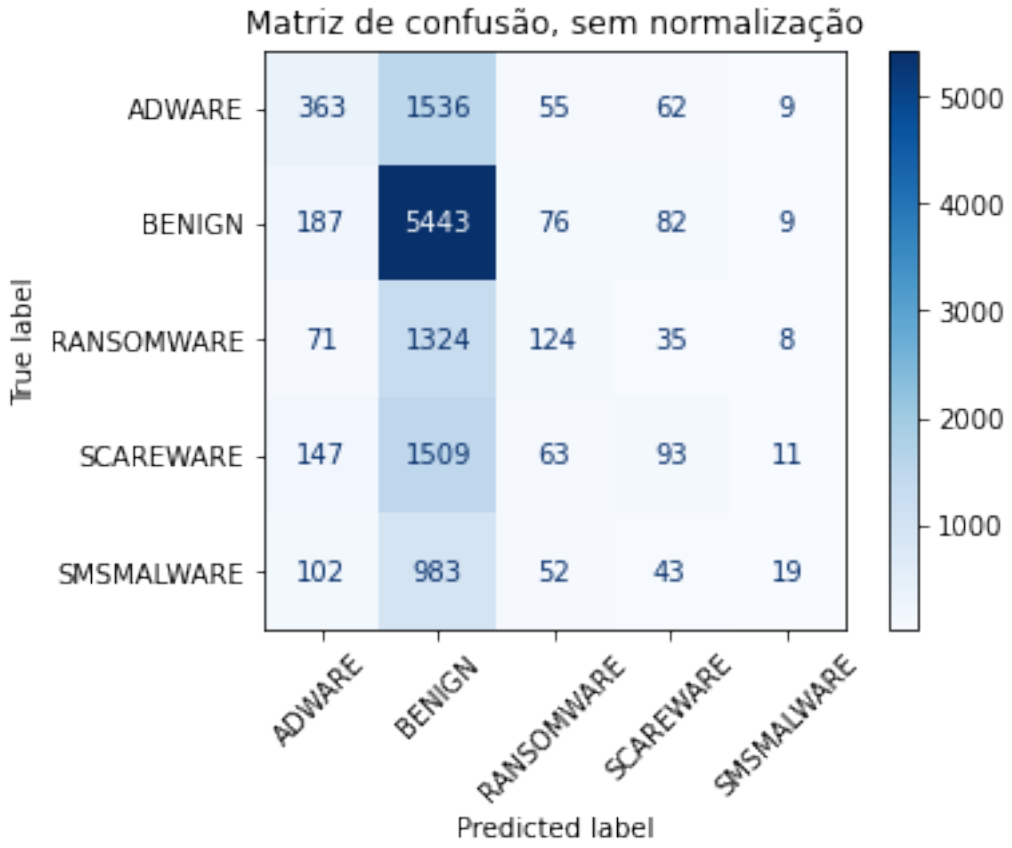

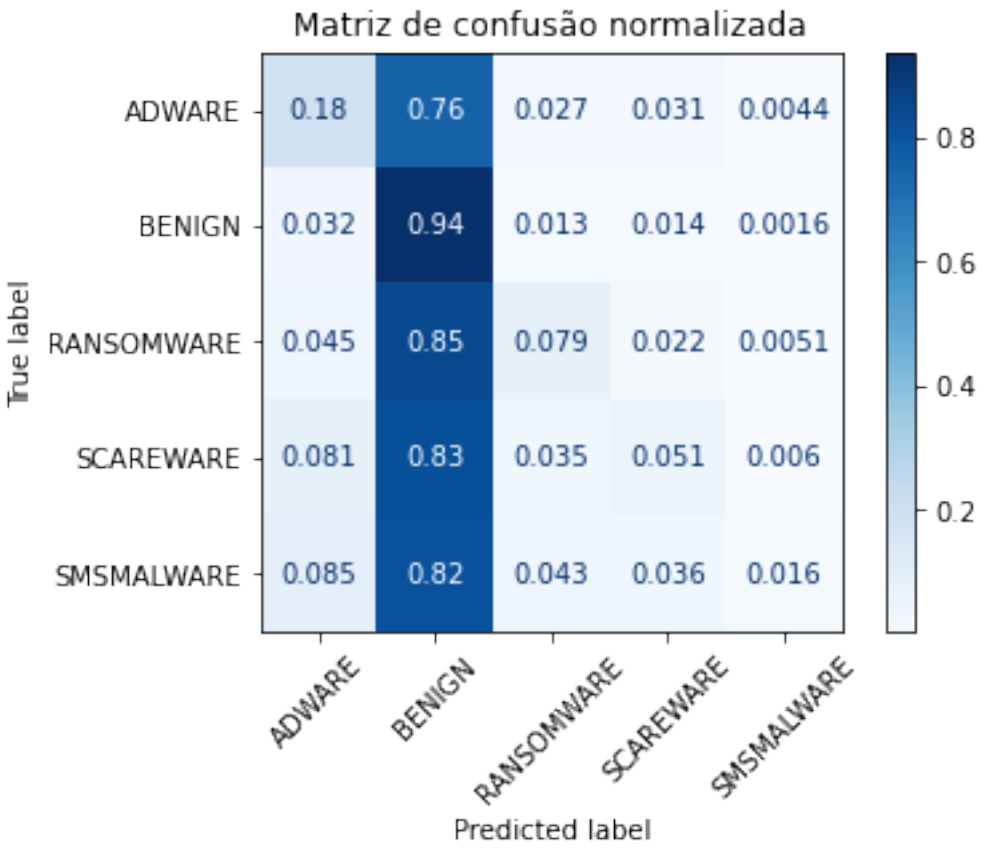
Matriz de confusão normalizada
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
0.18 0.76 0.027 0.031 0.0044
0.032 0.94 0.013 0.014 0.0016
0.045 0.85 0.079 0.022 0.0051
0.081 0.83 0.035 0.051 0.006
0.085 0.82 0.043 0.036 0.016
True label
Predicted label
0.8
0.6
0.4
0.2

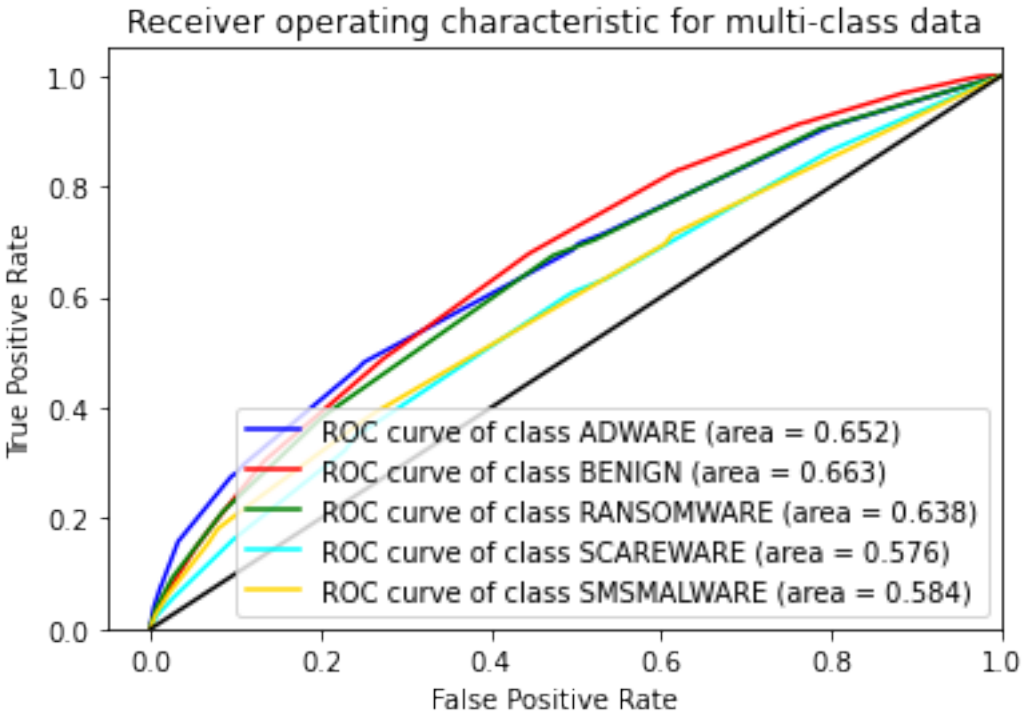
Receiver operating characteristic for multi-class data
True Positive Rate
False Positive Rate
0.0
0.2
0.4
0.6
0.8
1.0
ROC curve of class ADWARE (area = 0.652)
ROC curve of class BENIGN (area = 0.663)
ROC curve of class RANSOMWARE (area = 0.638)
ROC curve of class SCAREWARE (area = 0.576)
ROC curve of class SMSMALWARE (area = 0.584)

```
Acurácia: 0.488
Erro: 0.512
```

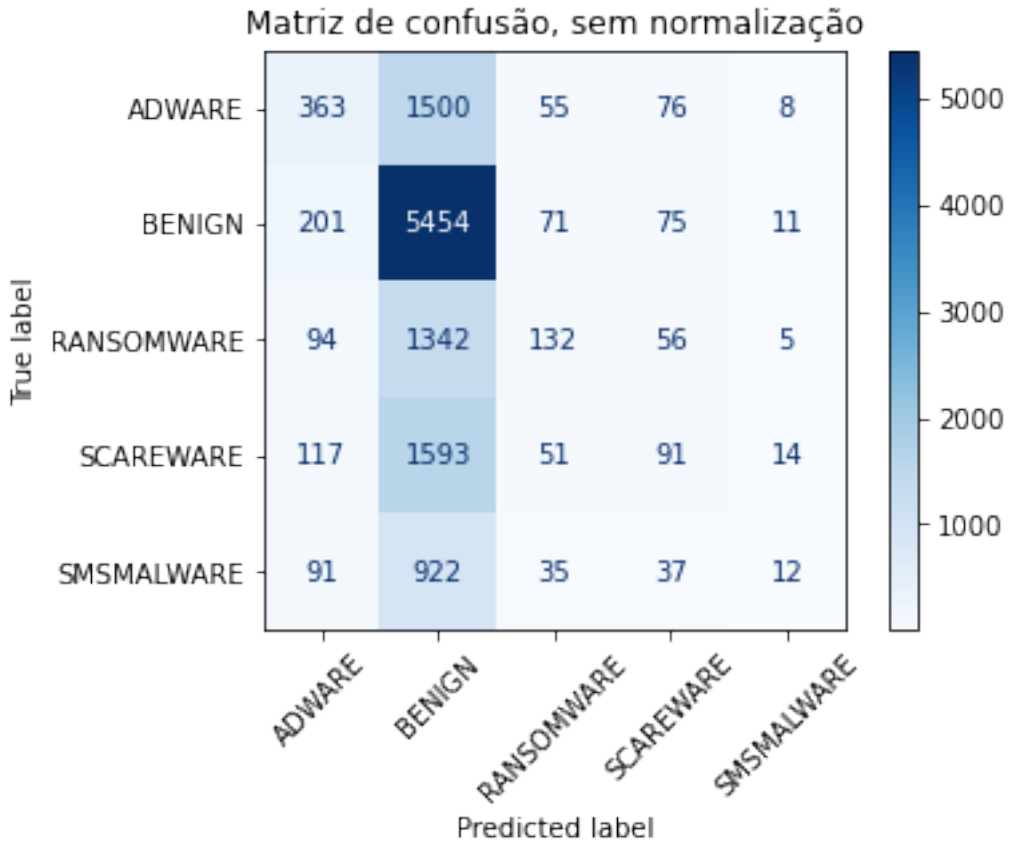

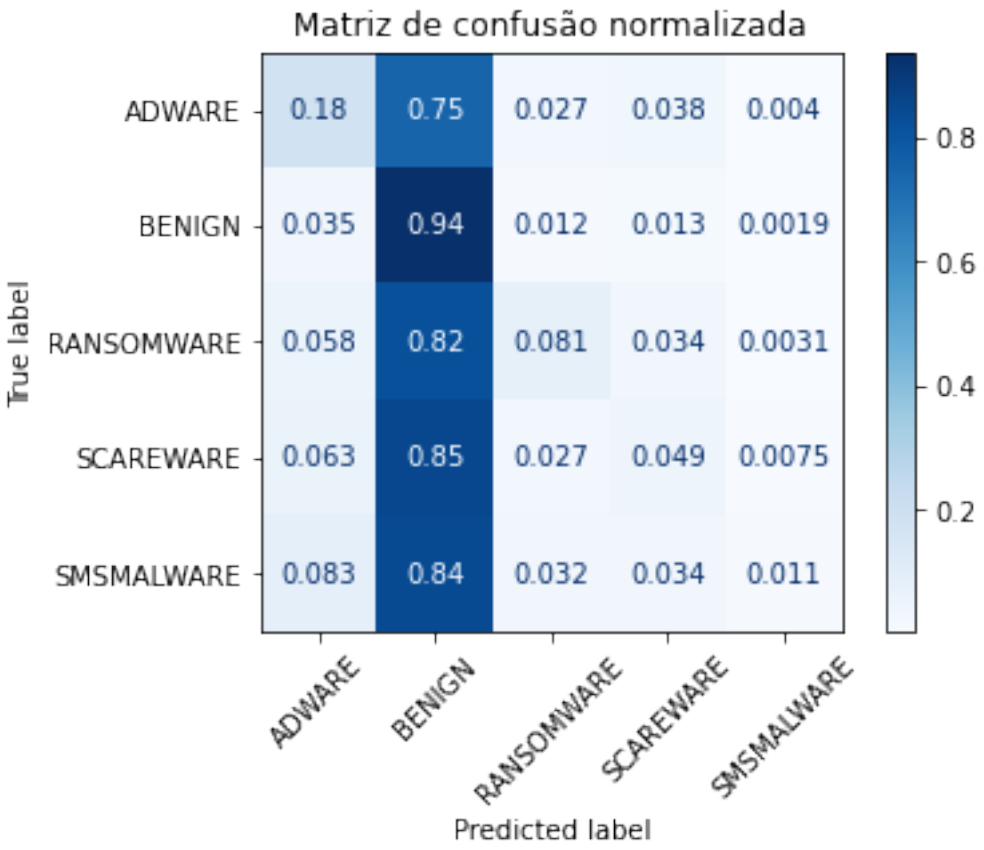
Matriz de confusão normalizada
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
0.18 0.75 0.027 0.038 0.004
0.035 0.94 0.012 0.013 0.0019
0.058 0.82 0.081 0.034 0.0031
0.063 0.85 0.027 0.049 0.0075
0.083 0.84 0.032 0.034 0.011
True label
Predicted label
0.8
0.6
0.4
0.2

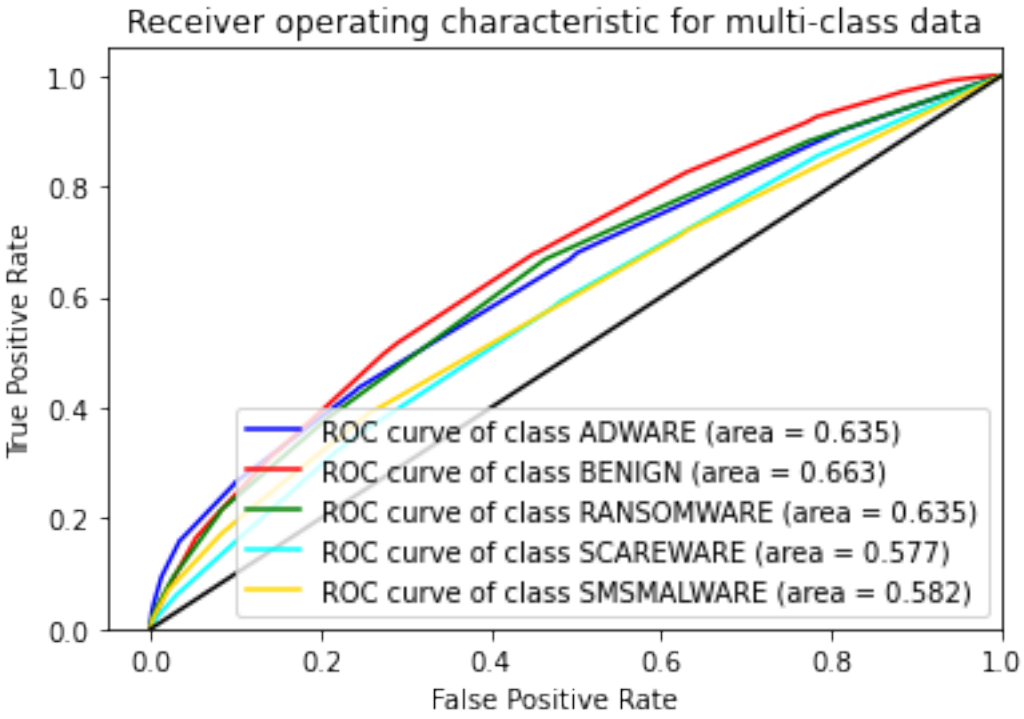
Receiver operating characteristic for multi-class data
True Positive Rate
False Positive Rate
0.0
0.2
0.4
0.6
0.8
1.0
ROC curve of class ADWARE (area = 0.635)
ROC curve of class BENIGN (area = 0.663)
ROC curve of class RANSOMWARE (area = 0.635)
ROC curve of class SCAREWARE (area = 0.577)
ROC curve of class SMSMALWARE (area = 0.582)

```
Média: 0.48985209721735484
```

[23]:
```
media_acc = sum(scores)/len(scores)
media_erro = 1 - media_acc
print("Acurácia média:", media_acc)
print("Erro médio:", media_erro)
```

```
Acurácia média: 0.48985209721735484
Erro médio: 0.5101479027826452
```

[33]:
```
scores_array = np.array(scores)
models_array = np.array(models)
folds_array = np.array(folds)
index = np.where(scores_array == max(scores_array))
melhor_model_KNN_k_fold = models_array[index[0]][0]
KNN_k_fold = folds_array[index[0]]
```

[37]:
```
# Guarda o modelo gerado
dic_melhores_modelos['melhor_val_cruz_knn'] = []
dic_melhores_modelos['melhor_val_cruz_knn'] = []
dic_melhores_modelos['melhor_val_cruz_knn'] = []

dic_melhores_modelos['melhor_val_cruz_knn'].append(melhor_model_KNN_k_fold)
dic_melhores_modelos['melhor_val_cruz_knn'].append(media_acc)
dic_melhores_modelos['melhor_val_cruz_knn'].append(KNN_k_fold)
```

[28]:
```
# Curva ROC por classe
funcoes_uteis.plot_roc_k_fold(clf_kNN, X_treinamento_norm, y_treinamento_norm,␣
↪5)
```

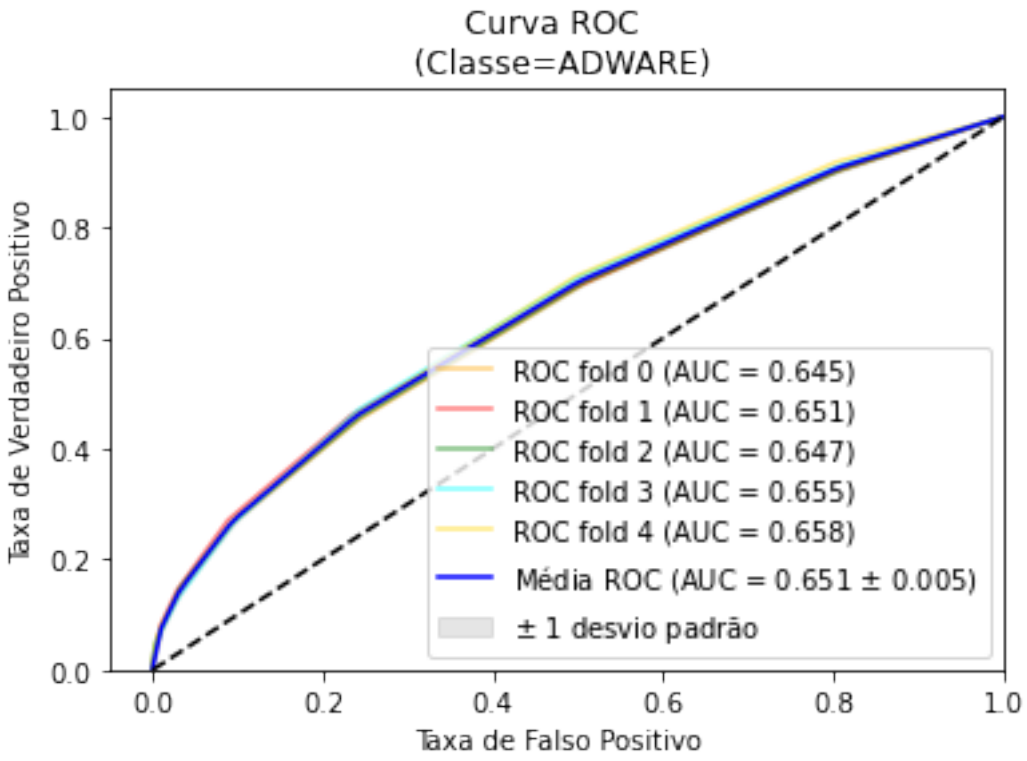
Curva ROC
(Classe=ADWARE)
Taxa de Verdadeiro Positivo
Taxa de Falso Positivo
0.0
0.2
0.4
0.6
0.8
1.0
ROC fold 0 (AUC = 0.645)
ROC fold 1 (AUC = 0.651)
ROC fold 2 (AUC = 0.647)
ROC fold 3 (AUC = 0.655)
ROC fold 4 (AUC = 0.658)
Média ROC (AUC = 0.651 ± 0.005)
± 1 desvio padrão

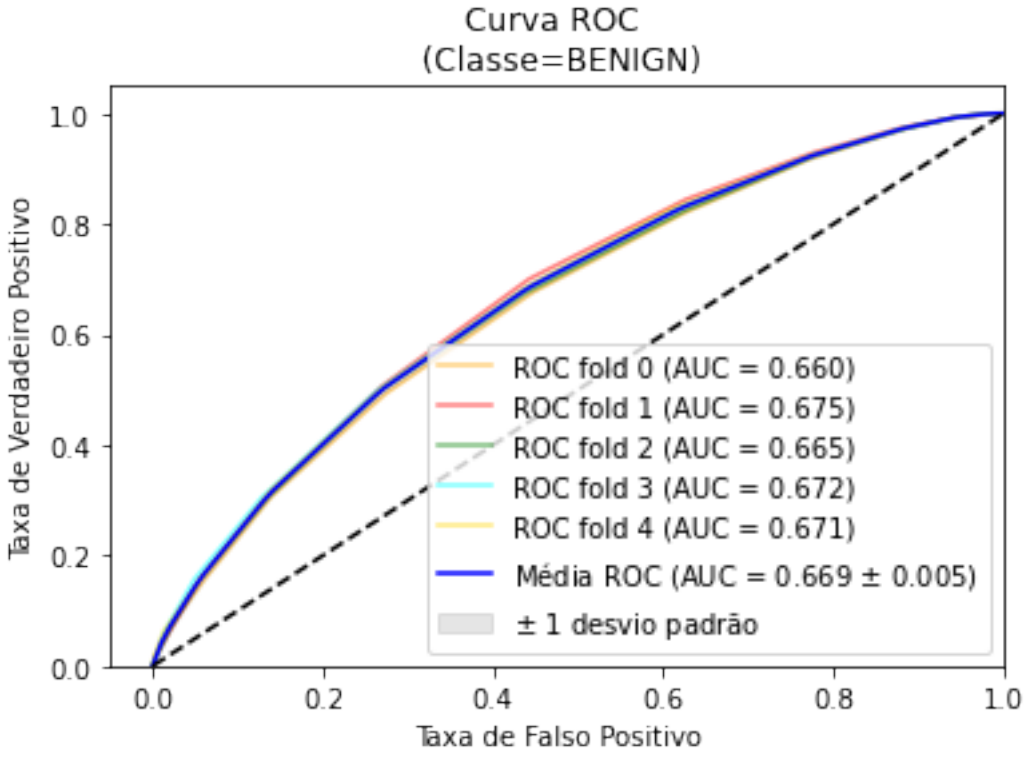
Curva ROC
(Classe=BENIGN)
Taxa de Verdadeiro Positivo
Taxa de Falso Positivo
0.0
0.2
0.4
0.6
0.8
1.0
ROC fold 0 (AUC = 0.660)
ROC fold 1 (AUC = 0.675)
ROC fold 2 (AUC = 0.665)
ROC fold 3 (AUC = 0.672)
ROC fold 4 (AUC = 0.671)
Média ROC (AUC = 0.669 ± 0.005)
± 1 desvio padrão

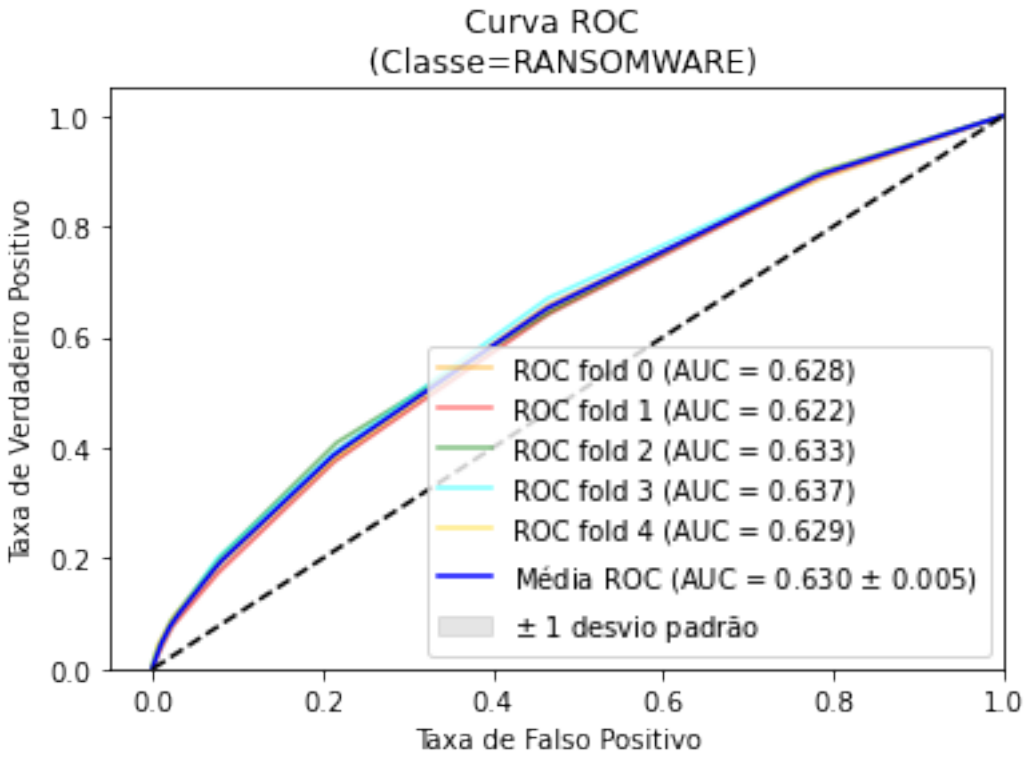
Curva ROC
(Classe=RANSOMWARE)
Taxa de Verdadeiro Positivo
Taxa de Falso Positivo
0.0
0.2
0.4
0.6
0.8
1.0
ROC fold 0 (AUC = 0.628)
ROC fold 1 (AUC = 0.622)
ROC fold 2 (AUC = 0.633)
ROC fold 3 (AUC = 0.637)
ROC fold 4 (AUC = 0.629)
Média ROC (AUC = 0.630 ± 0.005)
± 1 desvio padrão

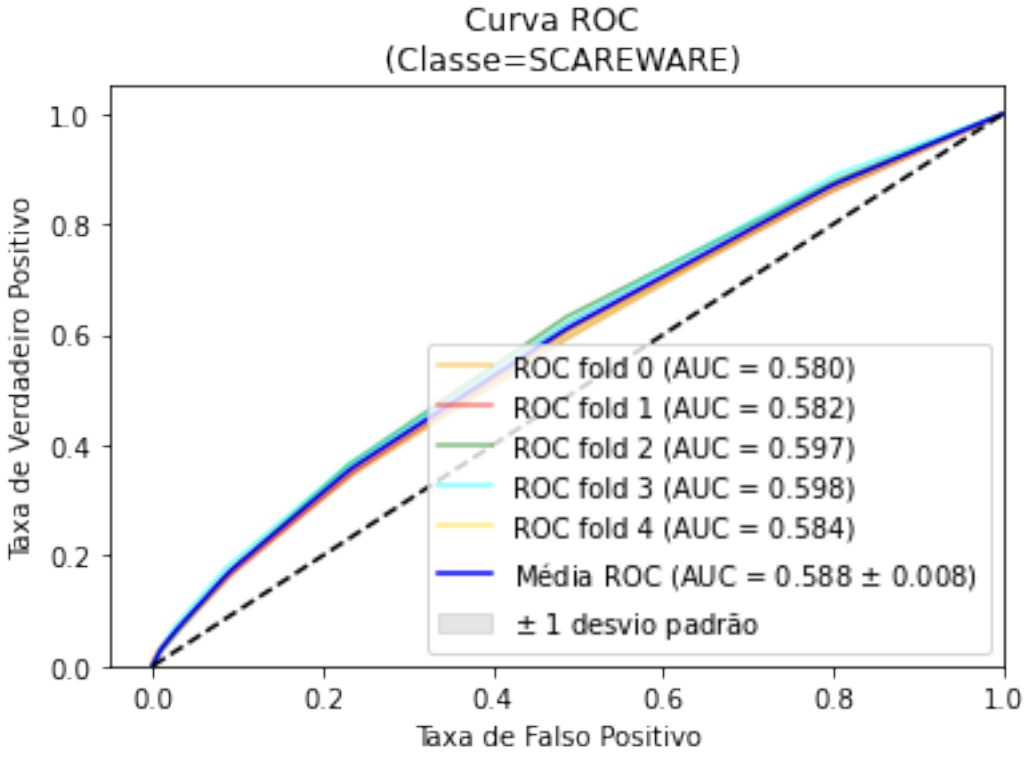
Curva ROC
(Classe=SCAREWARE)
Taxa de Verdadeiro Positivo
Taxa de Falso Positivo
0.0
0.2
0.4
0.6
0.8
1.0
ROC fold 0 (AUC = 0.580)
ROC fold 1 (AUC = 0.582)
ROC fold 2 (AUC = 0.597)
ROC fold 3 (AUC = 0.598)
ROC fold 4 (AUC = 0.584)
Média ROC (AUC = 0.588 ± 0.008)
± 1 desvio padrão

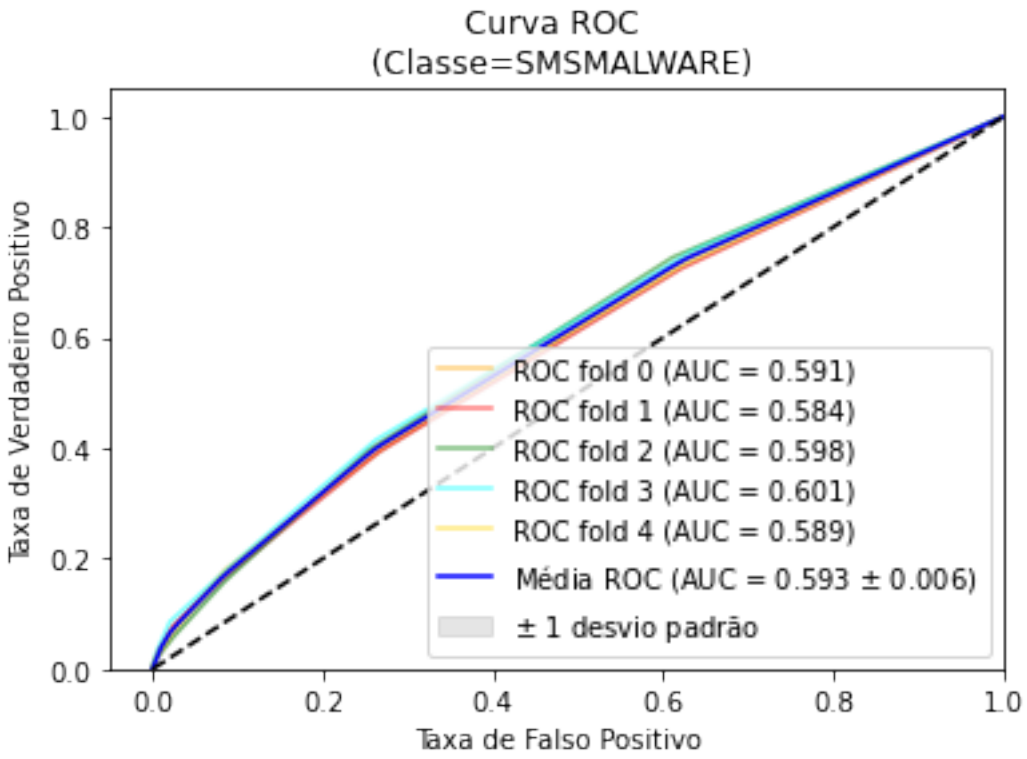


### 3.4.3 *Random Forest*

- Neste algoritmo foi utilizados os mesmos hiperparametros da etapa *percentage split*. Portanto o experimento para o *Random Forest* será executado com o seguinte hiperparâmetros e dados:
  - Dados: Normalizados
  - Número de estimadores: 50

[73]:
```
clf_rf = RandomForestClassifier(n_estimators = 50, random_state=0)

scores, models, folds = funcoes_uteis.k_fold_train(clf_rf, df_treinamento_norm,␣
↪clf_name='RF')
```

```
Acurácia: 0.979
Erro: 0.021
```

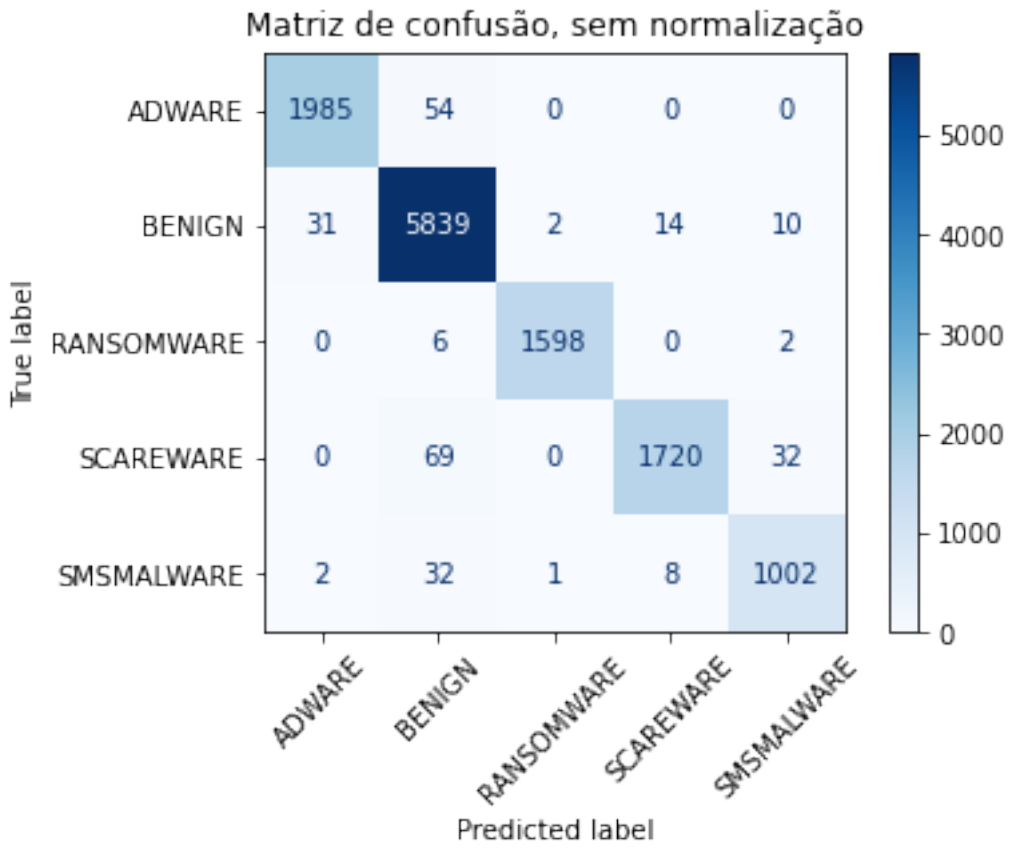
Matriz de confusão, sem normalização
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
True label
1985 54 0 0 0
31 5839 2 14 10
0 6 1598 0 2
0 69 0 1720 32
2 32 1 8 1002
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
Predicted label
5000
4000
3000
2000
1000
0

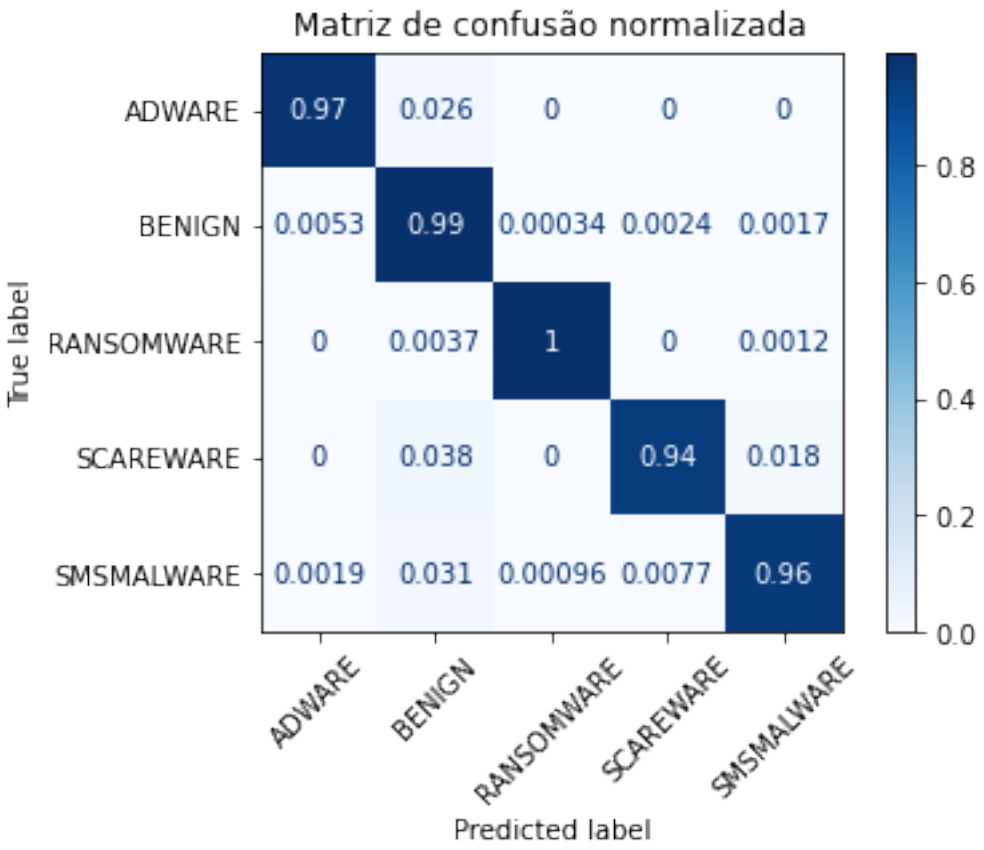
Matriz de confusão normalizada
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
0.97 0.026 0 0 0
0.0053 0.99 0.00034 0.0024 0.0017
0 0.0037 1 0 0.0012
0 0.038 0 0.94 0.018
0.0019 0.031 0.00096 0.0077 0.96
True label
Predicted label
0.0
0.2
0.4
0.6
0.8

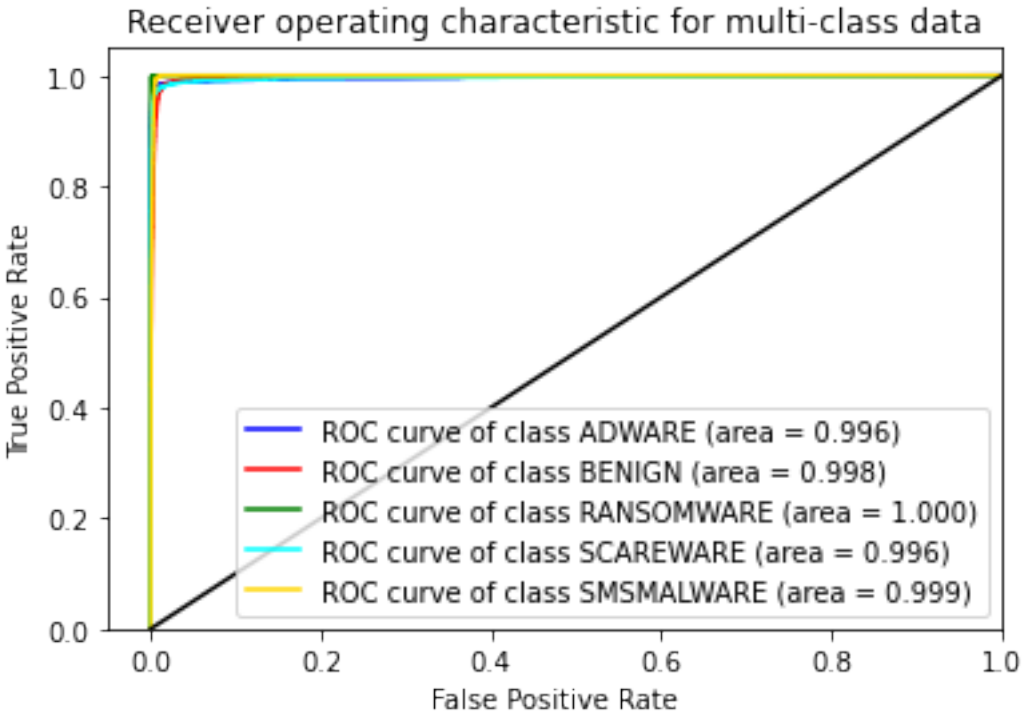
Receiver operating characteristic for multi-class data
True Positive Rate
False Positive Rate
0.0
0.2
0.4
0.6
0.8
1.0
ROC curve of class ADWARE (area = 0.996)
ROC curve of class BENIGN (area = 0.998)
ROC curve of class RANSOMWARE (area = 1.000)
ROC curve of class SCAREWARE (area = 0.996)
ROC curve of class SMSMALWARE (area = 0.999)

Acurácia: 0.979
Erro: 0.021

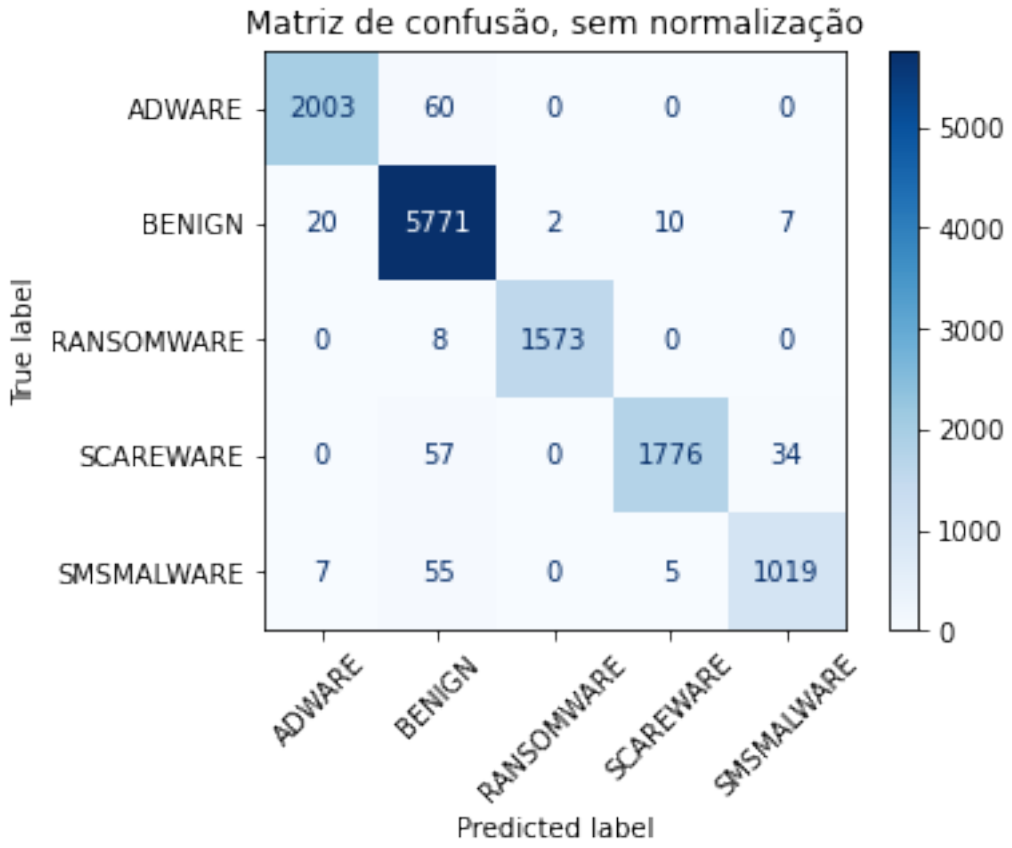

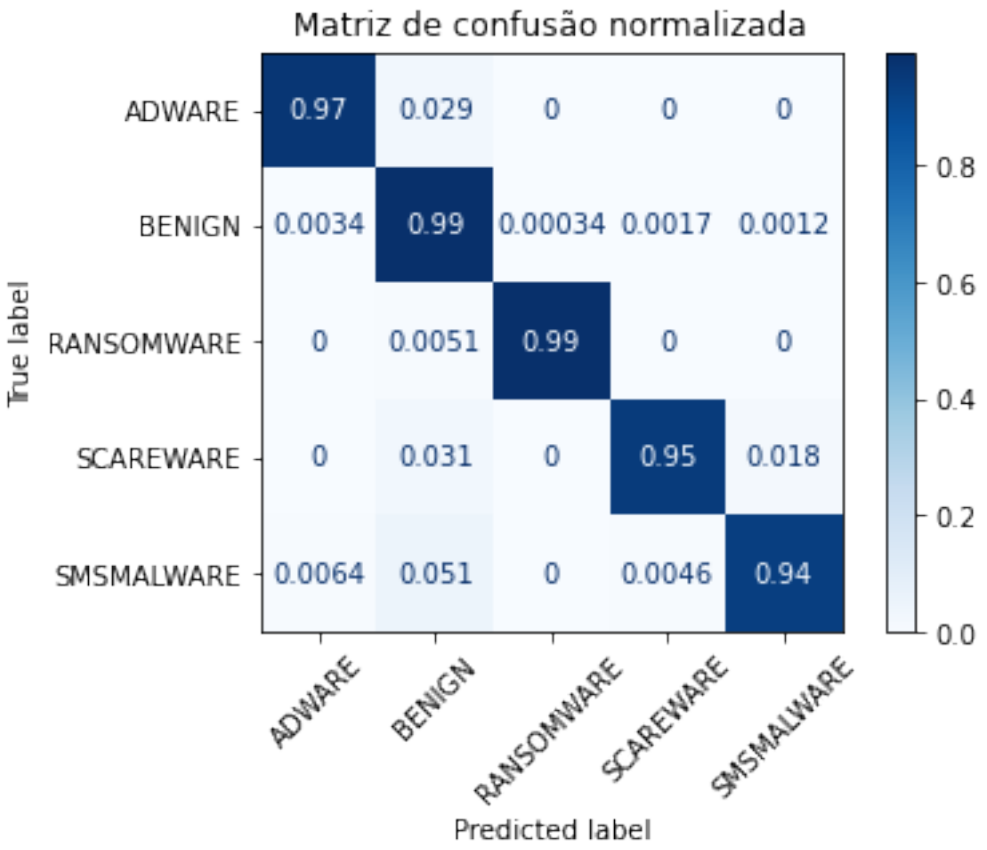
Matriz de confusão normalizada
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
True label
0.97 0.029 0 0 0
0.0034 0.99 0.00034 0.0017 0.0012
0 0.0051 0.99 0 0
0 0.031 0 0.95 0.018
0.0064 0.051 0 0.0046 0.94
0.8
0.6
0.4
0.2
0.0
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
Predicted label

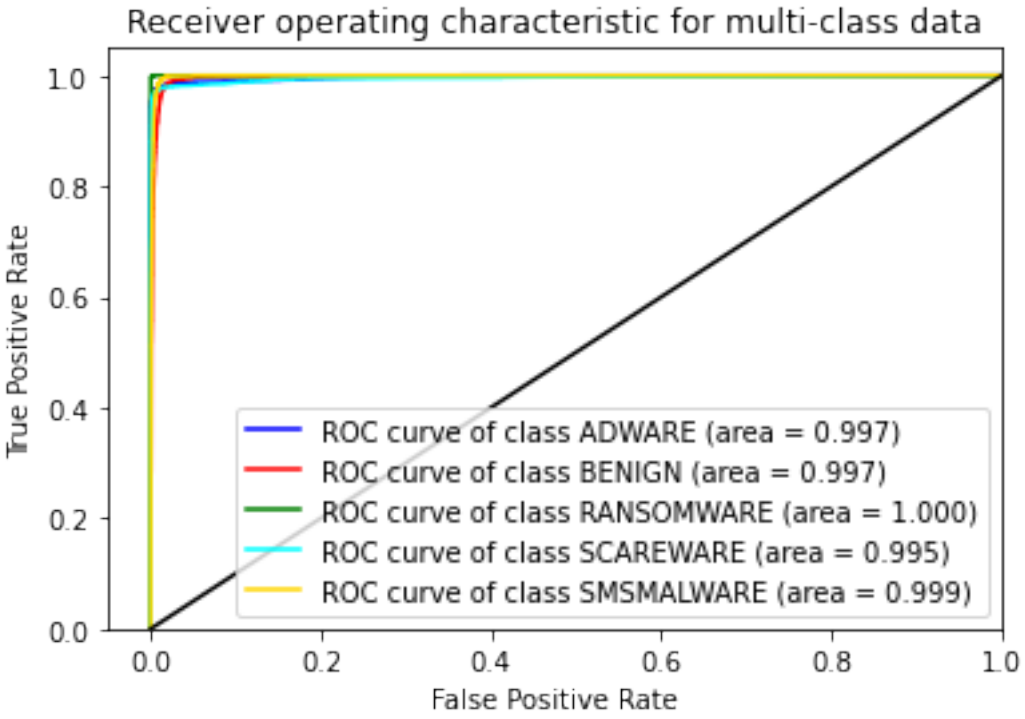
Receiver operating characteristic for multi-class data
True Positive Rate
False Positive Rate
0.0
0.2
0.4
0.6
0.8
1.0
ROC curve of class ADWARE (area = 0.997)
ROC curve of class BENIGN (area = 0.997)
ROC curve of class RANSOMWARE (area = 1.000)
ROC curve of class SCAREWARE (area = 0.995)
ROC curve of class SMSMALWARE (area = 0.999)

```
Acurácia: 0.979
Erro: 0.021
```

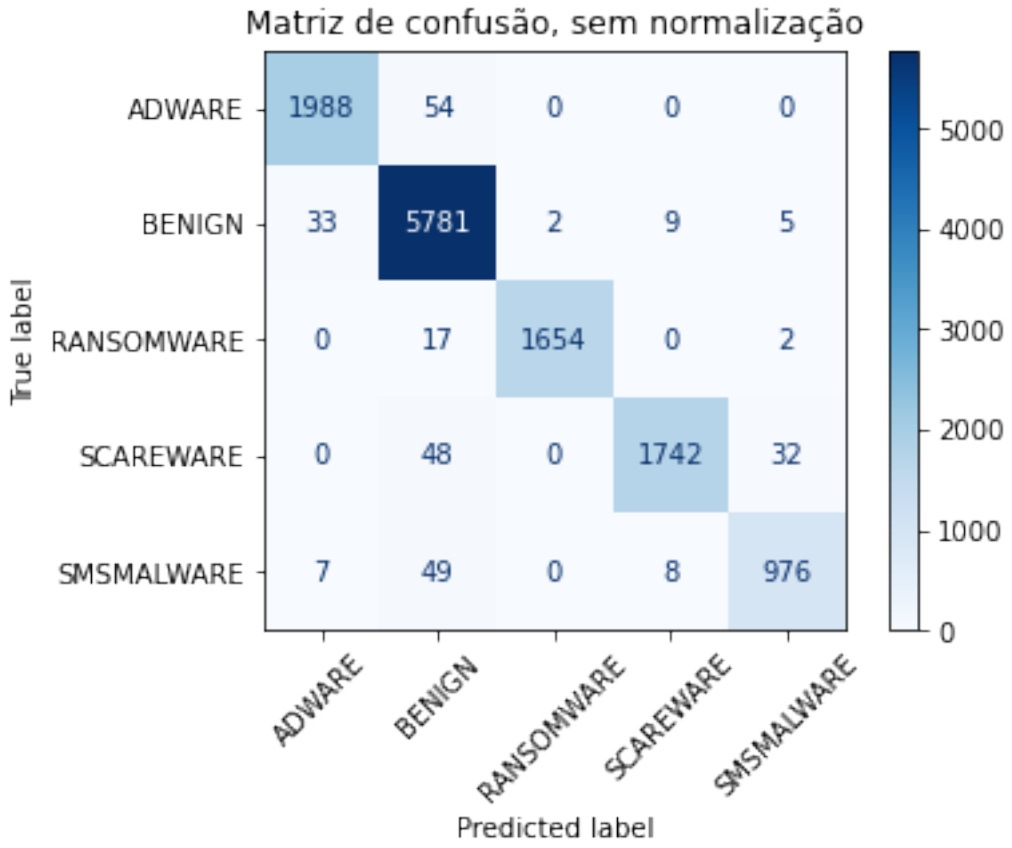

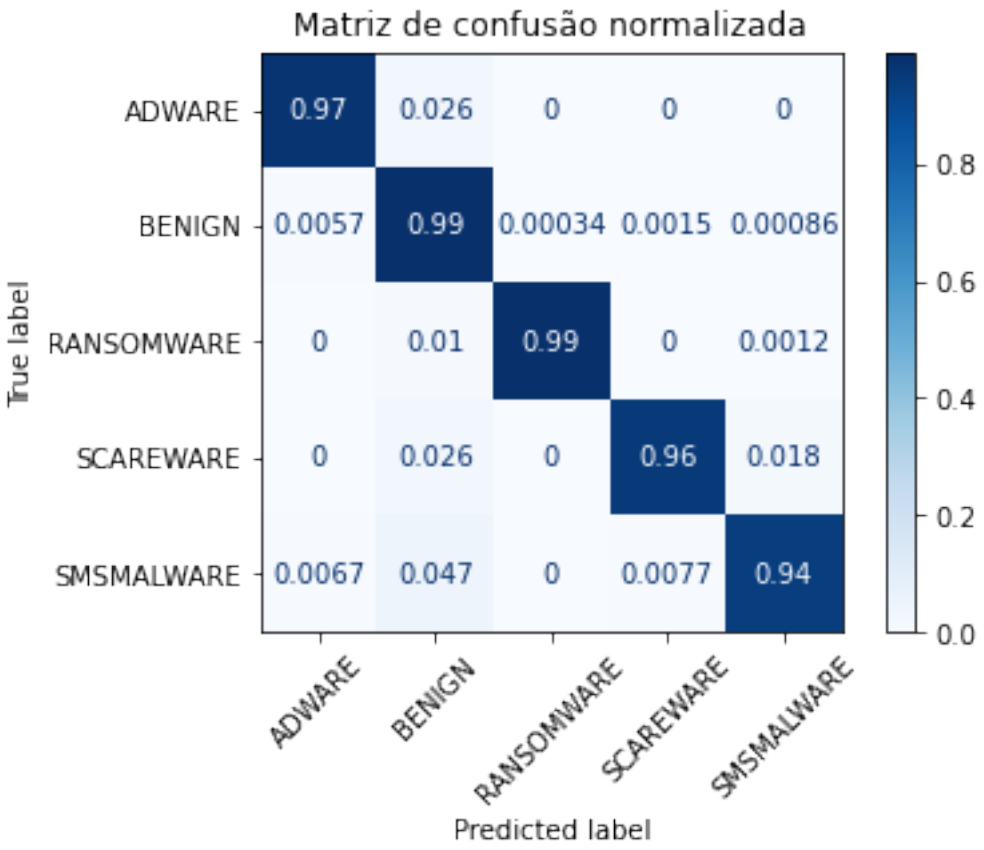
Matriz de confusão normalizada
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
0.97 0.026 0 0 0
0.0057 0.99 0.00034 0.0015 0.00086
0 0.01 0.99 0 0.0012
0 0.026 0 0.96 0.018
0.0067 0.047 0 0.0077 0.94
True label
Predicted label
0.0
0.2
0.4
0.6
0.8

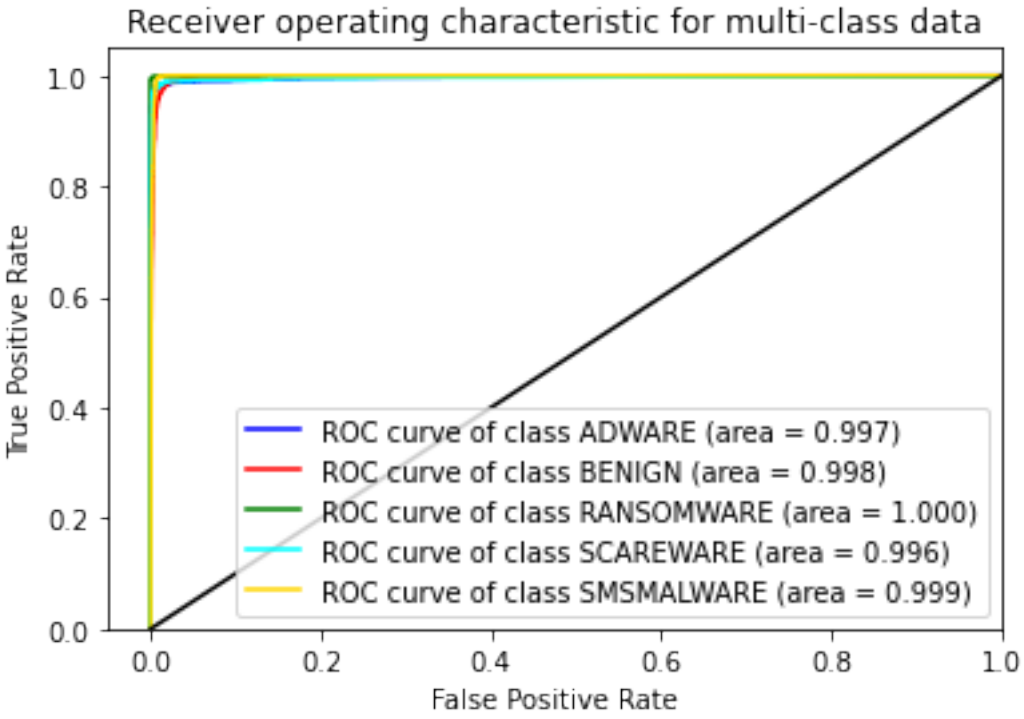
Receiver operating characteristic for multi-class data
True Positive Rate
False Positive Rate
0.0
0.2
0.4
0.6
0.8
1.0
ROC curve of class ADWARE (area = 0.997)
ROC curve of class BENIGN (area = 0.998)
ROC curve of class RANSOMWARE (area = 1.000)
ROC curve of class SCAREWARE (area = 0.996)
ROC curve of class SMSMALWARE (area = 0.999)

```
Acurácia: 0.979
Erro: 0.021
```

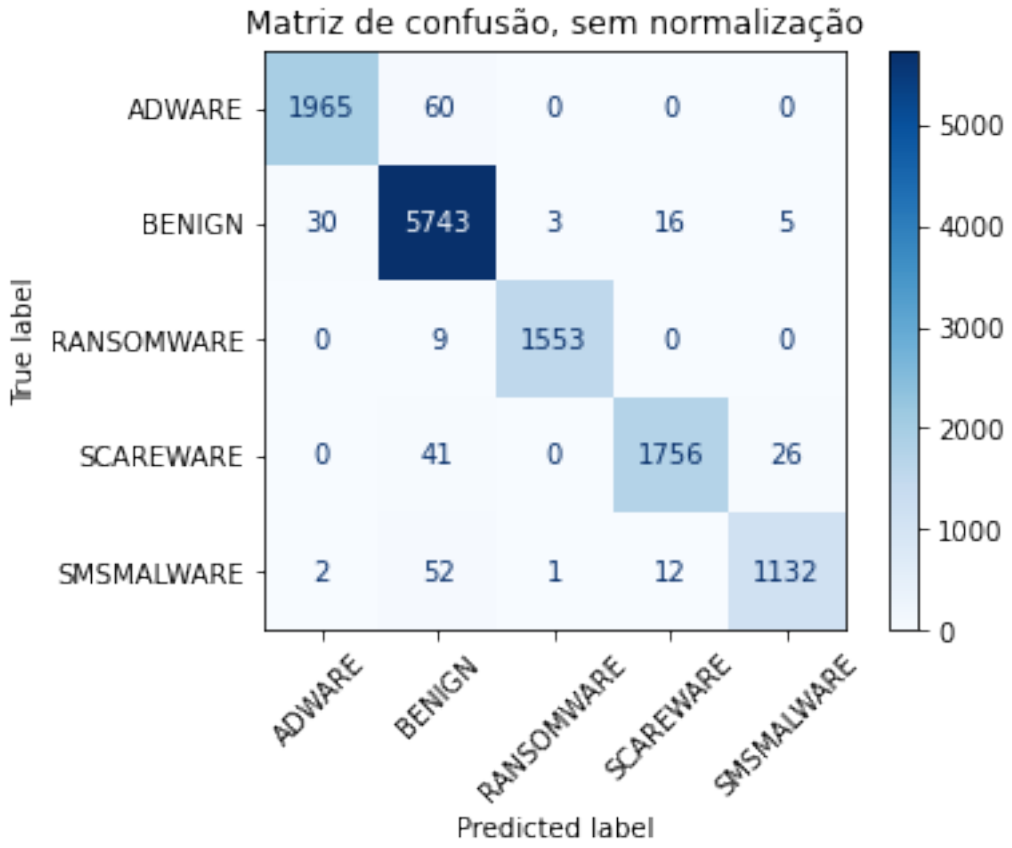

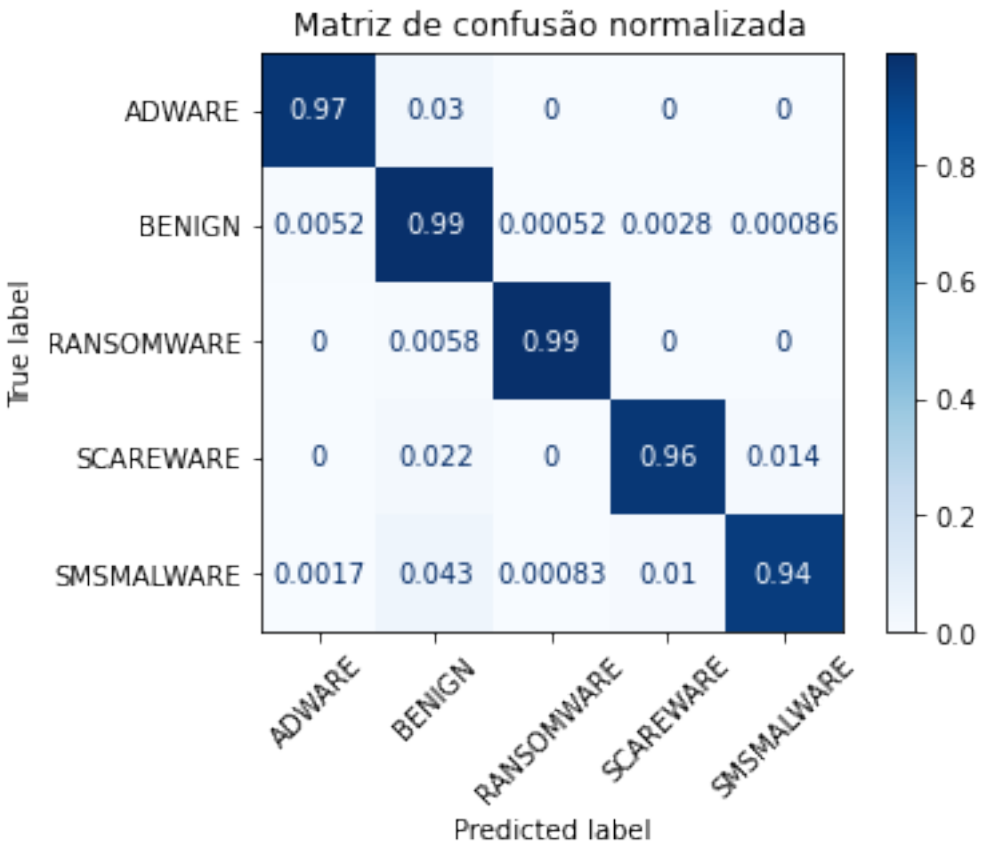
Matriz de confusão normalizada
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
True label
0.97 0.03 0 0 0
0.0052 0.99 0.00052 0.0028 0.00086
0 0.0058 0.99 0 0
0 0.022 0 0.96 0.014
0.0017 0.043 0.00083 0.01 0.94
0.8
0.6
0.4
0.2
0.0
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
Predicted label

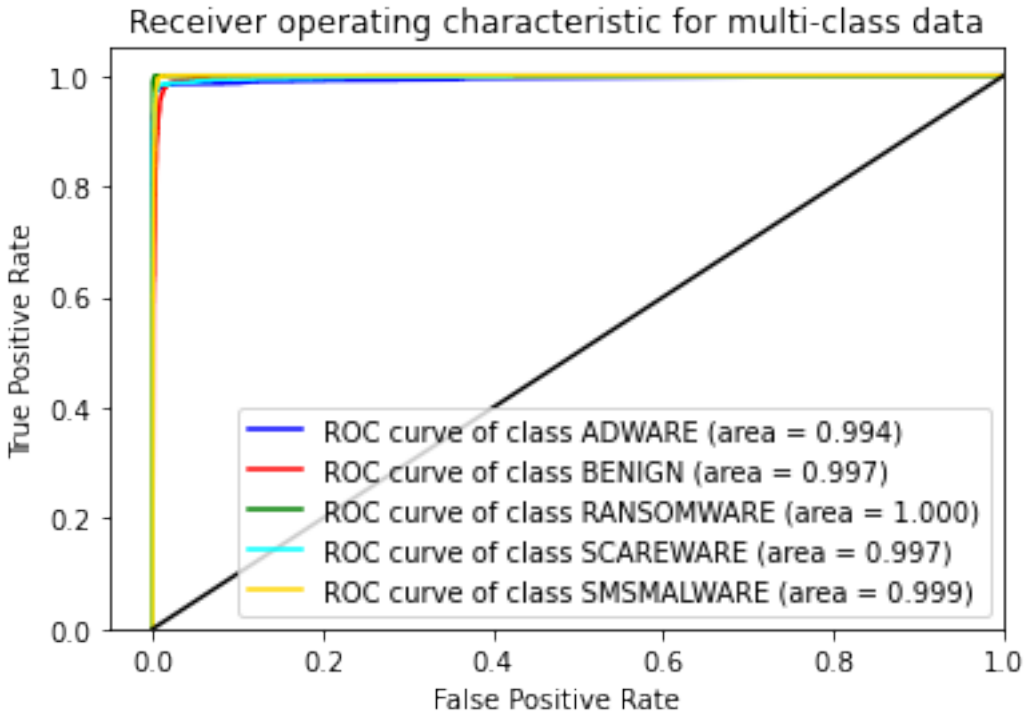
Receiver operating characteristic for multi-class data
True Positive Rate
False Positive Rate
0.0
0.2
0.4
0.6
0.8
1.0
ROC curve of class ADWARE (area = 0.994)
ROC curve of class BENIGN (area = 0.997)
ROC curve of class RANSOMWARE (area = 1.000)
ROC curve of class SCAREWARE (area = 0.997)
ROC curve of class SMSMALWARE (area = 0.999)

Acurácia: 0.976
Erro: 0.024

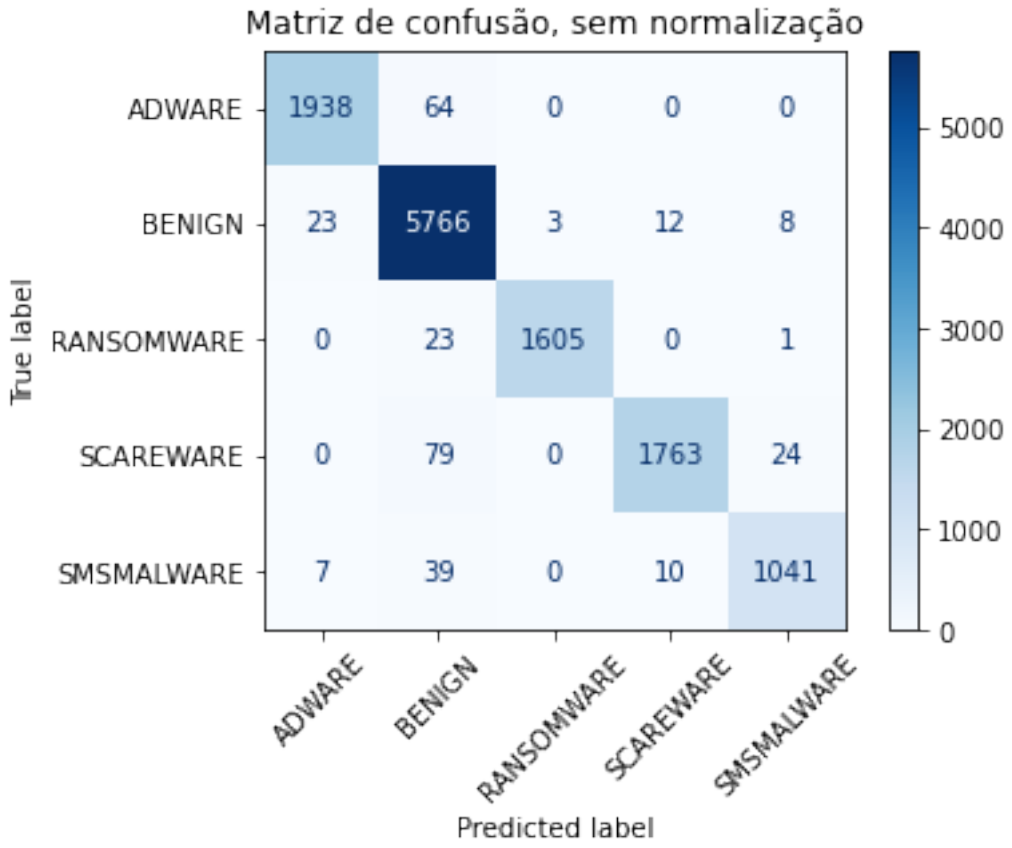

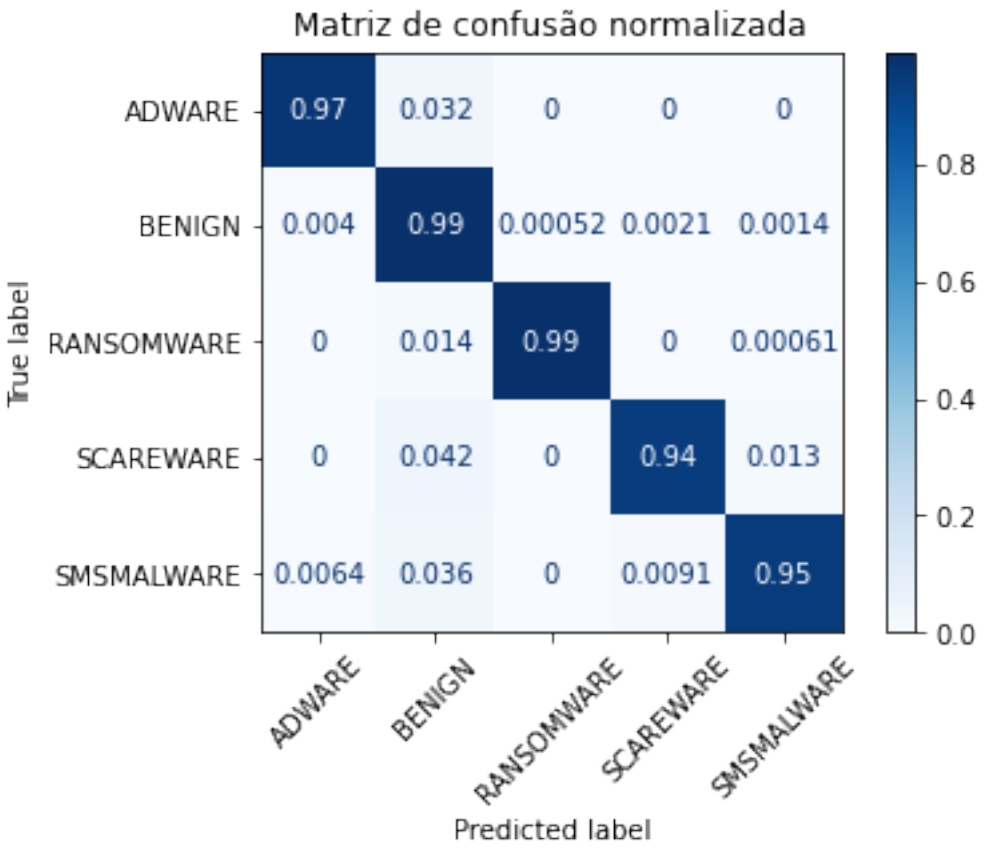
Matriz de confusão normalizada
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
0.97 0.032 0 0 0
0.004 0.99 0.00052 0.0021 0.0014
0 0.014 0.99 0 0.00061
0 0.042 0 0.94 0.013
0.0064 0.036 0 0.0091 0.95
True label
Predicted label
0.0
0.2
0.4
0.6
0.8

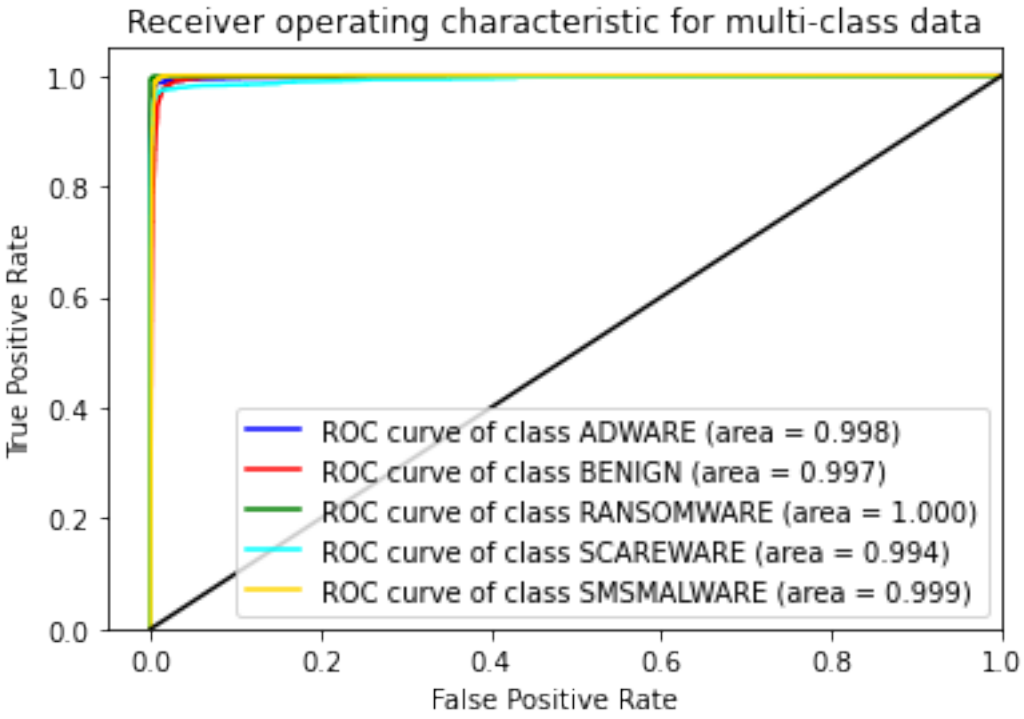
Receiver operating characteristic for multi-class data
True Positive Rate
False Positive Rate
0.0
0.2
0.4
0.6
0.8
1.0
ROC curve of class ADWARE (area = 0.998)
ROC curve of class BENIGN (area = 0.997)
ROC curve of class RANSOMWARE (area = 1.000)
ROC curve of class SCAREWARE (area = 0.994)
ROC curve of class SMSMALWARE (area = 0.999)

```
Média: 0.9783340963425958
```

[74]:
```
media_acc = sum(scores)/len(scores)
media_erro = 1 - media_acc
print("Acurácia média:", media_acc)
print("Erro médio:", media_erro)
```

```
Acurácia média: 0.9783340963425958
Erro médio: 0.021665903657404173
```

[75]:
```
scores_array = np.array(scores)
models_array = np.array(models)
folds_array = np.array(folds)
index = np.where(scores_array == max(scores_array))
melhor_model_RF_k_fold = models_array[index]
RF_k_fold = folds_array[index[0]]
```

[76]:
```
# Guarda o modelo gerado
dic_melhores_modelos['melhor_val_cruz_rf'].append(melhor_model_RF_k_fold)
dic_melhores_modelos['melhor_val_cruz_rf'].append(media_acc)
dic_melhores_modelos['melhor_val_cruz_rf'].append(RF_k_fold)
```

[36]:
```
# Curva ROC por classe
funcoes_uteis.plot_roc_k_fold(clf_rf, X_treinamento_norm, y_treinamento_norm, 5)
```

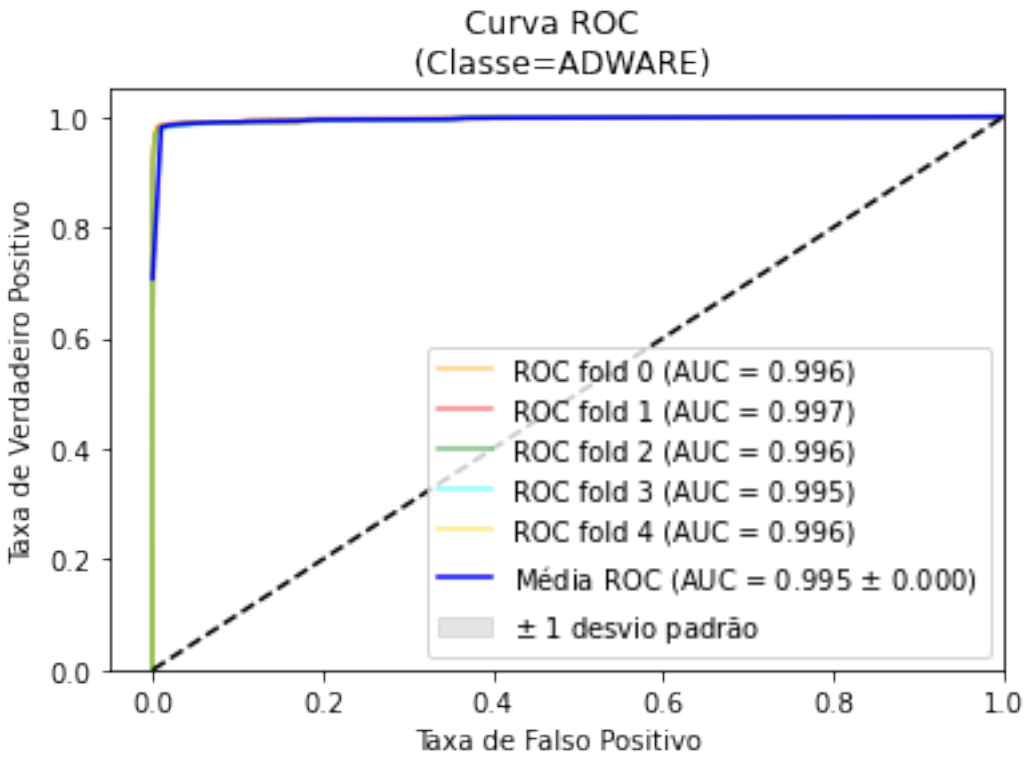
Curva ROC
(Classe=ADWARE)
Taxa de Verdadeiro Positivo
Taxa de Falso Positivo
0.0
0.2
0.4
0.6
0.8
1.0
ROC fold 0 (AUC = 0.996)
ROC fold 1 (AUC = 0.997)
ROC fold 2 (AUC = 0.996)
ROC fold 3 (AUC = 0.995)
ROC fold 4 (AUC = 0.996)
Média ROC (AUC = 0.995 ± 0.000)
± 1 desvio padrão

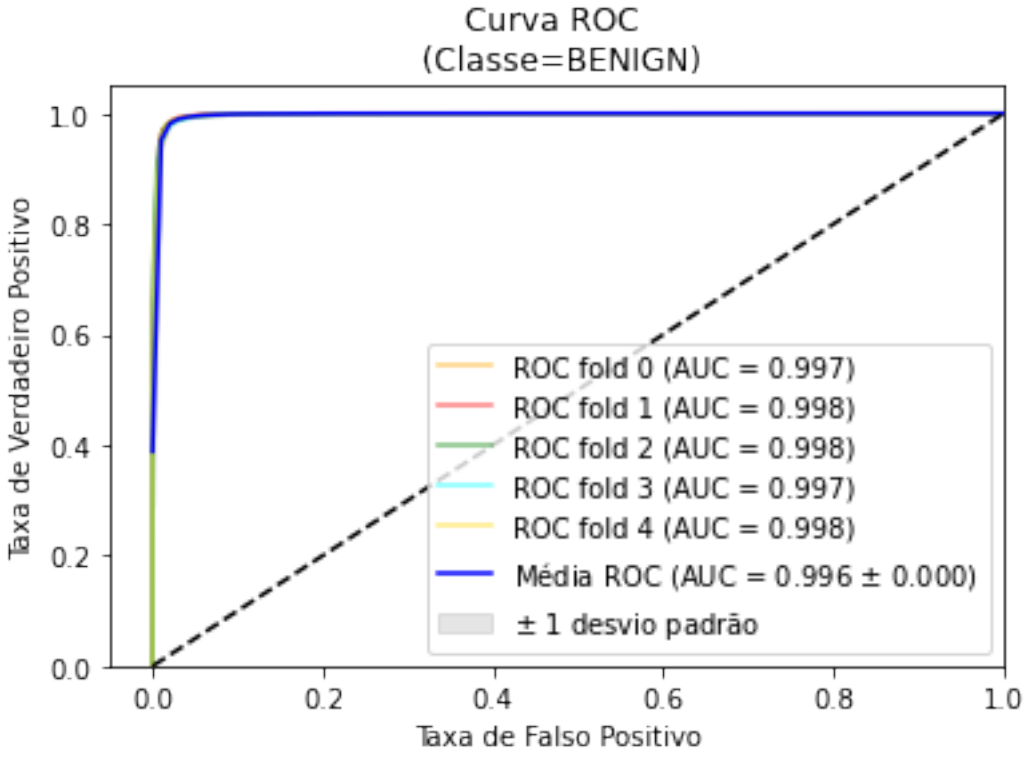
Curva ROC
(Classe=BENIGN)
Taxa de Verdadeiro Positivo
Taxa de Falso Positivo
0.0
0.2
0.4
0.6
0.8
1.0
ROC fold 0 (AUC = 0.997)
ROC fold 1 (AUC = 0.998)
ROC fold 2 (AUC = 0.998)
ROC fold 3 (AUC = 0.997)
ROC fold 4 (AUC = 0.998)
Média ROC (AUC = 0.996 ± 0.000)
± 1 desvio padrão

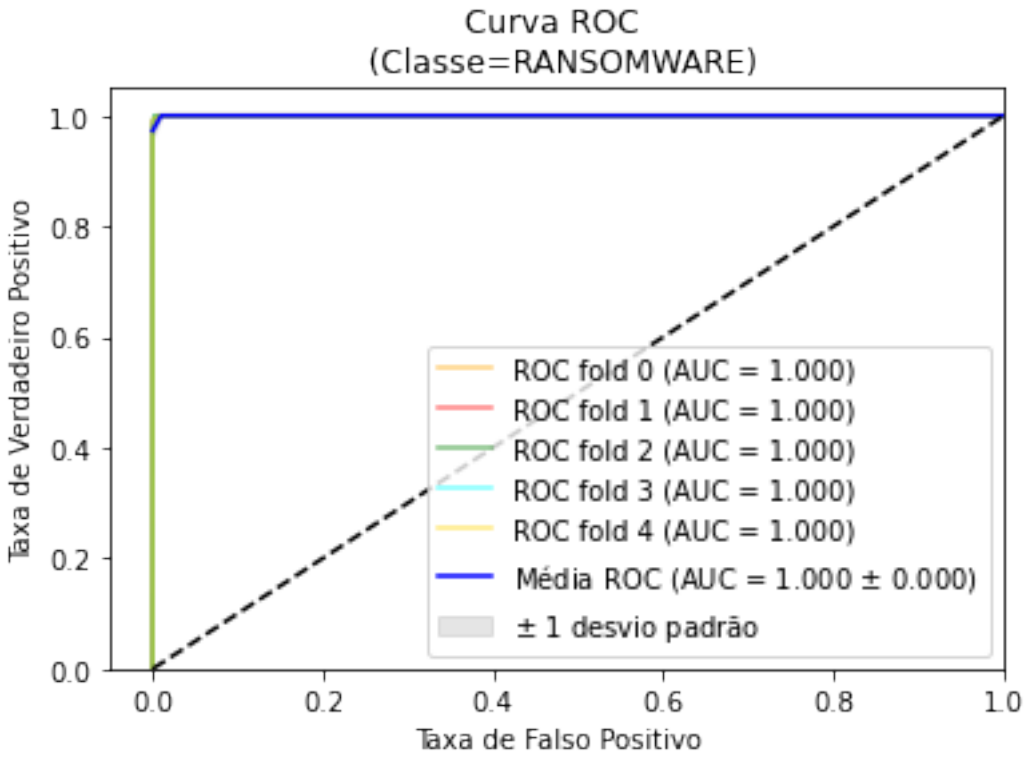
Curva ROC
(Classe=RANSOMWARE)
Taxa de Verdadeiro Positivo
Taxa de Falso Positivo
0.0
0.2
0.4
0.6
0.8
1.0
ROC fold 0 (AUC = 1.000)
ROC fold 1 (AUC = 1.000)
ROC fold 2 (AUC = 1.000)
ROC fold 3 (AUC = 1.000)
ROC fold 4 (AUC = 1.000)
Média ROC (AUC = 1.000 ± 0.000)
± 1 desvio padrão

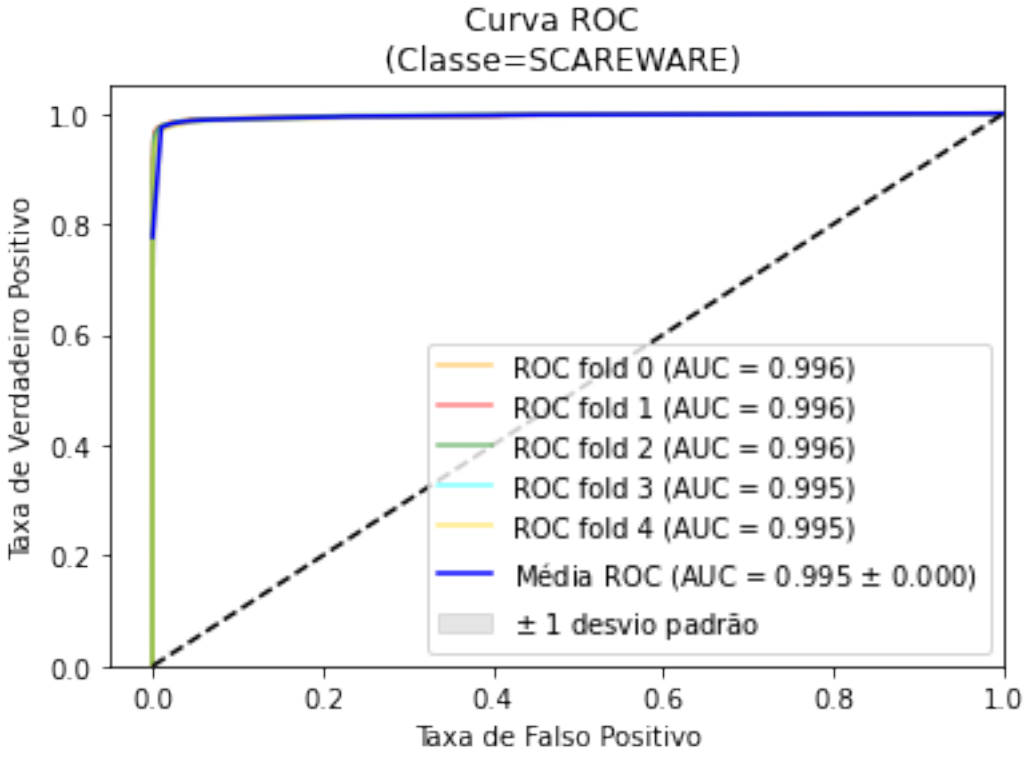
Curva ROC
(Classe=SCAREWARE)
Taxa de Verdadeiro Positivo
Taxa de Falso Positivo
0.0
0.2
0.4
0.6
0.8
1.0
ROC fold 0 (AUC = 0.996)
ROC fold 1 (AUC = 0.996)
ROC fold 2 (AUC = 0.996)
ROC fold 3 (AUC = 0.995)
ROC fold 4 (AUC = 0.995)
Média ROC (AUC = 0.995 ± 0.000)
± 1 desvio padrão

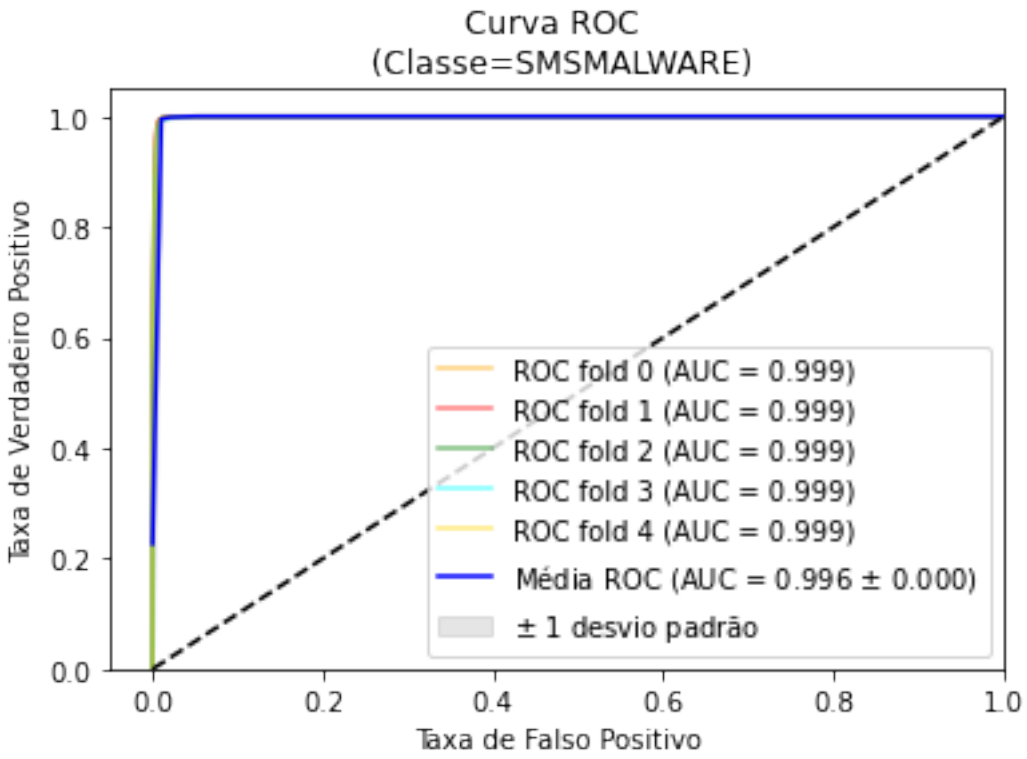


### 3.4.4 MLP (*Multi-layer Perceptron*)

- Neste algoritmo foram utilizados os mesmos hiperparametros da etapa *percentage split*. Portanto o experimento para o MLP será executado com os seguintes hiperparâmetros e dados:
  - Dados: Normalizados
  - Configuração de camadas ocultas: (100,100)

[60]:
```
clf_mlp = MLPClassifier(hidden_layer_sizes=(100,100), random_state=1)

scores, models, folds = funcoes_uteis.k_fold_train(clf_mlp,␣
↪df_treinamento_norm, clf_name='MLP')
```

```
Acurácia: 0.839
Erro: 0.161
```

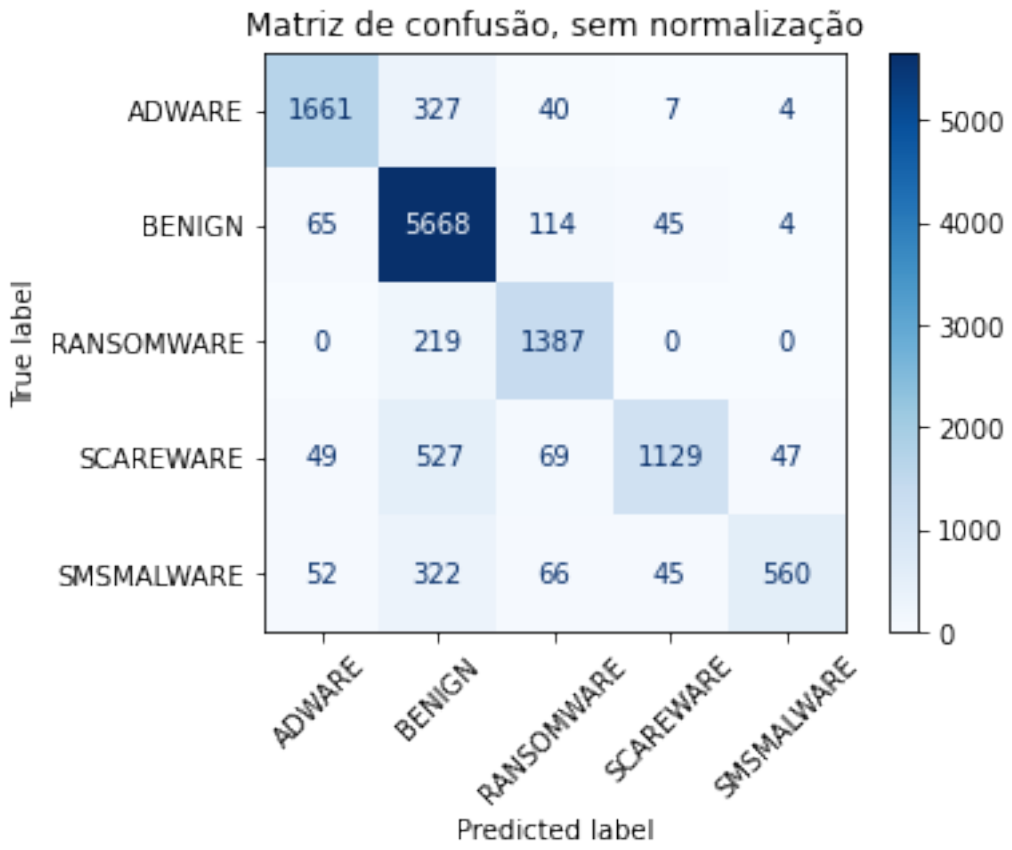
Matriz de confusão, sem normalização
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
True label
1661 327 40 7 4
65 5668 114 45 4
0 219 1387 0 0
49 527 69 1129 47
52 322 66 45 560
5000
4000
3000
2000
1000
0
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
Predicted label

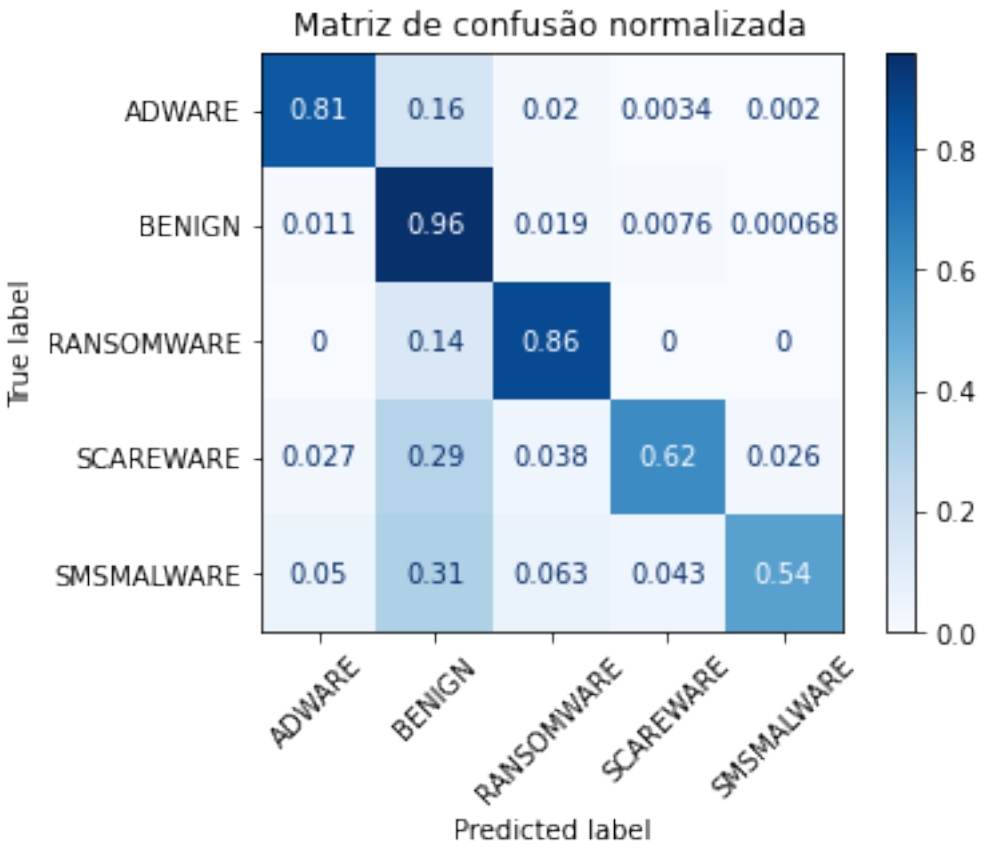
Matriz de confusão normalizada
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
0.81 0.16 0.02 0.0034 0.002
0.011 0.96 0.019 0.0076 0.00068
0 0.14 0.86 0 0
0.027 0.29 0.038 0.62 0.026
0.05 0.31 0.063 0.043 0.54
True label
Predicted label
0.0
0.2
0.4
0.6
0.8

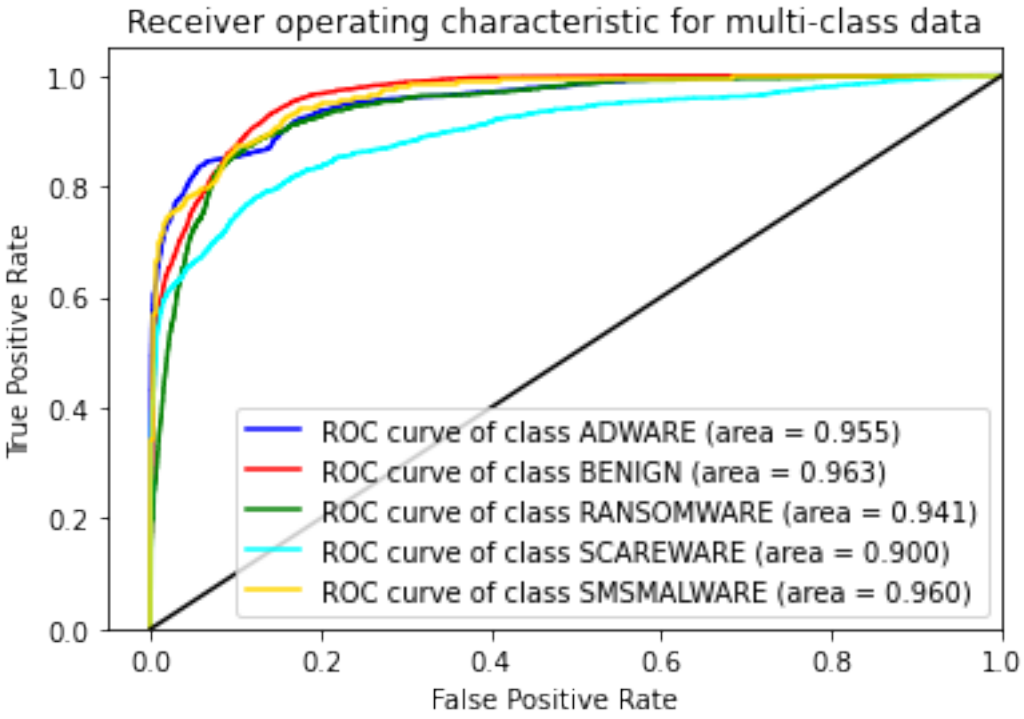
Receiver operating characteristic for multi-class data
True Positive Rate
False Positive Rate
0.0
0.2
0.4
0.6
0.8
1.0
ROC curve of class ADWARE (area = 0.955)
ROC curve of class BENIGN (area = 0.963)
ROC curve of class RANSOMWARE (area = 0.941)
ROC curve of class SCAREWARE (area = 0.900)
ROC curve of class SMSMALWARE (area = 0.960)

Acurácia: 0.787
Erro: 0.213

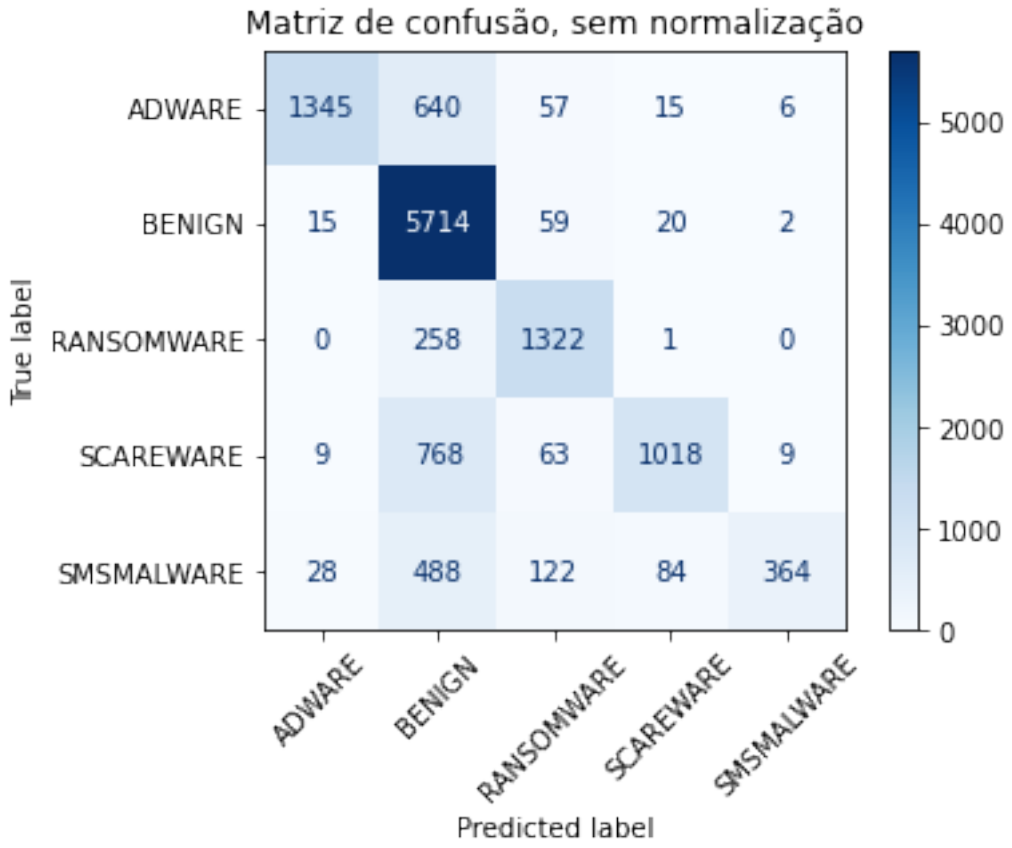

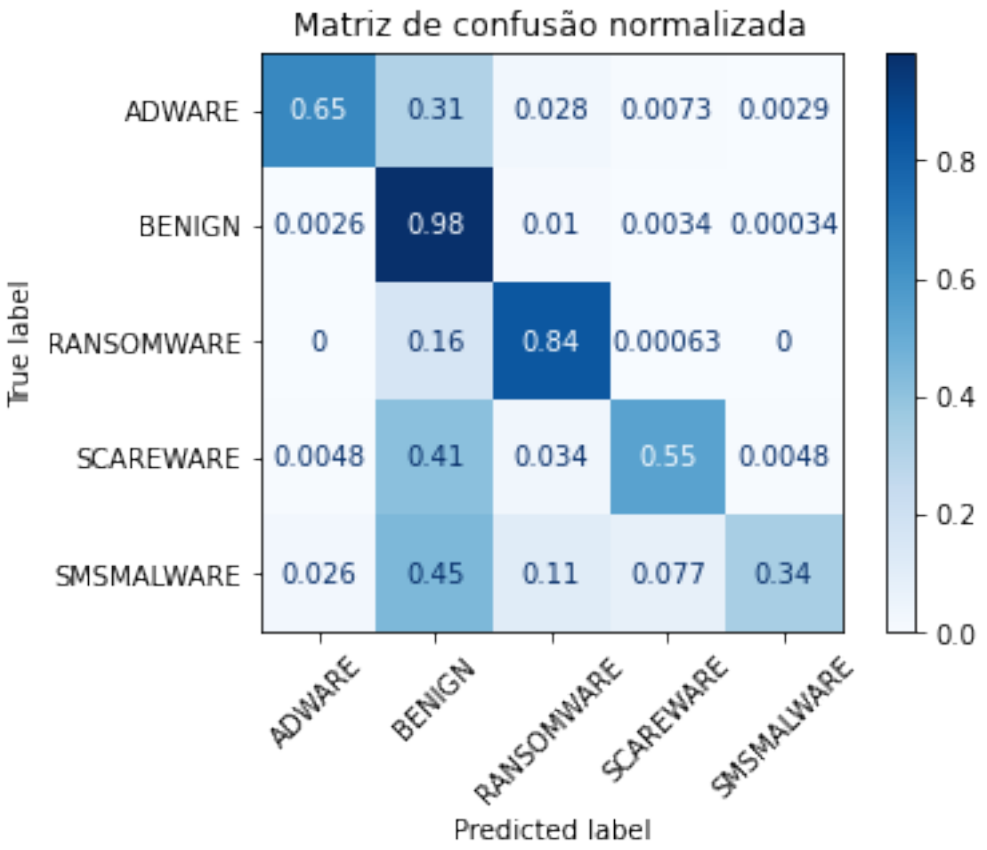
Matriz de confusão normalizada
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
True label
0.65 0.31 0.028 0.0073 0.0029
0.0026 0.98 0.01 0.0034 0.00034
0 0.16 0.84 0.00063 0
0.0048 0.41 0.034 0.55 0.0048
0.026 0.45 0.11 0.077 0.34
0.8
0.6
0.4
0.2
0.0
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
Predicted label

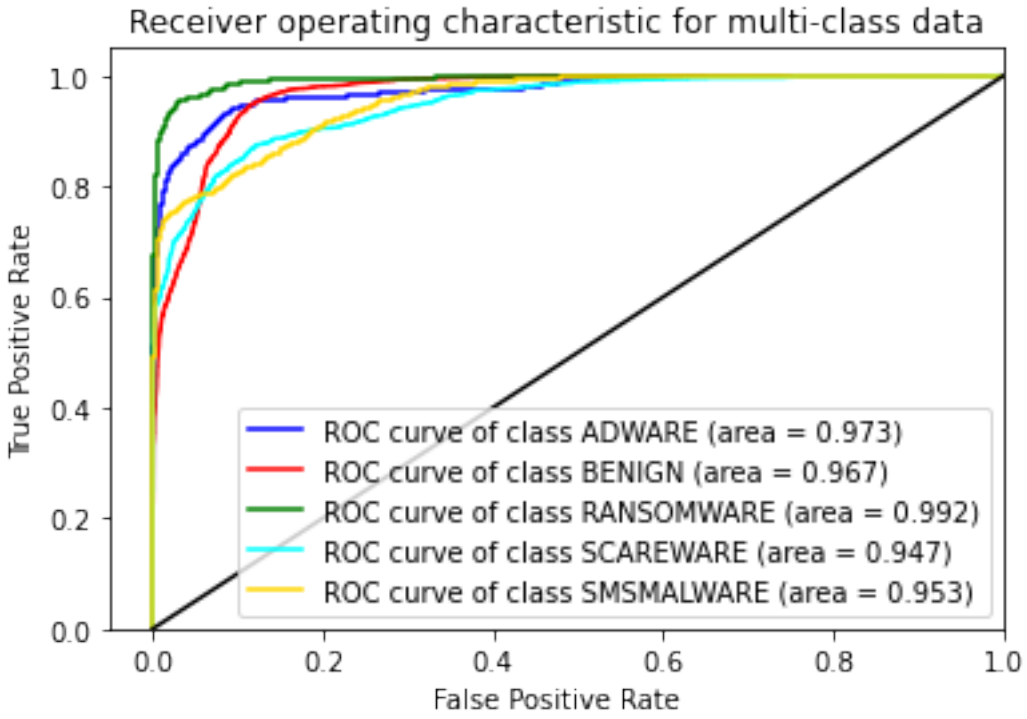
Receiver operating characteristic for multi-class data
True Positive Rate
False Positive Rate
0.0
0.2
0.4
0.6
0.8
1.0
ROC curve of class ADWARE (area = 0.973)
ROC curve of class BENIGN (area = 0.967)
ROC curve of class RANSOMWARE (area = 0.992)
ROC curve of class SCAREWARE (area = 0.947)
ROC curve of class SMSMALWARE (area = 0.953)

```
Acurácia: 0.708
Erro: 0.292
```

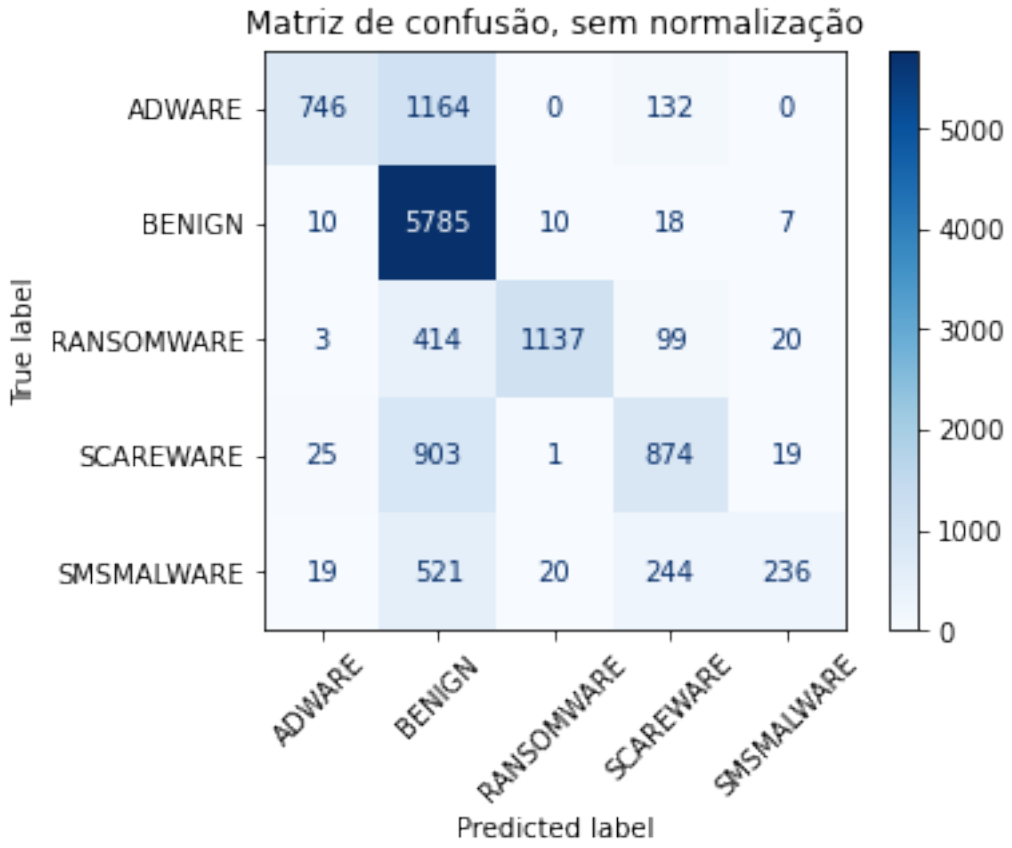

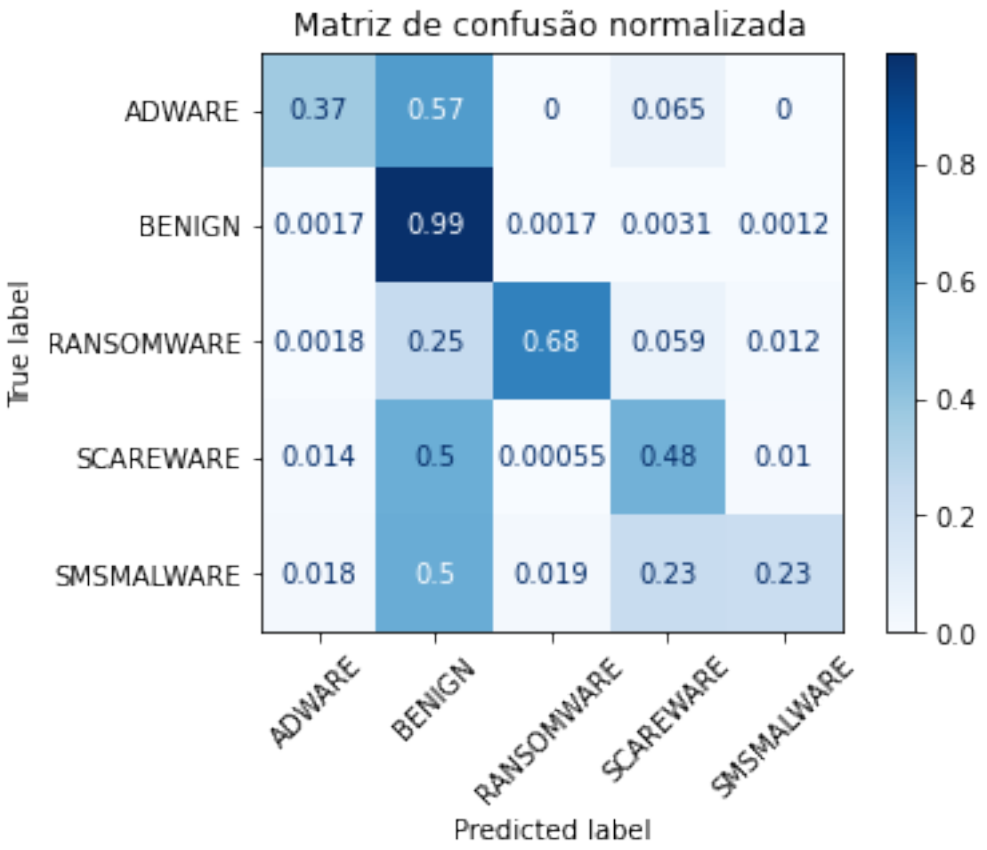
Matriz de confusão normalizada
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
0.37 0.57 0 0.065 0
0.0017 0.99 0.0017 0.0031 0.0012
0.0018 0.25 0.68 0.059 0.012
0.014 0.5 0.00055 0.48 0.01
0.018 0.5 0.019 0.23 0.23
True label
Predicted label
0.0
0.2
0.4
0.6
0.8

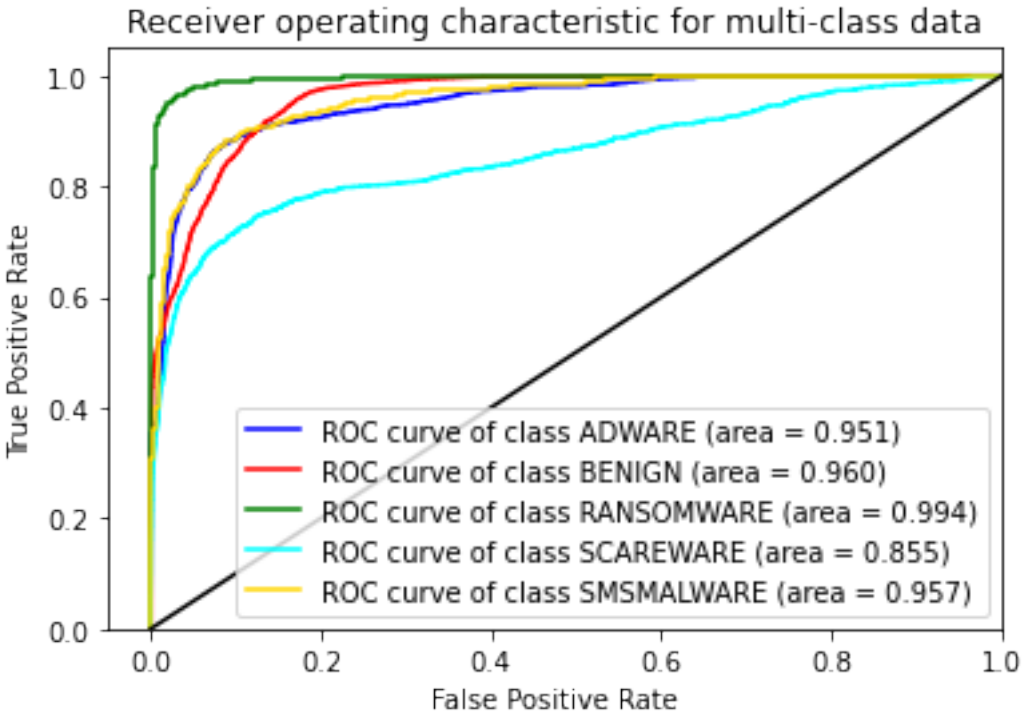
Receiver operating characteristic for multi-class data
True Positive Rate
False Positive Rate
0.0
0.2
0.4
0.6
0.8
1.0
ROC curve of class ADWARE (area = 0.951)
ROC curve of class BENIGN (area = 0.960)
ROC curve of class RANSOMWARE (area = 0.994)
ROC curve of class SCAREWARE (area = 0.855)
ROC curve of class SMSMALWARE (area = 0.957)

```
Acurácia: 0.823
Erro: 0.177
```

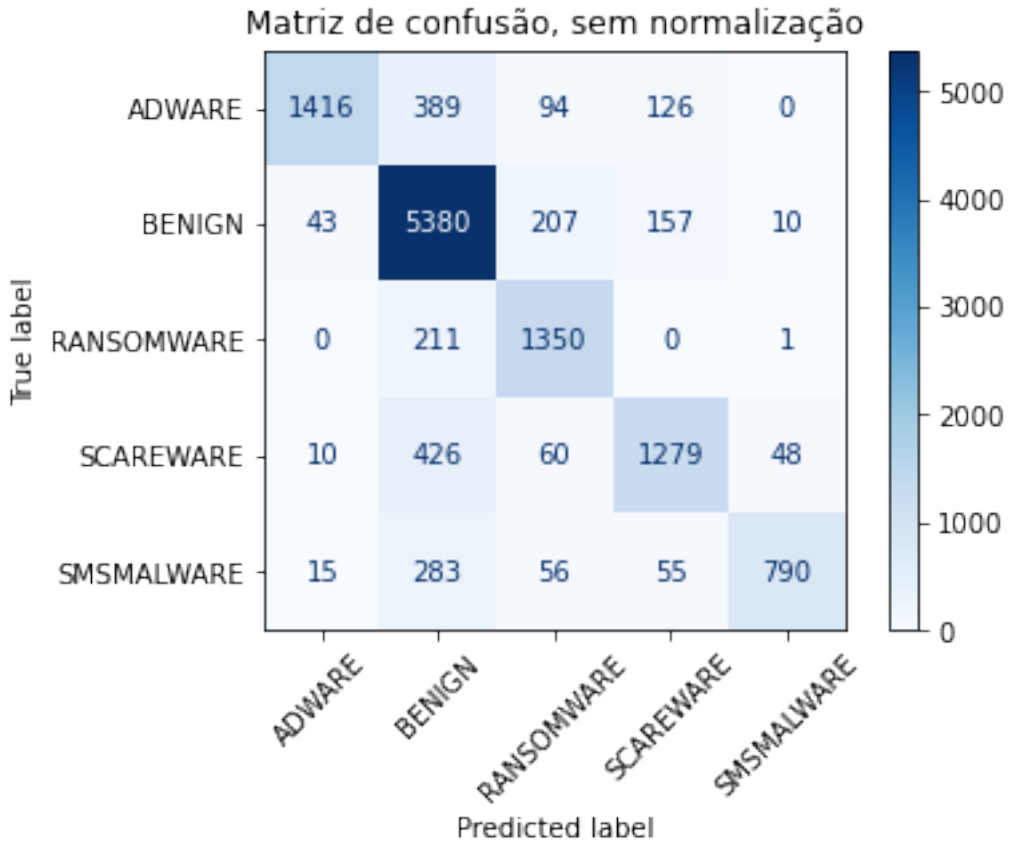

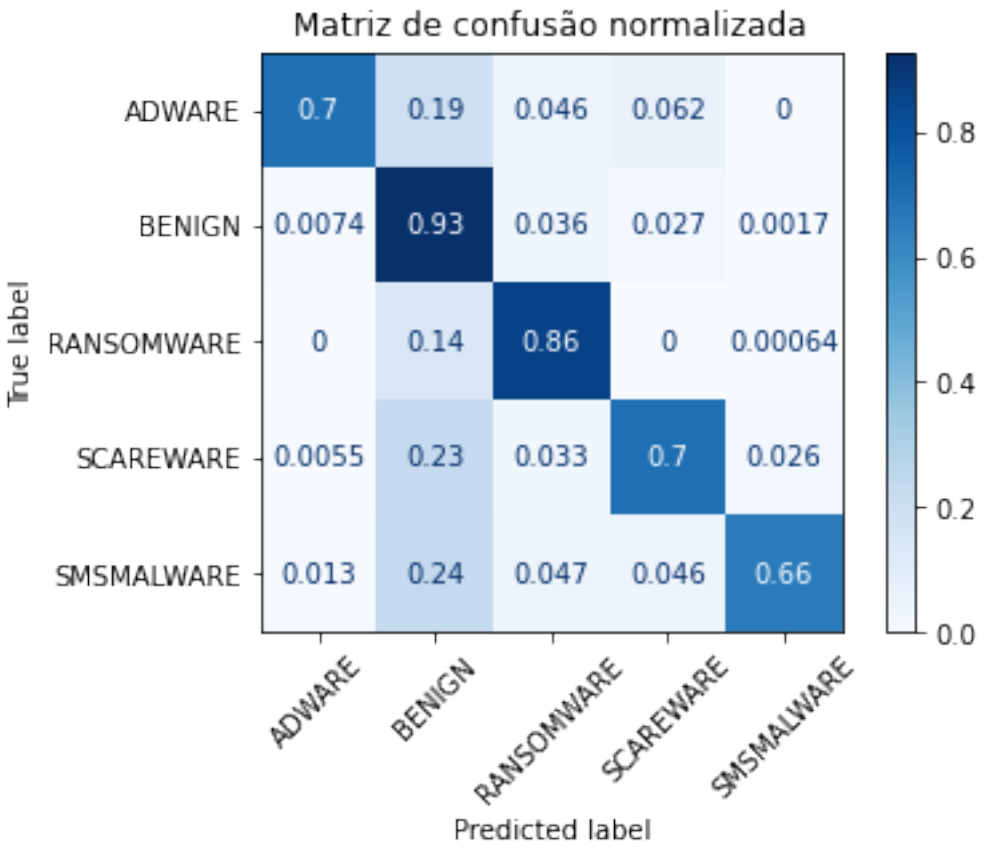
Matriz de confusão normalizada
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
0.7
0.19
0.046
0.062
0
0.0074
0.93
0.036
0.027
0.0017
0
0.14
0.86
0
0.00064
0.0055
0.23
0.033
0.7
0.026
0.013
0.24
0.047
0.046
0.66
True label
Predicted label
0.8
0.6
0.4
0.2
0.0

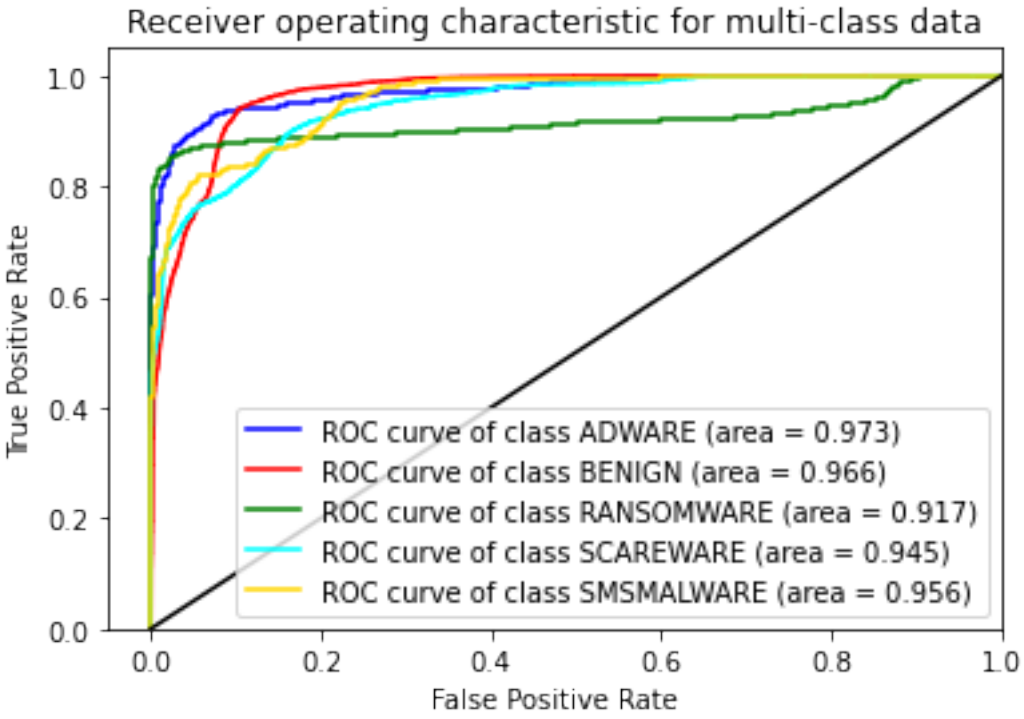
Receiver operating characteristic for multi-class data
True Positive Rate
False Positive Rate
0.0
0.2
0.4
0.6
0.8
1.0
ROC curve of class ADWARE (area = 0.973)
ROC curve of class BENIGN (area = 0.966)
ROC curve of class RANSOMWARE (area = 0.917)
ROC curve of class SCAREWARE (area = 0.945)
ROC curve of class SMSMALWARE (area = 0.956)

```
Acurácia: 0.773
Erro: 0.227
```

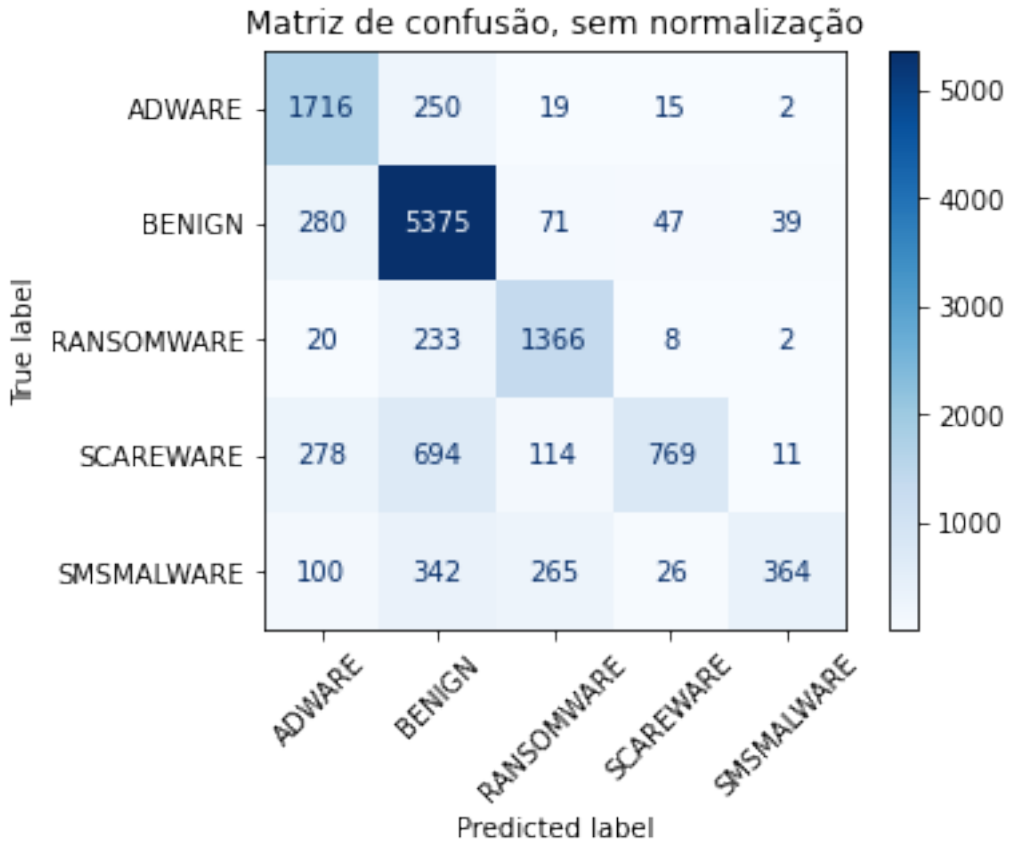

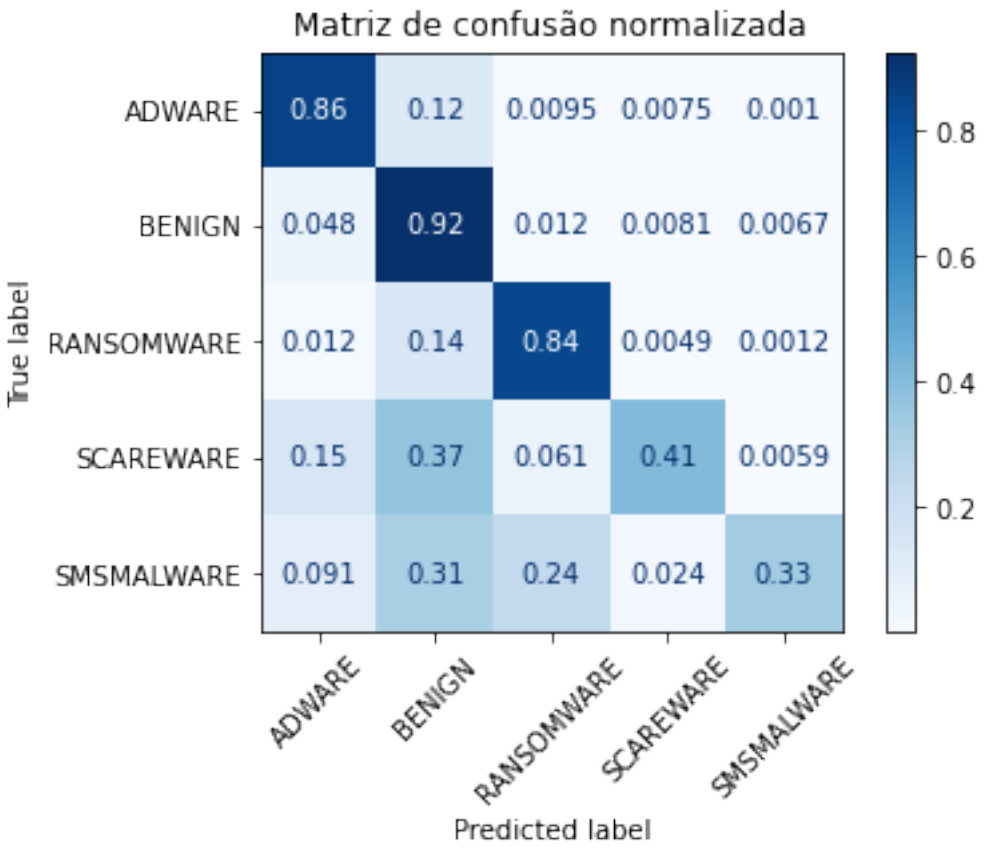
Matriz de confusão normalizada
ADWARE
BENIGN
RANSOMWARE
SCAREWARE
SMSMALWARE
0.86 0.12 0.0095 0.0075 0.001
0.048 0.92 0.012 0.0081 0.0067
0.012 0.14 0.84 0.0049 0.0012
0.15 0.37 0.061 0.41 0.0059
0.091 0.31 0.24 0.024 0.33
True label
Predicted label
0.8
0.6
0.4
0.2

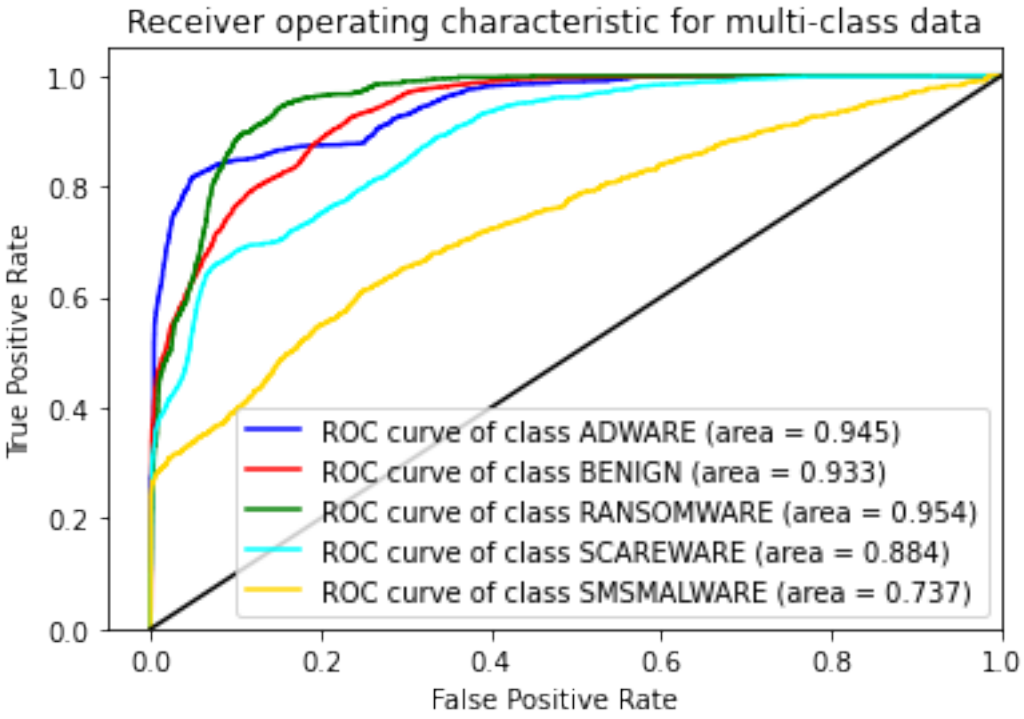
Receiver operating characteristic for multi-class data
True Positive Rate
False Positive Rate
0.0
0.2
0.4
0.6
0.8
1.0
ROC curve of class ADWARE (area = 0.945)
ROC curve of class BENIGN (area = 0.933)
ROC curve of class RANSOMWARE (area = 0.954)
ROC curve of class SCAREWARE (area = 0.884)
ROC curve of class SMSMALWARE (area = 0.737)

```
Média: 0.7858885533161174
```

[61]:
```
media_acc = sum(scores)/len(scores)
media_erro = 1 - media_acc
print("Acurácia média:", media_acc)
print("Erro médio:", media_erro)
```

```
Acurácia média: 0.7858885533161174
Erro médio: 0.2141114466838826
```

[76]:
```
scores_array = np.array(scores)
models_array = np.array(models)
folds_array = np.array(folds)
index = np.where(scores_array == max(scores_array))
melhor_model_mlp_k_fold = models_array[index]
MLP_k_fold = folds_array[index[0]]
```

[63]:
```
# Guarda o modelo gerado
dic_melhores_modelos['melhor_val_cruz_mlp'].append(melhor_model_mlp_k_fold)
dic_melhores_modelos['melhor_val_cruz_mlp'].append(media_acc)
dic_melhores_modelos['melhor_val_cruz_mlp'].append(MLP_k_fold)
```

[43]:
```
# Curva ROC por classe
funcoes_uteis.plot_roc_k_fold(clf_mlp, X_treinamento_norm, y_treinamento_norm,␣
↪5)
```

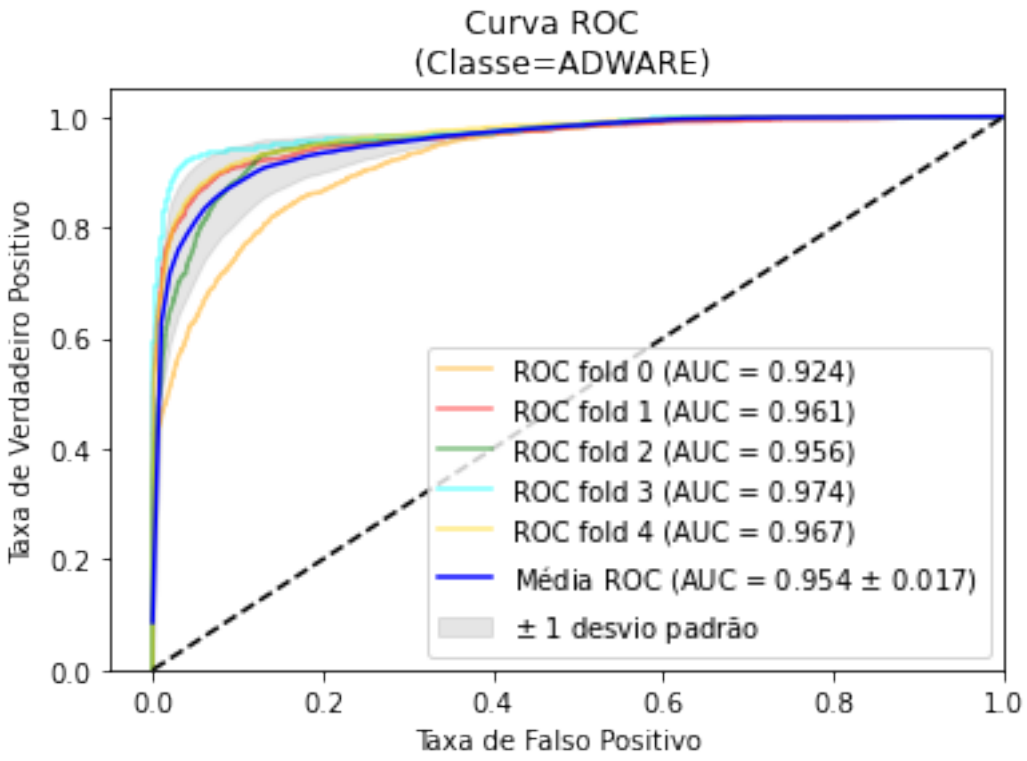
Curva ROC
(Classe=ADWARE)
Taxa de Verdadeiro Positivo
Taxa de Falso Positivo
0.0
0.2
0.4
0.6
0.8
1.0
ROC fold 0 (AUC = 0.924)
ROC fold 1 (AUC = 0.961)
ROC fold 2 (AUC = 0.956)
ROC fold 3 (AUC = 0.974)
ROC fold 4 (AUC = 0.967)
Média ROC (AUC = 0.954 ± 0.017)
± 1 desvio padrão

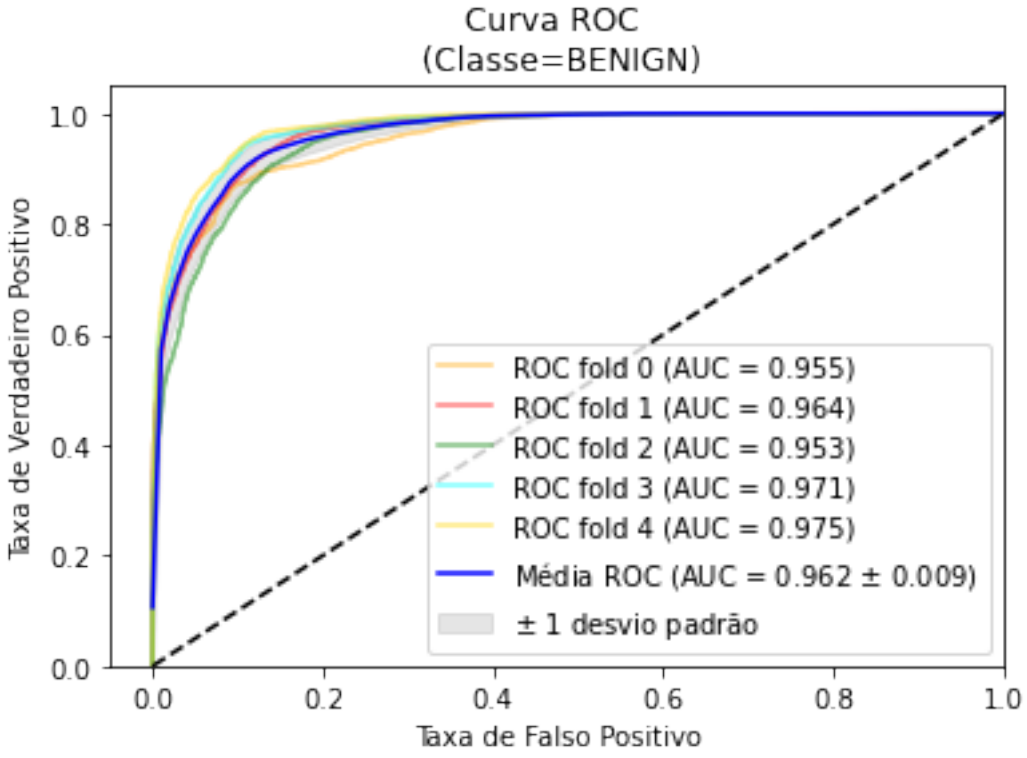
Curva ROC
(Classe=BENIGN)
Taxa de Verdadeiro Positivo
Taxa de Falso Positivo
0.0
0.2
0.4
0.6
0.8
1.0
ROC fold 0 (AUC = 0.955)
ROC fold 1 (AUC = 0.964)
ROC fold 2 (AUC = 0.953)
ROC fold 3 (AUC = 0.971)
ROC fold 4 (AUC = 0.975)
Média ROC (AUC = 0.962 ± 0.009)
± 1 desvio padrão

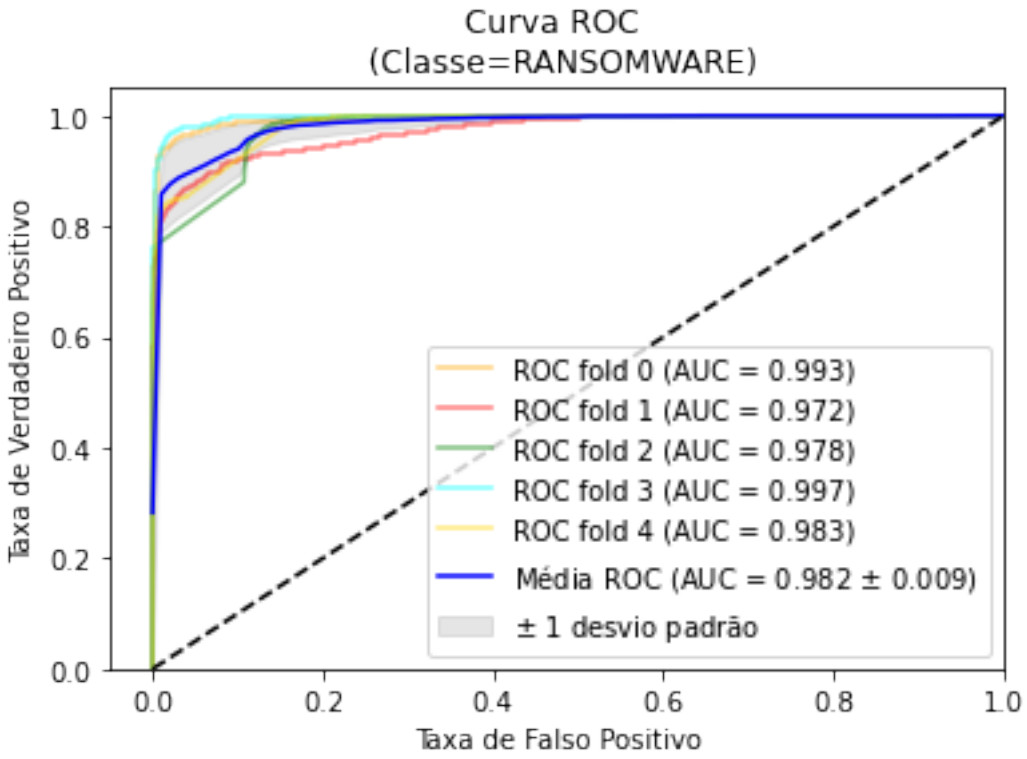
Curva ROC
(Classe=RANSOMWARE)
Taxa de Verdadeiro Positivo
Taxa de Falso Positivo
0.0
0.2
0.4
0.6
0.8
1.0
ROC fold 0 (AUC = 0.993)
ROC fold 1 (AUC = 0.972)
ROC fold 2 (AUC = 0.978)
ROC fold 3 (AUC = 0.997)
ROC fold 4 (AUC = 0.983)
Média ROC (AUC = 0.982 ± 0.009)
± 1 desvio padrão

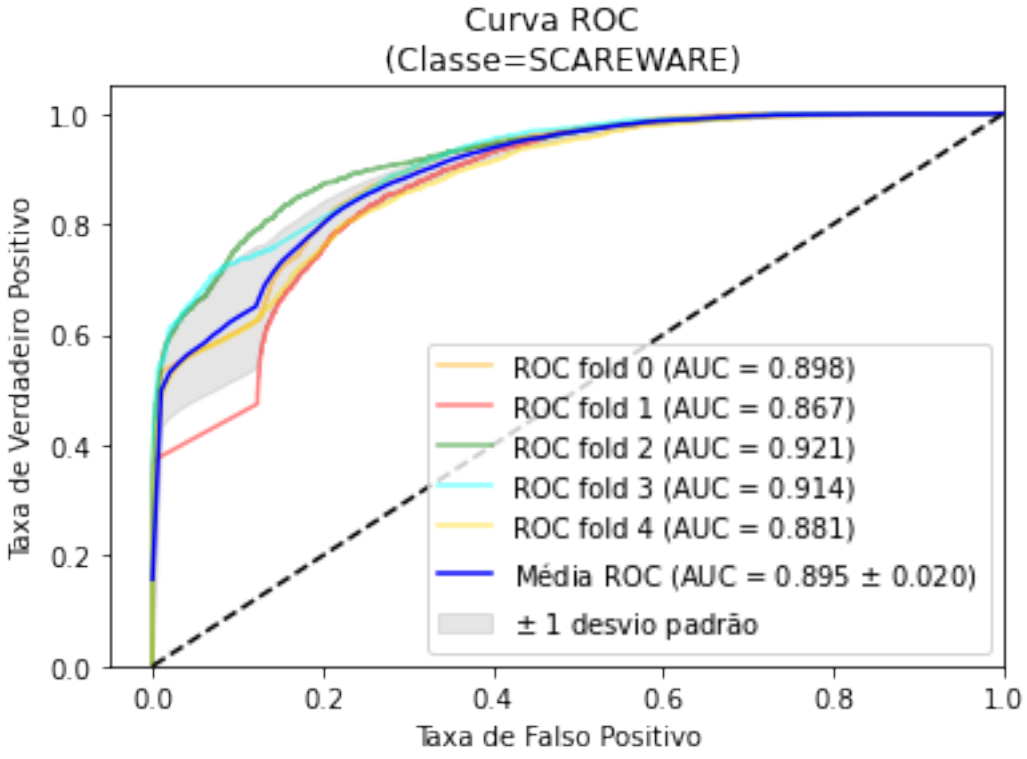
Curva ROC
(Classe=SCAREWARE)
Taxa de Verdadeiro Positivo
Taxa de Falso Positivo
0.0
0.2
0.4
0.6
0.8
1.0
ROC fold 0 (AUC = 0.898)
ROC fold 1 (AUC = 0.867)
ROC fold 2 (AUC = 0.921)
ROC fold 3 (AUC = 0.914)
ROC fold 4 (AUC = 0.881)
Média ROC (AUC = 0.895 ± 0.020)
± 1 desvio padrão

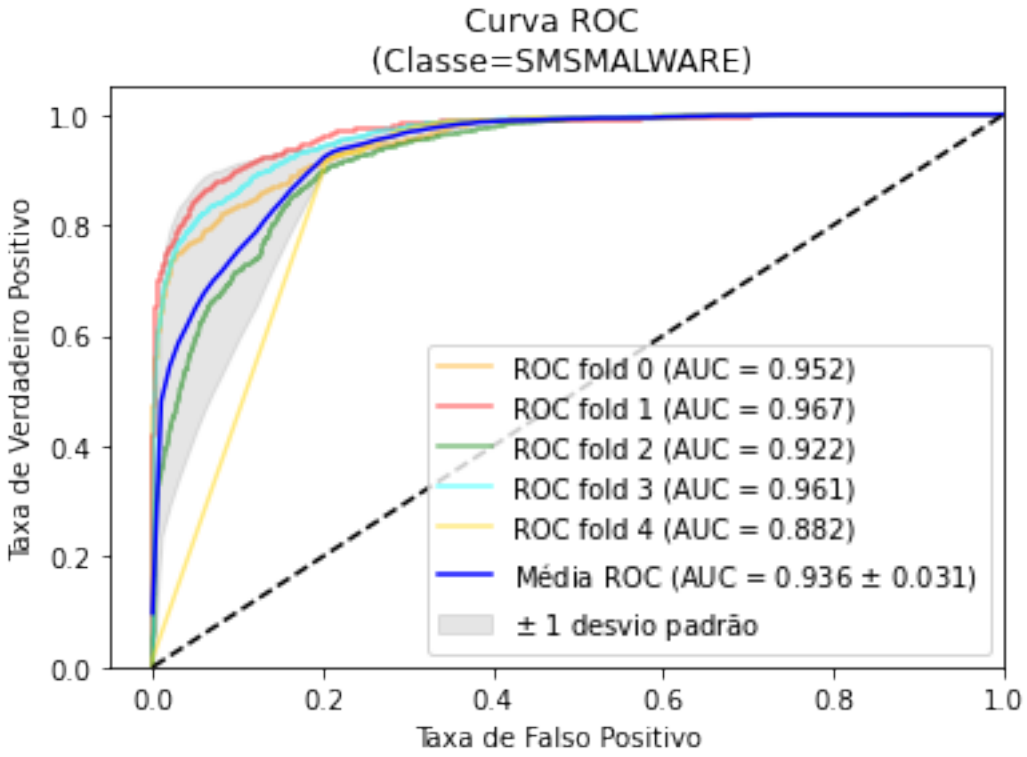


### 3.4.5 Comparação de Resultados e discussão

- É possível observar pelos experimentos com validação cruzada que os resultados são similares aos com *percentage split*, o gráfico abaixo demonstra claramente a similaridade. Esta similaridade permite-se dizer que os modelos gerados apenas com *percentage split* tendem a ser confiáveis. Novamente o MLP apresentou dificuldades em prever SMSMALWARE e SCAREWARE. Esta dificuldade fica fácil de se observar nestes experimentos, pois foi possível traçar a curva ROC por classe para cada *fold* e para estas duas classes a curva é mais próxima ao centro do gráfico.
- Entre todos os modelos gerados, o *Random Forest* conseguiu atingir os melhores resultados. A dificuldade que o MLP apresenta sobre as classes SMSMALWARE e SCAREWARE é superada pelo *Random Forest*, atingindo acertos de mais de 94/%, conforme pode ser visto pela matriz de confusão.

[164]:
```
classsificador_vc = classsificador_split_test + ['KNN', 'RF', 'MLP','KNN',␣
↪'RF', 'MLP',]
acuracias_medias_vc = acuracias_split_test + [0.489, 0.978, 0.785, 1-0.489, 1-0.
↪978, 1-0.785]
divisao_vc = divisao_split_test + ['acc_vc_media','acc_vc_media','acc_vc_media',
             'erro_vc_medio','erro_vc_medio','erro_vc_medio']
```

```
# Exibe os resultados
funcoes_uteis.plot_resultados(classsificador_vc, 'Classificador',
                              acuracias_medias_vc, 'acc_média', divisao_vc,
                              'Resultados dos classificadores', figsize=(7,5))
```

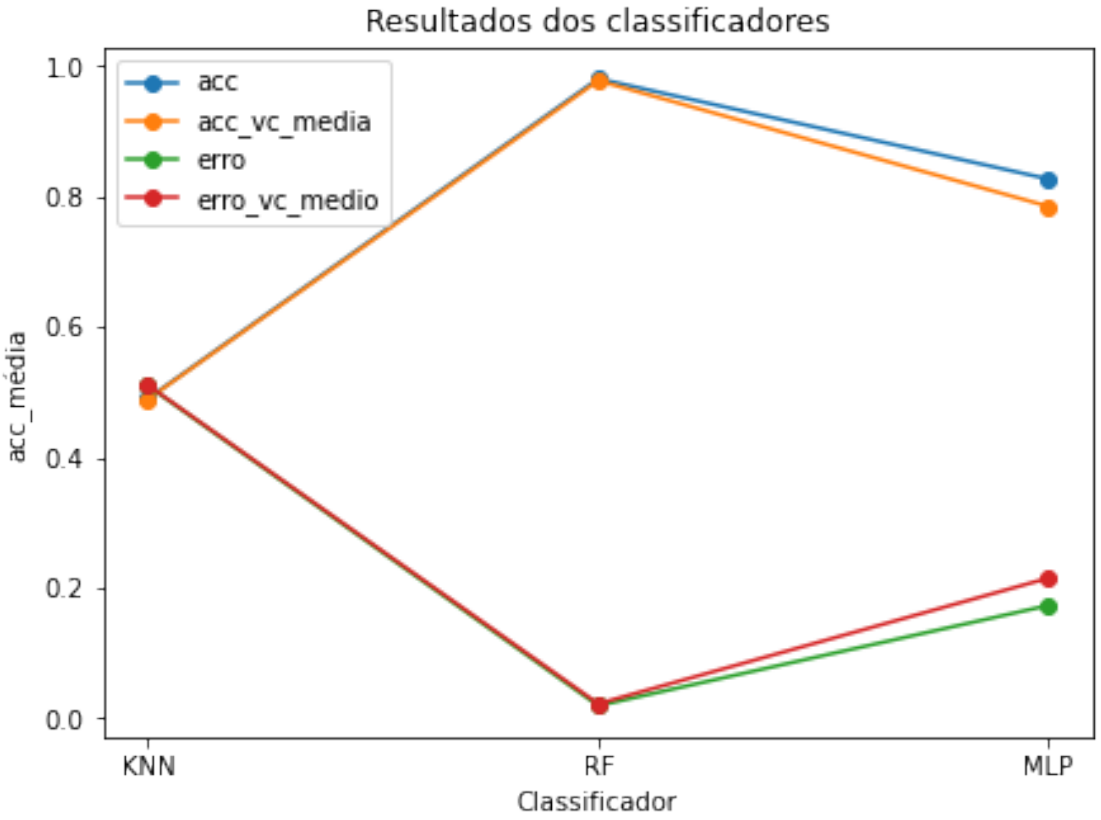


## 4 Validação dos modelos

- Nesta etapa foram calculadas as taxas de acerto, erro e exibidos a matriz de confusão e cuva ROC dos melhores modelos gerados pelas atapas anteriores, utilizando-se para isso os dados de validação.
- Nas estapas anteriores os dados normalizados foram escolhidos por alcançarem os melhores resultados, portanto, nesta etapa, também serão utilizados os dados normalizados.

[55]:
```
# Distribuição das classes
funcoes_uteis.plot_distribuicao_classes(df_validacao_norm, 'Label')
```

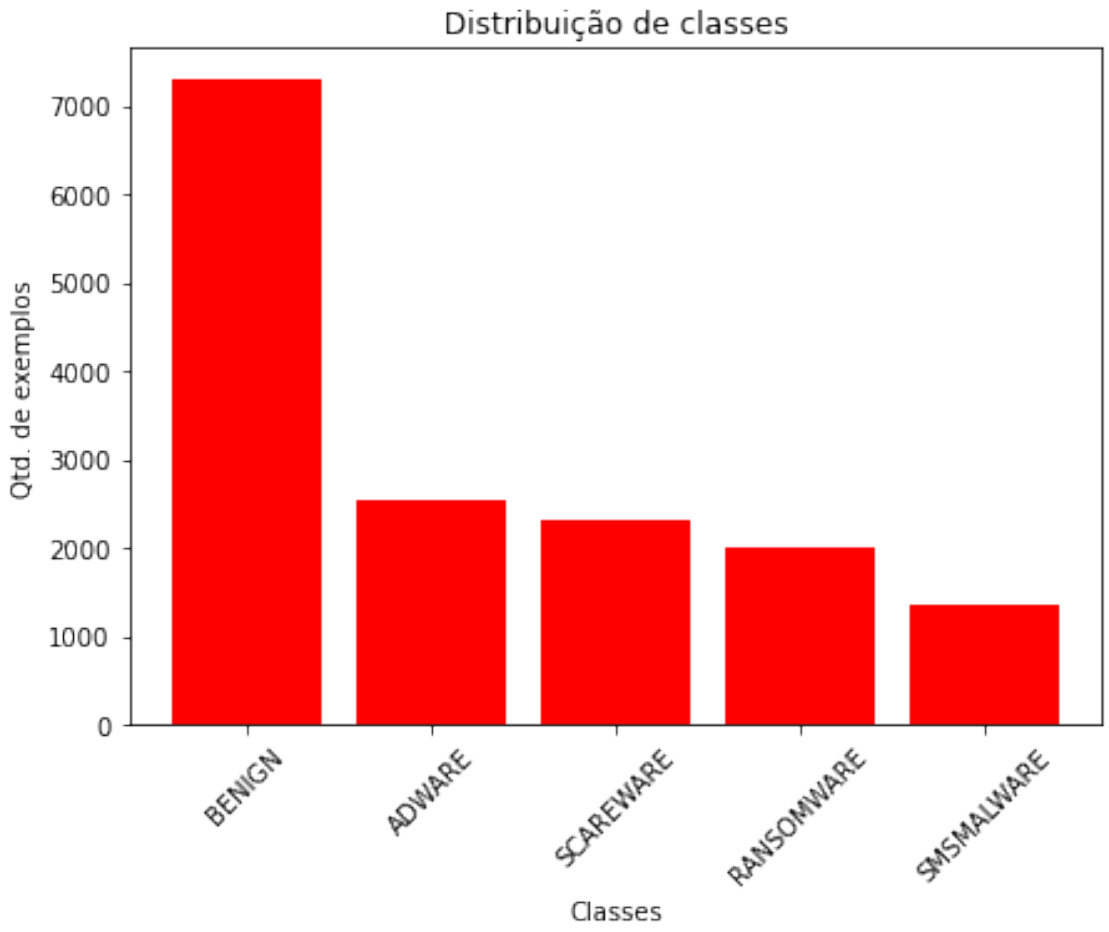


### 4.1 Preparação dos dados para validação, normalizados e não normalizados

[156]:
```
# Remove a coluna NOME_APP
df_validacao_norm = df_validacao_norm.drop('NOME_APP', axis=1)
df_validacao = df_validacao.drop('NOME_APP', axis=1)
```

[157]:
```
# Dados de validação
X_validacao_norm = df_validacao_norm.iloc[:,0:-1].values
y_validacao_norm = df_validacao_norm.iloc[:,-1].values

X_validacao = df_validacao.iloc[:,0:-1].values
y_validacao = df_validacao.iloc[:,-1].values
```

## 4.2 Melhores modelos gerados com *Percentage split*

### 4.2.1 KNN (*K-nearest neighbors algorithm*)

[112]:
```
# Obtém o modelo gerado
modelo_knn_ps = dic_melhores_modelos['split_perc_knn'][0]
y_pred = modelo_knn_ps.predict(X_validacao_norm)
print(classification_report(y_pred, y_validacao_norm, zero_division=True))
```

```
              precision    recall  f1-score   support

      ADWARE       0.18      0.44      0.26      1047
      BENIGN       0.94      0.51      0.66     13588
  RANSOMWARE       0.07      0.36      0.12       405
   SCAREWARE       0.05      0.31      0.09       379
  SMSMALWARE       0.02      0.28      0.03        90

    accuracy                           0.49     15509
   macro avg       0.25      0.38      0.23     15509
weighted avg       0.84      0.49      0.60     15509
```

[113]:
```
 # Calcula erro (1-accuracy)
accuracy = accuracy_score(y_validacao_norm, y_pred)
erro = 1 - accuracy
print('Acurácia: {:.3f}'.format(accuracy))
print('Erro: {:.3f}'.format(erro))
```

```
Acurácia: 0.492
Erro: 0.508
```

[114]:
```
# Exibe a matriz de confusão
funcoes_uteis.plot_confusion_matrix(y_validacao_norm, y_pred,
                                    set(y_validacao_norm),
                                    'Matriz de Confusão KNN (PS)')
```

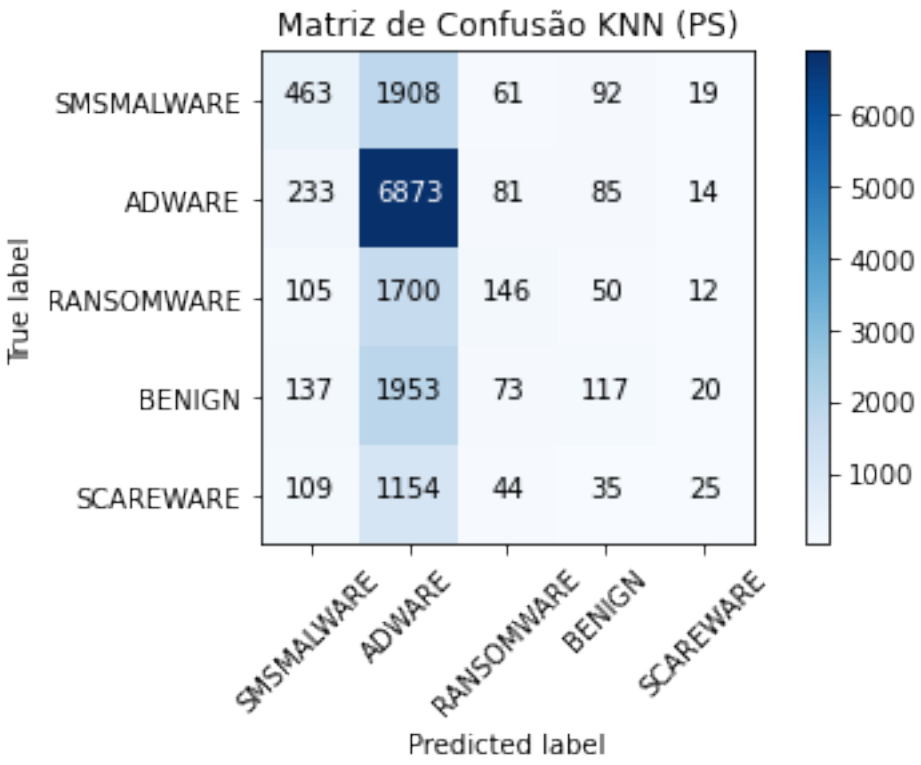


[115]:
```
# Exibe curva ROC
funcoes_uteis.plot_roc_curve(modelo_knn_ps, X_train_norm, y_train_norm,
                             X_validacao_norm, y_validacao_norm)
```

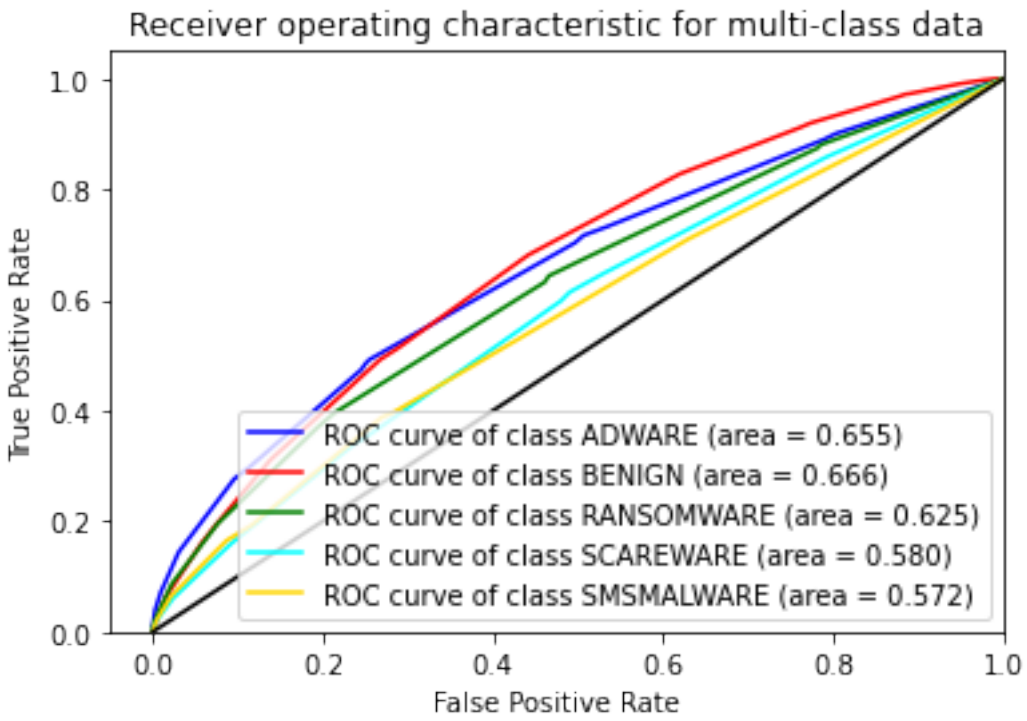


### 4.2.2 *Random Forest*

[116]:
```
# Obtém o modelo gerado
modelo_rf_ps = dic_melhores_modelos['split_perc_rf'][0]
y_pred = modelo_rf_ps.predict(X_validacao_norm)
print(classification_report(y_pred, y_validacao_norm, zero_division=True))
```

```
              precision    recall  f1-score   support

      ADWARE       0.97      0.99      0.98      2510
      BENIGN       0.99      0.97      0.98      7481
  RANSOMWARE       0.99      1.00      0.99      1986
   SCAREWARE       0.95      0.99      0.97      2199
  SMSMALWARE       0.94      0.96      0.95      1333

    accuracy                           0.98     15509
   macro avg       0.97      0.98      0.98     15509
weighted avg       0.98      0.98      0.98     15509
```

[117]:
```
# Calcula erro (1-accuracy)
accuracy = accuracy_score(y_validacao_norm, y_pred)
erro = 1 - accuracy
```

```
print('Acurácia: {:.3f}'.format(accuracy))
print('Erro: {:.3f}'.format(erro))
```

```
Acurácia: 0.978
Erro: 0.022
```

[118]:
```
# Exibe a matriz de confusão
funcoes_uteis.plot_confusion_matrix(y_validacao_norm, y_pred,
                                    set(y_validacao_norm),
                                    'Matriz de Confusão RF (PS)')
```

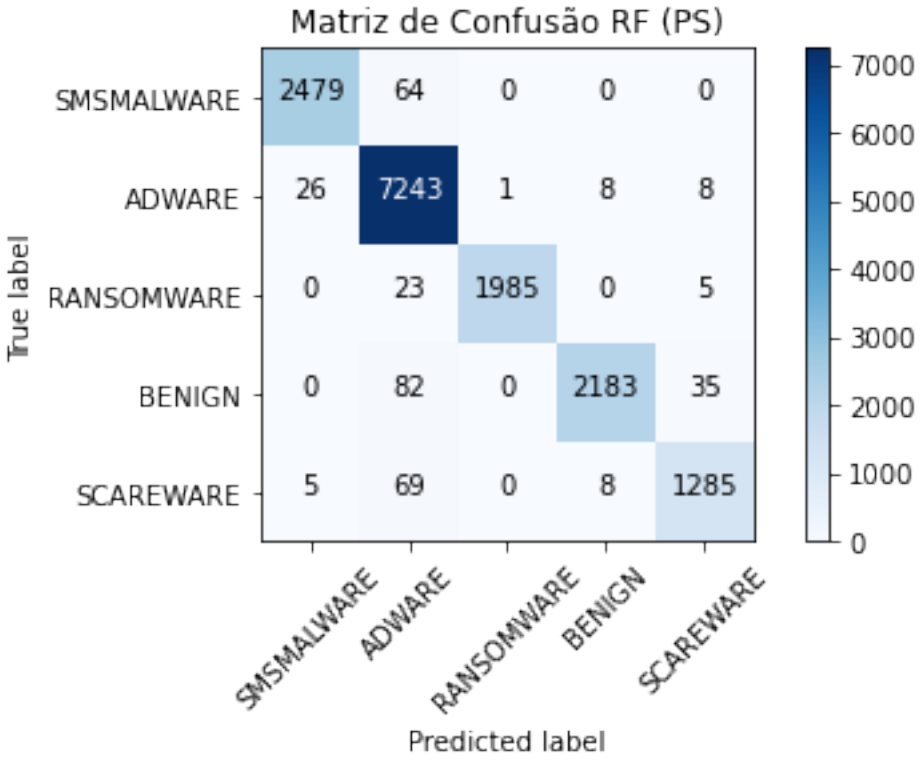


[119]:
```
# Exibe curva ROC
funcoes_uteis.plot_roc_curve(modelo_rf_ps, X_train_norm, y_train_norm,
                             X_validacao_norm, y_validacao_norm)
```

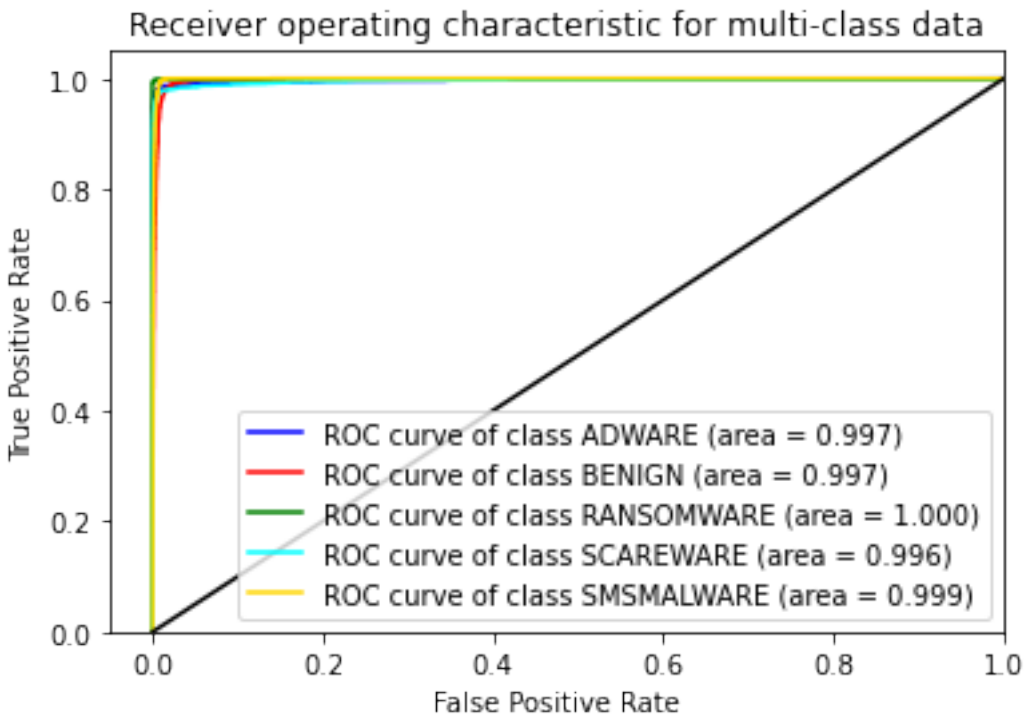


### 4.2.3 MLP (*Multi-layer Perceptron*)

[158]:
```
# Obtém o modelo gerado
modelo_mlp_ps = dic_melhores_modelos['split_perc_mlp'][0]
y_pred = modelo_mlp_ps.predict(X_validacao_norm)
print(classification_report(y_pred, y_validacao_norm, zero_division=True))
```

```
              precision    recall  f1-score   support

      ADWARE       0.83      0.78      0.80      2725
      BENIGN       0.90      0.81      0.85      8094
  RANSOMWARE       0.84      0.91      0.87      1864
   SCAREWARE       0.71      0.85      0.77      1924
  SMSMALWARE       0.61      0.92      0.74       902

    accuracy                           0.83     15509
   macro avg       0.78      0.85      0.81     15509
weighted avg       0.84      0.83      0.83     15509
```

[159]:
```
# Calcula erro (1-accuracy)
accuracy = accuracy_score(y_validacao_norm, y_pred)
erro = 1 - accuracy
```

```
print('Acurácia: {:.3f}'.format(accuracy))
print('Erro: {:.3f}'.format(erro))
```

```
Acurácia: 0.826
Erro: 0.174
```

[160]:
```
# Exibe a matriz de confusão
funcoes_uteis.plot_confusion_matrix(y_validacao_norm, y_pred,
                                    set(y_validacao_norm),
                                    'Matriz de Confusão MLP (PS)')
```

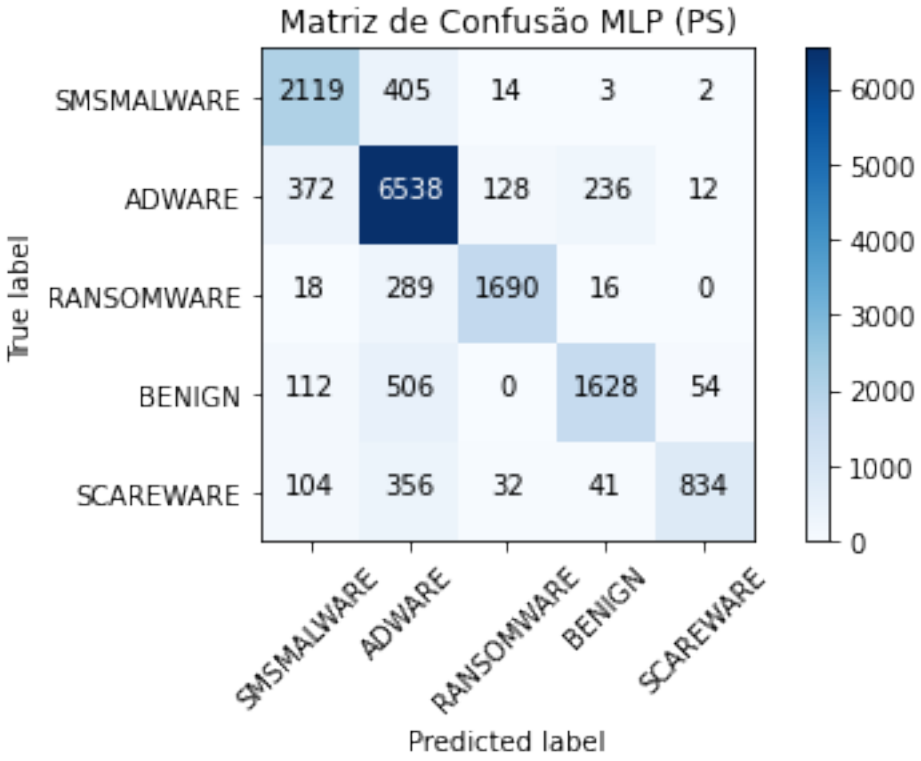


[161]:
```
# Exibe curva ROC
funcoes_uteis.plot_roc_curve(modelo_mlp_ps, X_train_norm, y_train_norm,
                             X_validacao_norm, y_validacao_norm)
```

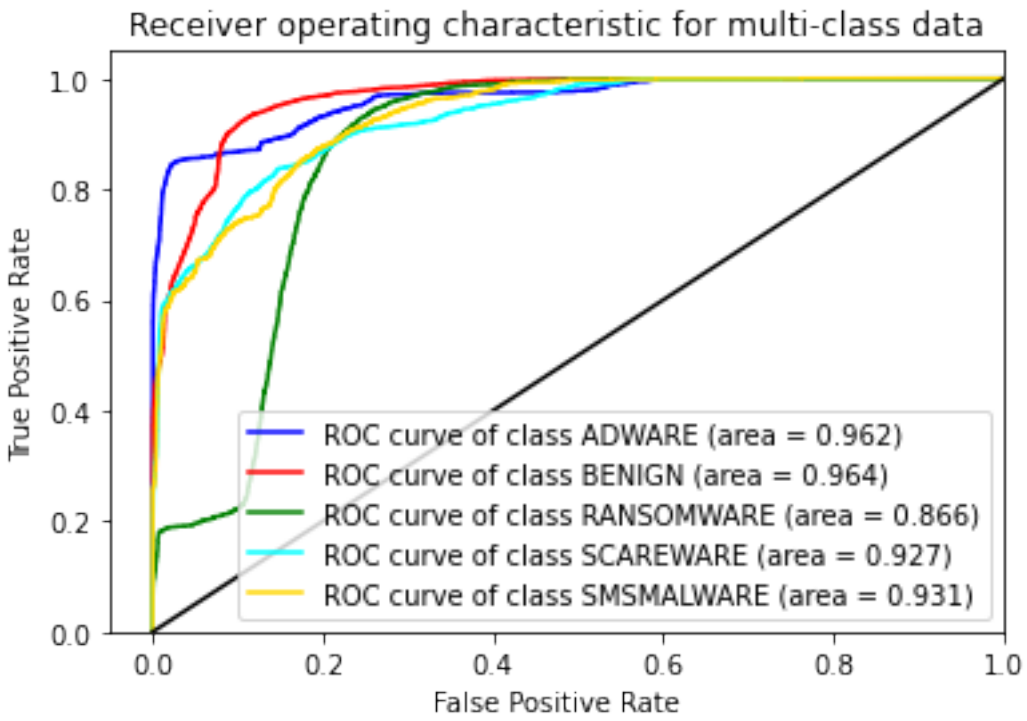


## 4.3 Melhores modelos gerados com validação cruzada

### 4.3.1 KNN (*K-nearest neighbors algorithm*)

[45]:
```
# Obtém o melhor modelo da validação cruzada
melhor_modelo_knn_vc = dic_melhores_modelos['melhor_val_cruz_knn'][0]
y_pred = melhor_modelo_knn_vc.predict(X_validacao_norm)
print(classification_report(y_pred, y_validacao_norm, zero_division=True))
```

```
              precision    recall  f1-score   support

      ADWARE       0.18      0.43      0.26      1095
      BENIGN       0.94      0.51      0.66     13554
  RANSOMWARE       0.06      0.33      0.11       399
   SCAREWARE       0.05      0.31      0.09       388
  SMSMALWARE       0.02      0.30      0.03        73

    accuracy                           0.49     15509
   macro avg       0.25      0.37      0.23     15509
weighted avg       0.84      0.49      0.60     15509
```

[46]:
```
 # Calcula erro (1-accuracy)
accuracy = accuracy_score(y_validacao_norm, y_pred)
erro = 1 - accuracy
print('Acurácia: {:.3f}'.format(accuracy))
print('Erro: {:.3f}'.format(erro))
```

```
Acurácia: 0.490
Erro: 0.510
```

[47]:
```
# Exibe a matriz de confusão
funcoes_uteis.plot_confusion_matrix(y_validacao_norm, y_pred,
                                    set(y_validacao_norm),
                                    'Matriz de Confusão KNN (VC)')
```

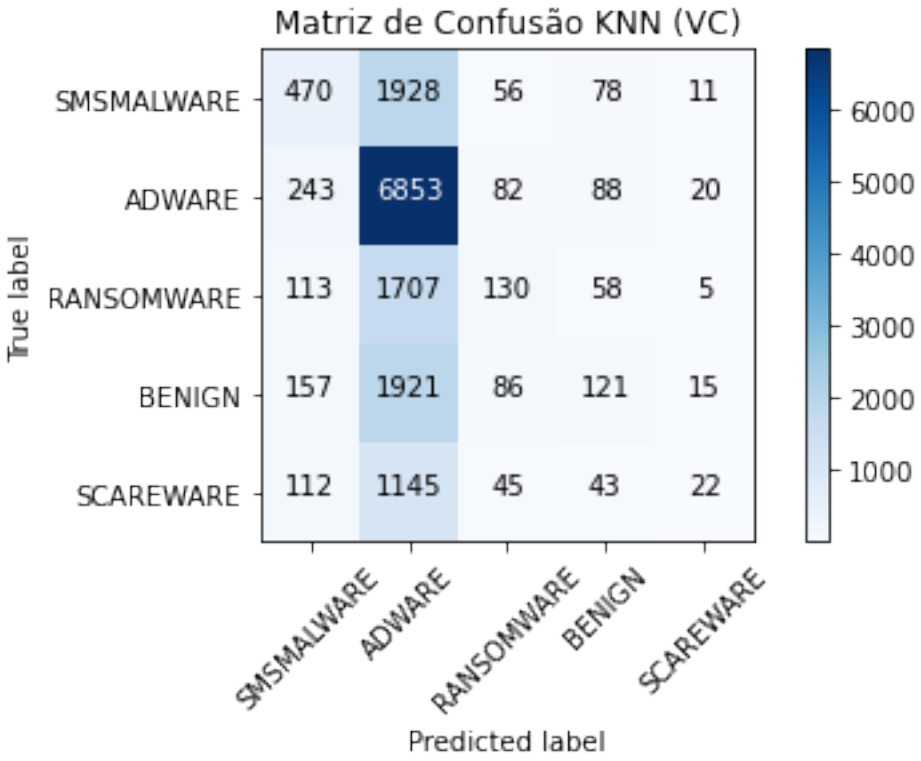


[57]:
```
# Exibe curva ROC
X_train_data = dic_melhores_modelos['melhor_val_cruz_knn'][2][0][0]
y_train_data = dic_melhores_modelos['melhor_val_cruz_knn'][2][0][1]
funcoes_uteis.plot_roc_curve(melhor_modelo_knn_vc, X_train_data, y_train_data,
                             X_validacao_norm, y_validacao_norm)
```

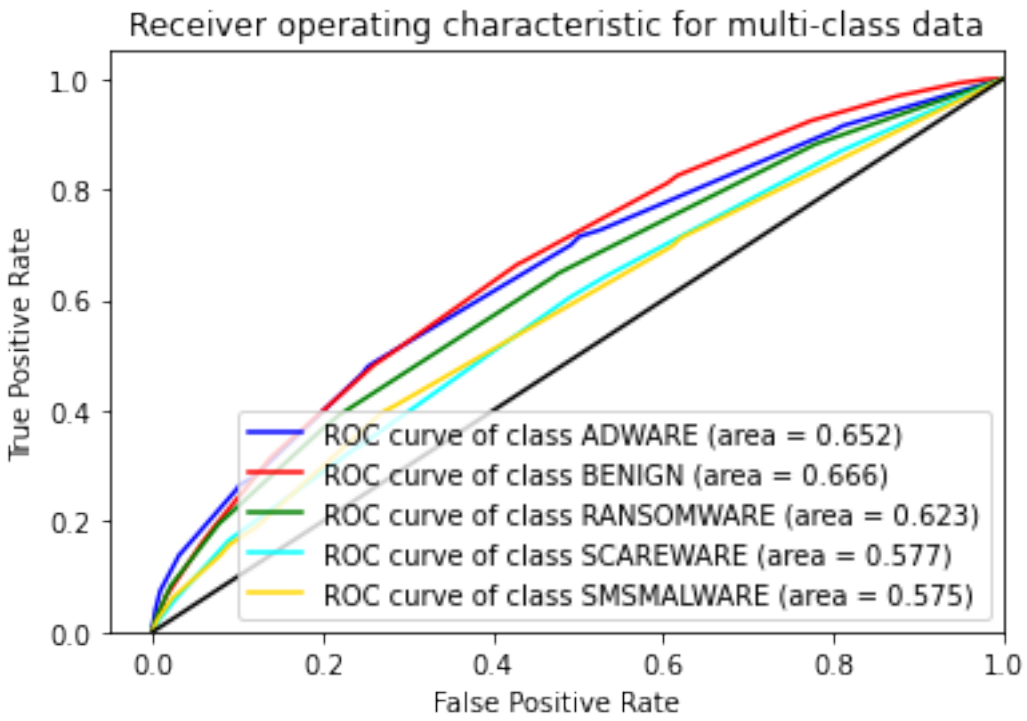


### 4.3.2 *Random Forest*

[82]:
```
X_train_data = dic_melhores_modelos['melhor_val_cruz_rf'][2][0][0]
y_train_data = dic_melhores_modelos['melhor_val_cruz_rf'][2][0][1]

clf_rf = RandomForestClassifier(n_estimators = 50, random_state=0)
clf_rf.fit(X_train_data, y_train_data)
melhor_modelo_rf_vc = clf_rf
```

[83]:
```
# Obtém o melhor modelo da validação cruzada
#melhor_modelo_rf_vc = dic_melhores_modelos['melhor_val_cruz_rf'][0][0]
y_pred = melhor_modelo_rf_vc.predict(X_validacao_norm)
print(classification_report(y_pred, y_validacao_norm, zero_division=True))
```

```
              precision    recall  f1-score   support

      ADWARE       0.97      0.99      0.98      2503
      BENIGN       0.99      0.97      0.98      7468
  RANSOMWARE       0.99      1.00      0.99      2005
   SCAREWARE       0.95      0.99      0.97      2207
 SMSMALWARE        0.94      0.97      0.96      1326

    accuracy                           0.98     15509
   macro avg       0.97      0.98      0.98     15509
```

```
weighted avg       0.98      0.98      0.98     15509
```

[84]:
```
 # Calcula erro (1-accuracy)
accuracy = accuracy_score(y_validacao_norm, y_pred)
erro = 1 - accuracy
print('Acurácia: {:.3f}'.format(accuracy))
print('Erro: {:.3f}'.format(erro))
```

```
Acurácia: 0.978
Erro: 0.022
```

[85]:
```
# Exibe a matriz de confusão
funcoes_uteis.plot_confusion_matrix(y_validacao_norm, y_pred,
                                    set(y_validacao_norm),
                                    'Matriz de Confusão RF (VC)')
```

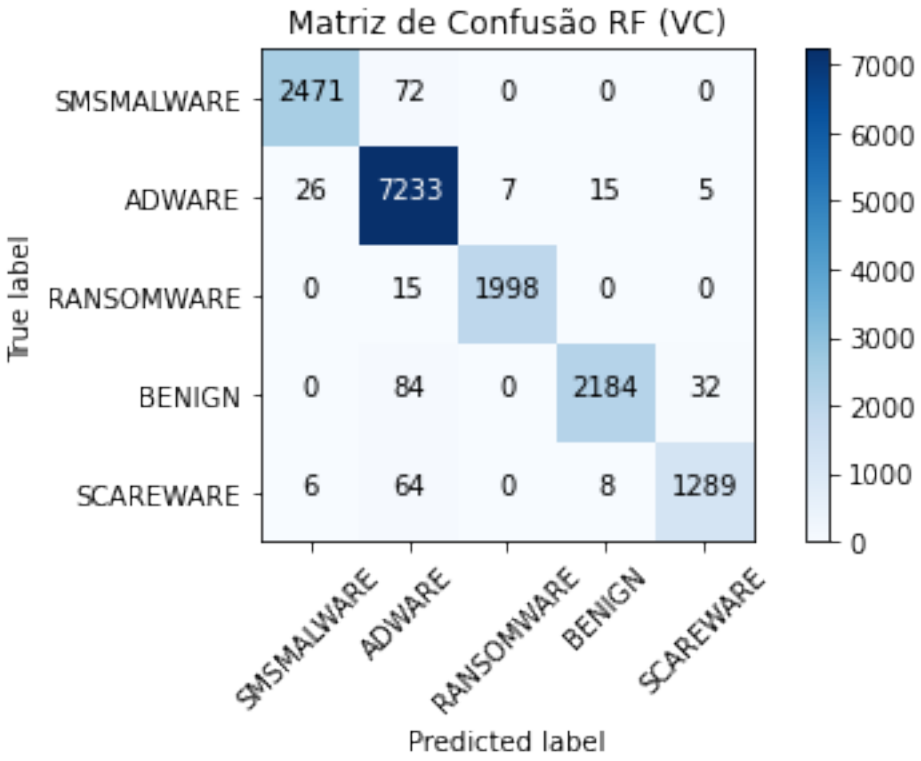


[99]:
```
# Exibe curva ROC
X_train_data = dic_melhores_modelos['melhor_val_cruz_rf'][2][0][0]
y_train_data = dic_melhores_modelos['melhor_val_cruz_rf'][2][0][1]
funcoes_uteis.plot_roc_curve(melhor_modelo_rf_vc, X_train_data, y_train_data,
                             X_validacao_norm, y_validacao_norm)
```

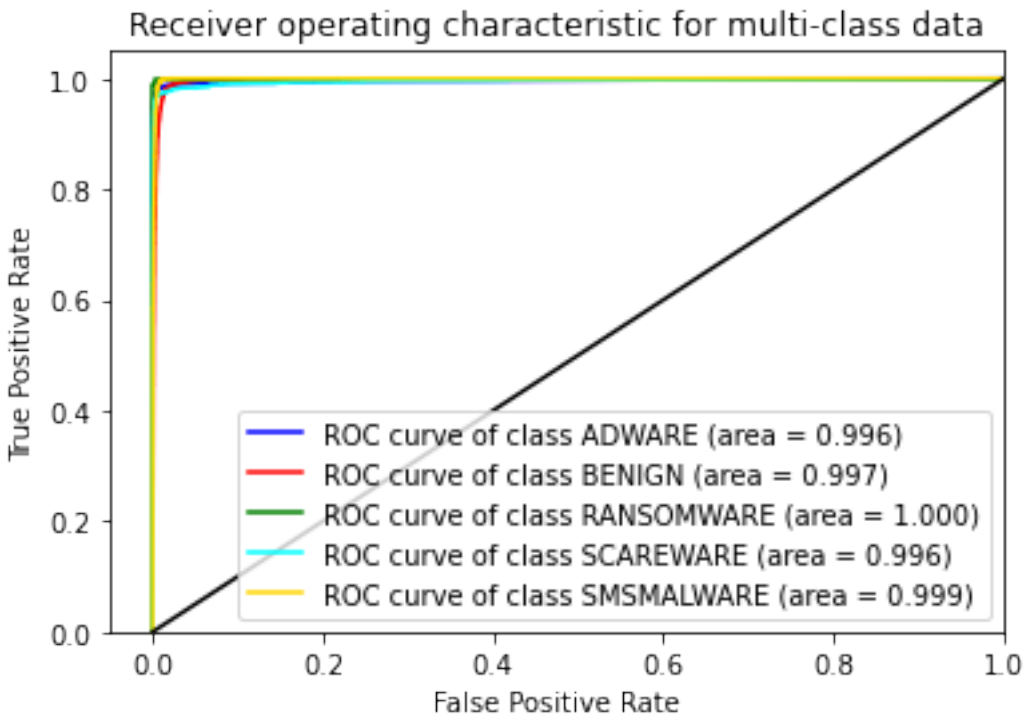


### 4.3.3 MLP (*Multi-layer Perceptron*)

[68]:
```
# Obtém o melhor modelo da validação cruzada
melhor_modelo_mlp_vc = dic_melhores_modelos['melhor_val_cruz_mlp'][0][0]
y_pred = melhor_modelo_mlp_vc.predict(X_validacao_norm)
print(classification_report(y_pred, y_validacao_norm, zero_division=True))
```

```
              precision    recall  f1-score   support

      ADWARE       0.88      0.73      0.80      3070
      BENIGN       0.93      0.78      0.85      8668
  RANSOMWARE       0.82      0.74      0.78      2241
   SCAREWARE       0.41      0.92      0.57      1032
  SMSMALWARE       0.32      0.88      0.47       498

    accuracy                           0.78     15509
   macro avg       0.67      0.81      0.69     15509
weighted avg       0.85      0.78      0.80     15509
```

[69]:
```
 # Calcula erro (1-accuracy)
accuracy = accuracy_score(y_validacao_norm, y_pred)
erro = 1 - accuracy
```

```
print('Acurácia: {:.3f}'.format(accuracy))
print('Erro: {:.3f}'.format(erro))
```

```
Acurácia: 0.775
Erro: 0.225
```

[70]:
```
# Exibe a matriz de confusão
funcoes_uteis.plot_confusion_matrix(y_validacao_norm, y_pred,
                                    set(y_validacao_norm),
                                    'Matriz de Confusão MLP (VC)')
```

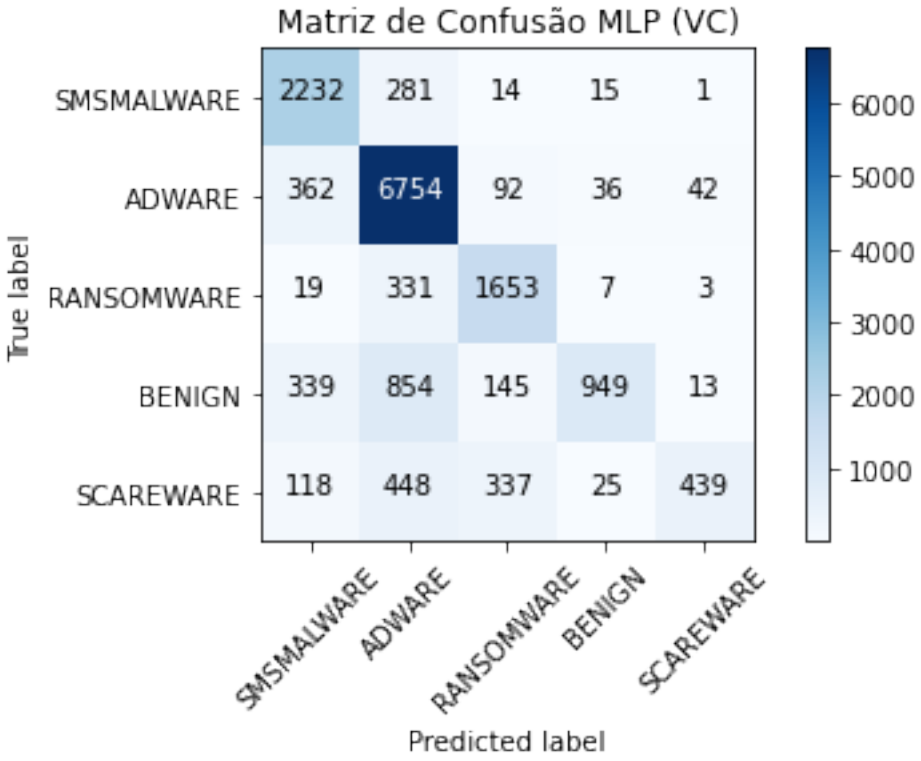


[71]:
```
# Exibe curva ROC
X_train_data = dic_melhores_modelos['melhor_val_cruz_mlp'][2][0][0]
y_train_data = dic_melhores_modelos['melhor_val_cruz_mlp'][2][0][1]
funcoes_uteis.plot_roc_curve(melhor_modelo_mlp_vc, X_train_data, y_train_data,
                             X_validacao_norm, y_validacao_norm)
```

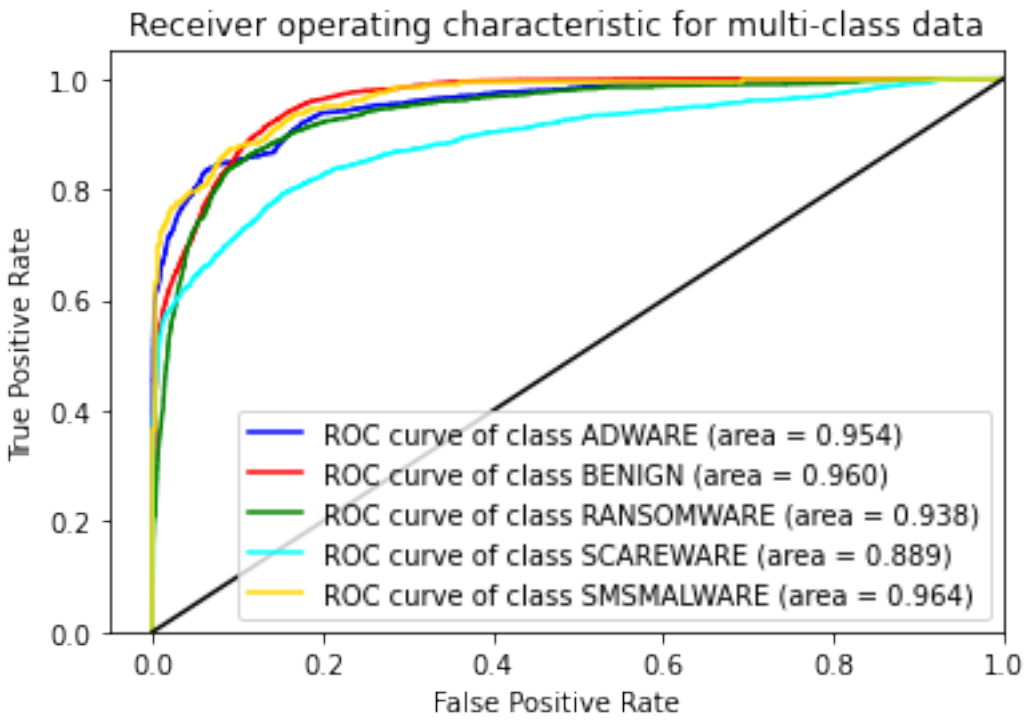


### 4.3.4 Comparação de Resultados e discussão

- Os resultados obtidos com dados de validação permite concluir que os modelos gerados são consistentes com o erro e acurácia anteriormente obtidos, dado a proximidade dos resultados.

[171]:
```
classsificador_valid = ['KNN', 'RF', 'MLP','KNN', 'RF', 'MLP','KNN', 'RF',␣
 ↪'MLP','KNN', 'RF', 'MLP']
acuracias_valid = [0.492, 0.978, 0.826, 1-0.492, 1-0.978, 1-0.826, 0.490, 0.
 ↪978, 0.775, 1-0.490, 1-0.978, 1-0.775]
divisao_valid = ['acc_ps','acc_ps','acc_ps','erro_ps','erro_ps','erro_ps',
                 'acc_vc','acc_vc','acc_vc','erro_vc','erro_vc','erro_vc']

# Exibe os resultados
funcoes_uteis.plot_resultados(classsificador_valid, 'Classificador',
                              acuracias_valid, 'acc', divisao_valid,
                              'Resultados dos classificadores\n(com dados de␣
 ↪validação)', figsize=(7,5))

# acc_ps - Acurácia Percentage Split
# acc_vc - Acurácia Validação Cruzada
```

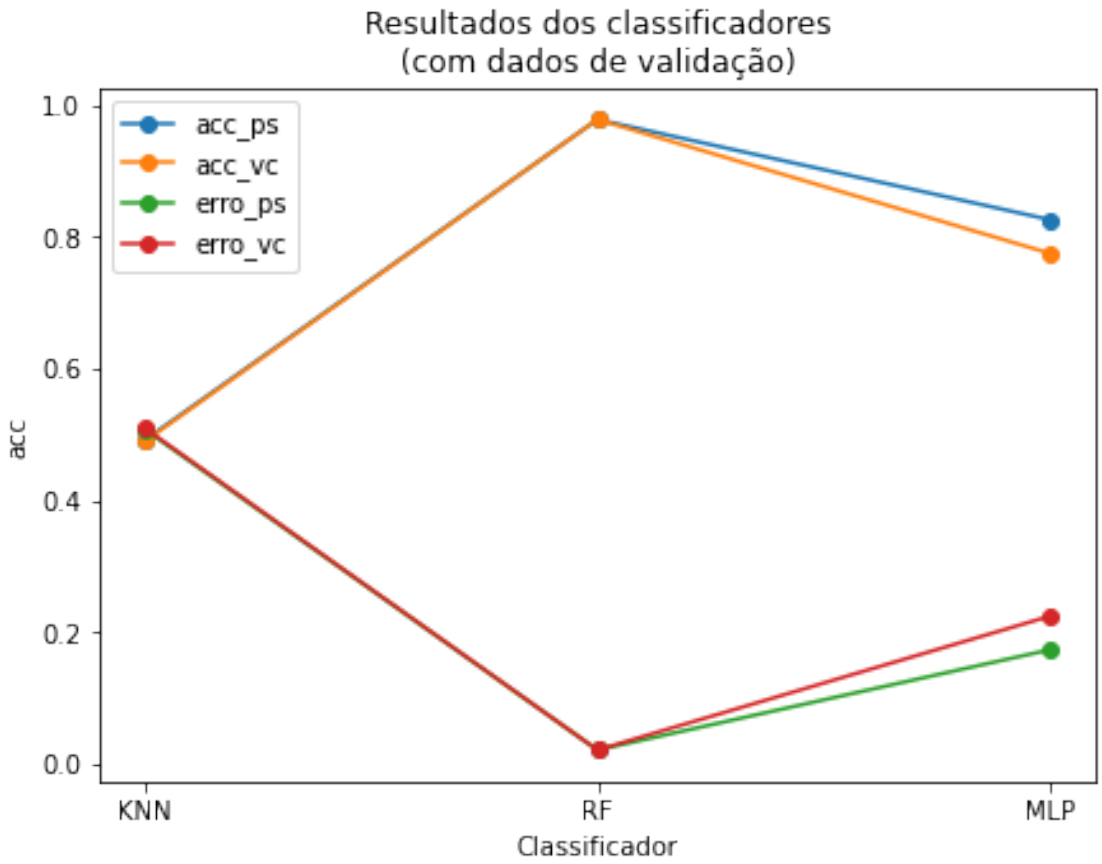


### 4.3.5 Sítese dos resultados

| **Treinamento (*Percentage Split*)** | | | | | | **Treinamento (Validação Cruzada, melhor modelo)** | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|---|
| **Acc. Dados de Teste** | | | **Acc. Dados de Validação** | | | **Acc. Média Dados de Teste** | | | **Acc. Dados de Validação** | | |
| **KNN** | **RF** | **MLP** | **KNN** | **RF** | **MLP** | **KNN** | **RF** | **MLP** | **KNN** | **RF** | **MLP** |
| 0.490 | 0.981 | 0.827 | 0.492 | 0.978 | 0.826 | 0.489 | 0.978 | 0.785 | 0.490 | 0.978 | 0.775 |